Otimização de Portfólios com Machine Learning: Integração de Deep Learning para Previsão de Regimes de Mercado

*Curso de Algotrading - INSPER

Hicham Munir Tayfour
Departamento de Economia
INSPER - Instituto de Ensino e Pesquisa
São Paulo, Brasil
hichamt@al.insper.edu.br

Prof. Raul Ikeda Gomes da Silva
Departamento de Engenharia da Computação
INSPER - Instituto de Ensino e Pesquisa
São Paulo, Brasil
rauligs@insper.edu.br

***Resumo*—Este artigo compara estratégias de otimização de portfólio (GMV, MSR) utilizando uma abordagem de rebalanceamento puramente fixo versus uma estratégia híbrida. Nesta última, mantém-se o rebalanceamento fixo como mecanismo de segurança, adicionando-se um gatilho tático 'inteligente' baseado em Machine Learning (ML) para antecipar mudanças de regime. Modelos de *deep learning* (MLP, LSTM) foram treinados para prever regimes de mercado (Alta, Baixa, Lateralização), atingindo acurácias entre 19.9% e 56.2%.**

O *backtest* comparou uma estratégia MSR de rebalanceamento fixo (Retorno Anual 30.5%, Sharpe 0.718) com uma MSR usando o gatilho de ML (Retorno Anual 30.3%, Sharpe 0.718).

Concluí-se que, nesta implementação, o uso do ML como gatilho tático não agregou valor (ΔSharpe: -0.000) e não gerou rebalanceamentos adicionais (0 *triggers*), resultando em desempenho idêntico ao da estratégia de rebalanceamento fixo.

***Index Terms*—machine learning, deep learning, otimização de portfólio, algotrading, regimes de mercado, backtesting, Sharpe ratio**

I. Introdução

A otimização de portfólios moderna, introduzida por Markowitz [1], fundamenta-se na estimativa de dois parâmetros críticos: o vetor de retornos esperados (μ) e a matriz de covariância (Σ). A dificuldade em estimar μ de forma robusta é um dos maiores desafios em finanças quantitativas. Estimadores históricos simples são notoriamente instáveis e fracos preditores de retornos futuros, um problema extensivamente discutido na literatura.

Paralelamente, avanços em Machine Learning (ML) e Deep Learning (DL) têm mostrado grande promessa na modelagem de padrões não-lineares e dependências temporais em séries financeiras. Este trabalho propõe e testa uma estratégia de alocação de ativos híbrida: em vez de usar o ML para substituir os estimadores clássicos de μ, nós o utilizamos como um mecanismo de *timing* tático. Ressalta-se que, por questões de gestão de risco e segurança operacional, o rebalanceamento periódico foi mantido também na estratégia de ML. Dessa forma, o modelo atua como um disparador de rebalanceamentos adicionais, sem eliminar a rotação periódica da carteira.

A análise é conduzida inteiramente na linguagem R [2], utilizando pacotes do ecossistema tidyverse [3] e torch [4]. A contribuição principal é a integração de um modelo de classificação de regime de mercado (baseado em MLP e LSTM) com um processo de otimização de portfólio tradicional (MSR e GMV). Avaliamos se um "rebalanceamento inteligente", acionado por mudanças de regime detectadas pelos modelos de DL, pode superar uma estratégia idêntica, mas que utiliza um rebalanceamento passivo baseado em calendário fixo.

II. Metodologia

Nossa metodologia é dividida em três etapas principais: (1) aquisição de dados e engenharia de features; (2) desenvolvimento do modelo de classificação de regime; e (3) formulação das estratégias de otimização de portfólio e o backtest.

A. Aquisição e Engenharia de Features

Utilizamos as bibliotecas tidyquant [5], TTR [6] e rbcb [7] no R para baixar e processar dados diários de 2015 a 2025 para um conjunto diversificado de ativos, incluindo:

- Ações brasileiras: PETR4.SA, TAEE11.SA, VALE3.SA, WEGE3.SA, BBAS3.SA, BBSE3.SA, ITUB4.SA, ITSA4.SA
- Ações dos EUA: AAPL, AMZN, MSFT, NVDA
- Criptomoedas: BTC-USD, ETH-USD, USDT-USD
- Commodities: GLD, SLV
- ETFs: BOVA11.SA, EFA, SPY, XOP
- *Risk-Free* : CDI e Treasury Securities

Além de indicadores técnicos padrão (SMAs, RSI, Bandas de Bollinger), foi calculado a volatilidade condicional usando o modelo eGARCH(1,1) via pacote rugarch [8]. A modelagem GARCH é essencial para capturar a clusterização de volatilidade, um fato estilizado conhecido dos retornos financeiros. Embora um grande número de features tenha sido gerado, o

Instituto de Ensino e Pesquisa - INSPER, Departamento de Economia, São Paulo, Brasil.

modelo final de ML utiliza um subconjunto selecionado de 15 indicadores, escolhidos por sua relevância, incluindo drawdown, indicadores de momentum (ex: ROC), volatilidade (eGARCH, ATR), lags de retorno e indicadores de tendência (ex: SMA Crossover, ADX).

B. Modelo de Classificação de Regime

Para prever a direção futura do mercado, desenvolvemos e comparamos dois modelos classificadores usando o pacote `torch` [4] em R: um **Multi-Layer Perceptron (MLP)** e uma **Long Short-Term Memory (LSTM)**.

O alvo da previsão (*target*) não é o retorno pontual, mas sim uma classe de regime definida por um *look-forward* de 20 dias. O conjunto de dados é dividido em tercis com base no retorno futuro:

- **Alta**: Se $Retorno_{t+20}$ estiver no 3º tercil (percentil > 66%)
- **Baixa**: Se $Retorno_{t+20}$ estiver no 1º tercil (percentil < 33%)
- **Lateralização**: Se $Retorno_{t+20}$ estiver no 2º tercil (entre 33% e 66%)

Ambos os modelos são treinados individualmente para cada ativo usando dados de treino e validação, com o desempenho final avaliado em um conjunto de teste temporalmente separado. As arquiteturas são apresentadas nas Figuras 1 e 2.

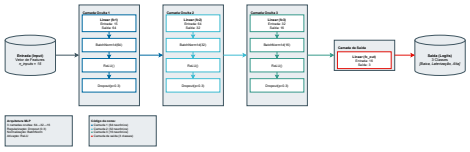


Figura 1. Estrutura do Modelo MLP para Classificação de Regime

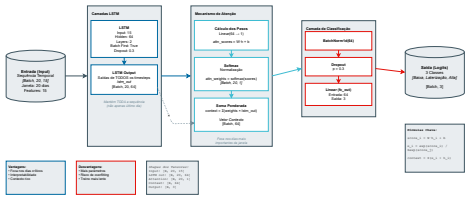


Figura 2. Estrutura do Modelo LSTM para Classificação de Regime

Modelo MLP: O MLP (Figura 1) é uma rede *feedforward* que recebe um vetor estático de 15 *features* para um único *timestep*. O modelo utiliza uma arquitetura com três camadas ocultas (64, 32 e 16 neurônios). Cada camada é seguida por `BatchNorm1d`, ativação `ReLU` e `Dropout` (taxa de 0,3) para regularização. A camada de saída final projeta a representação de 16 neurônios para as 3 classes de *logits* (Baixa, Lateralização, Alta).

Modelo LSTM: Em contraste, o modelo LSTM (Figura 2) é uma rede recorrente projetada para dados sequenciais. Ele recebe uma janela de 20 dias das 15 *features* (shape: [Batch, 20, 15]). O núcleo do modelo é uma LSTM de 2 camadas com 64 unidades ocultas. Crucialmente, o modelo utiliza a saída (hidden state) do **último *timestep*** da janela (o 20º dia) como a representação final da sequência, descartando os 19 timesteps anteriores. Esta abordagem assume que o último estado da LSTM já encapsula a informação mais relevante de toda a janela. Este vetor de saída final (shape: [Batch, 64]) é então passado por uma camada de classificação final (`BatchNorm1d`, `Dropout` e `Linear`) para produzir as 3 classes de *logits*.

O treinamento para ambos os modelos é realizado por até 150 épocas com taxa de aprendizado inicial de 0,0005 e estratégia de *early stopping*. Para lidar com o desbalanceamento de classes, implementamos **Focal Loss** ($\alpha = 0,25$, $\gamma = 2,0$) em conjunto com pesos de classe (*class weights*) derivados da distribuição dos dados de treino, melhorando a capacidade do modelo de identificar as classes minoritárias.

C. Otimização de Portfólio e Backtest

Como baseline de desempenho, implementamos duas estratégias clássicas de otimização de média-variância, rebalanceadas periodicamente usando uma janela móvel (lookback) de 126 dias. O backtesting não utilizou pacotes de terceiros, mas sim um motor de backtest vetorial customizado, construído em R, para permitir a integração com lógicas de rebalanceamento complexas.

Implementamos também variantes que permitem alocação em ativo livre de risco (RF), com restrição de peso máximo de 30% (RF≤30%), visando avaliar o impacto da inclusão de um porto seguro nas estratégias.

1) Mínima Variância Global (GMV): O portfólio GMV independe dos retornos esperados e foca apenas na minimização do risco (variância) da carteira. A formulação busca os pesos $\mathbf{w}$ que resolvem:

$$\min_{\mathbf{w}} \quad \mathbf{w}^T \Sigma \mathbf{w} \quad \text{s.t.} \quad \mathbf{w}^T \mathbf{1} = 1 \tag{1}$$

onde Σ é a matriz de covariância amostral calculada na janela de lookback.

2) Máximo Sharpe Ratio (MSR) Long-Only: O portfólio MSR busca a alocação que maximiza o retorno por unidade de risco [9]. Esta é a carteira de tangência na fronteira eficiente. A formulação é equivalente a:

$$\min_{\mathbf{w}} \quad \frac{1}{2}\mathbf{w}^T \Sigma \mathbf{w} \quad \text{s.t.} \quad \mathbf{w}^T \boldsymbol{\mu} = \mu_p, \quad \mathbf{w} \geq 0 \tag{2}$$

onde $\boldsymbol{\mu}$ é o vetor de retornos médios históricos da janela de lookback e a restrição $\mathbf{w} \geq 0$ impõe uma carteira long-only, resolvida via programação quadrática usando o pacote quadprog [10].

III. Resultados Empíricos

A. Análise Exploratória

A análise de correlação mostra como as relações entre os ativos mudam em diferentes regimes (Pré-Pandemia, Pandemia, Pós-Pandemia, figuras 8 a 12). Notavelmente, a correlação entre ativos de risco tende a aumentar significativamente em períodos de estresse. Por exemplo, a correlação entre o mercado brasileiro (BOVA11.SA) e americano (SPY) saltou de **0.473** (Pré-Pandemia) para **0.783** (Pandemia), demonstrando o colapso da diversificação durante crises.

Esta instabilidade generalizada da matriz Σ é um problema conhecido como "estimation error"(erro de estimação). Confiar em uma matriz de covariância histórica de longo prazo para otimização é problemático, pois ela não reflete as dinâmicas de correlação do regime atual.

B. Performance dos Modelos de Regime

O modelo MLP e LSTM foi treinado para cada ativo. A Tabela I resume a acurácia obtida no conjunto de teste para os principais ativos.

Tabela I
ACURÁCIA DE CLASSIFICAÇÃO DE REGIME POR ATIVO (MLP VS. LSTM)

Ativo	Acur. MLP (%)	Acur. LSTM (%)
Ações Brasil		
BBAS3.SA	38.9%	32.4%
BBSE3.SA	30.1%	40.3%
ITSA4.SA	39.6%	31.3%
ITUB4.SA	45.6%	45.2%
PETR4.SA	35.8%	47.1%
TAEE11.SA	28.2%	46.0%
VALE3.SA	21.8%	51.2%
WEGE3.SA	24.9%	37.1%
Ações EUA		
AAPL	29.5%	34.8%
AMZN	36.9%	40.4%
MSFT	41.5%	32.3%
NVDA	38.7%	36.4%
Criptomoedas		
BTC-USD	24.2%	25.1%
ETH-USD	40.9%	45.1%
USDT-USD	56.2%	53.6%
Commodities		
GLD	21.0%	19.9%
SLV	32.8%	26.4%
ETFs		
BOVA11.SA	39.3%	38.9%
SPY	32.8%	36.7%
EFA	44.1%	40.8%
XOP	39.1%	42.3%

Os resultados mostram desempenho variável dependendo do ativo. Ativos como GLD (**21.0%**) e EFA (**44.1%**) apresentam alguma acurácia, enquanto ativos mais voláteis como NVDA (**38.7%**) e criptomoedas apresentam maior dificuldade de previsão. É importante notar que a acurácia de um modelo baseline (aleatório) seria de **33.3%**, dado que a metodologia de labeling por percentil cria três classes balanceadas. Os resultados indicam que, embora alguns modelos superem marginalmente o baseline, outros (como GLD) falham em extrair qualquer sinal preditivo (figuras 23 a 28).

C. Backtesting das Estratégias Baseline

Realizamos o backtest das estratégias MSR (histórica) e GMV para as carteiras "Nacional"e "Internacional". É fundamental notar que este backtest utiliza apenas dados históricos (μ e Σ amostrais) e não utiliza os sinais do modelo de ML. As métricas de desempenho estão resumidas na Tabela II.

A Tabela II demonstra que as estratégias MSR (históricas) superaram significativamente as estratégias GMV em termos de retorno anualizado e Sharpe Ratio. A estratégia MSR Internacional alcançou um Sharpe Ratio de **1.005**. No entanto, uma análise mais profunda revela instabilidade significativa nas alocações.

Tabela II
MÉTRICAS DE DESEMPENHO DO BACKTEST (COMPARATIVO FIXO VS. ML)

Estratégia	Retorno Anual	Sharpe Ratio	Max DD
Carteira Nacional			
MSR Nac. (sem RF) - Fixo	30.5%	0.718	-45.4%
MSR Nac. (sem RF) - MLP	30.3%	0.718	-45.4%
MSR Nac. (sem RF) - LSTM	30.3%	0.718	-45.4%
MSR Nac. (RF≤30%) - Fixo	15.0%	0.521	-21.3%
MSR Nac. (RF≤30%) - MLP	14.5%	0.490	-21.4%
MSR Nac. (RF≤30%) - LSTM	14.5%	0.490	-21.4%
GMV Nac. (sem RF) - Fixo	13.4%	0.279	-32.8%
GMV Nac. (sem RF) - MLP	14.2%	0.331	-30.6%
GMV Nac. (sem RF) - LSTM	14.2%	0.331	-30.6%
GMV Nac. (RF≤30%) - Fixo	14.1%	0.446	-22.5%
GMV Nac. (RF≤30%) - MLP	13.6%	0.408	-22.0%
GMV Nac. (RF≤30%) - LSTM	13.6%	0.408	-22.0%
Carteira Internacional			
MSR Int. (sem RF) - Fixo	27.0%	1.005	-27.8%
MSR Int. (sem RF) - MLP	28.0%	1.037	-22.8%
MSR Int. (sem RF) - LSTM	28.0%	1.037	-22.8%
MSR Int. (RF≤30%) - Fixo	2.8%	0.073	-6.6%
MSR Int. (RF≤30%) - MLP	2.9%	0.108	-6.4%
MSR Int. (RF≤30%) - LSTM	2.9%	0.108	-6.4%
GMV Int. (sem RF) - Fixo	1.0%	-0.410	-8.7%
GMV Int. (sem RF) - MLP	0.8%	-0.462	-8.5%
GMV Int. (sem RF) - LSTM	0.8%	-0.462	-8.5%
GMV Int. (RF≤30%) - Fixo	2.5%	-0.018	-6.9%
GMV Int. (RF≤30%) - MLP	2.6%	0.018	-6.6%
GMV Int. (RF≤30%) - LSTM	2.6%	0.018	-6.6%

As alocações MSR são extremamente instáveis, concentradas e não-intuitivas. A estratégia MSR, baseada puramente na média histórica (μ) de uma janela de 126 dias, sofre do problema clássico de "estimation error". A otimização de Média-Variância é conhecida por ser um "maximizador de erros": ela trata o μ histórico (que é um estimador ruidoso e pobre do futuro) como um sinal perfeito.

A carteira nacional salta agressivamente entre alocações de quase 100% em um único ativo (figura 29). A estratégia MSR long-only simplesmente "caça"o ativo que teve o melhor desempenho recente na janela de lookback, resultando em períodos de 100% em um ativo, seguidos por rotação para 100% em outro.

Embora essa estratégia de "momentum"baseada em otimização tenha gerado um Sharpe Ratio positivo no backtest, ela expõe o risco fundamental da Média-Variância clássica: as alocações são impulsionadas por ruído estatístico (o μ histórico) e resultam em um turnover de carteira extremo e instável.

IV. CONCLUSÃO E TRABALHOS FUTUROS

Este trabalho construiu e validou dois componentes principais: (1) um modelo de Deep Learning (incluindo arquiteturas MLP e LSTM) capaz de prever regimes de mercado e (2) um sistema de *backtesting* para estratégias de otimização de portfólio MSR e GMV.

Tabela III
COMPARAÇÃO DE DESEMPENHO: R$ 100.000 INVESTIDOS (CARTEIRA NACIONAL)

Portfólio	Valor Final (R$)	Retorno Total (%)	Retorno Anual (%)
MSR (Fixo, RF≤30%)	322.447	222%	15.3%
MSR + MLP (RF≤30%)	309.399	209%	14.8%
MSR + LSTM (RF≤30%)	309.399	209%	14.8%
MSR (Fixo, sem RF)	838.929	739%	29.5%
MSR + MLP (sem RF)	820.350	720%	29.3%
MSR + LSTM (sem RF)	820.350	720%	29.3%
GMV (Fixo, RF≤30%)	299.745	200%	14.3%
GMV (Fixo, sem RF)	267.182	167%	12.7%
100% BOVA11	257.877	158%	12.2%
100% CDI (RF)	203.842	104%	9.0%

Tabela IV
COMPARAÇÃO DE DESEMPENHO: US$ 100.000 INVESTIDOS (CARTEIRA INTERNACIONAL)

Portfólio	Valor Final (US$)	Retorno Total (%)	Retorno Anual (%)
MSR (Fixo, sem RF)	473.073	373%	27.2%
MSR + MLP (sem RF)	495.291	395%	28.4%
MSR + LSTM (sem RF)	495.291	395%	28.4%
MSR (Fixo, RF≤30%)	119.446	19%	2.8%
MSR + MLP (RF≤30%)	120.093	20%	2.9%
MSR + LSTM (RF≤30%)	120.093	20%	2.9%
GMV (Fixo, RF≤30%)	117.466	18%	2.5%
GMV (Fixo, sem RF)	105.967	6%	0.9%
100% SPY	319.980	220%	19.7%
100% Treasury (RF)	118.165	18%	2.6%

Uma primeira integração foi realizada ao se utilizar o modelo de ML como um **gatilho de rebalanceamento tático**: a carteira é rebalanceada não apenas em intervalos fixos, mas também quando o modelo prevê uma mudança no regime de mercado.

No entanto, a principal ideia desta análise é que os sinais de regime do modelo de ML não foram, nesta fase, utilizados para **informar a alocação** do portfólio. A otimização MSR executada baseou-se em $\boldsymbol{\mu}$ histórico, que é sabidamente um estimador pobre.

O próximo passo, e principal contribuição futura deste trabalho, é a **integração completa** destes dois componentes. Propomos substituir o vetor de retornos esperados históricos ($\boldsymbol{\mu}$) na função de otimização MSR pelo vetor de sinais preditivos (ex: 1 para Alta, -1 para Baixa, 0 para Lateralização) gerados pelo nosso modelo de ML.

Isso transformará a estratégia de uma MSR passiva (baseada no passado) para uma MSR tática e ativa (baseada em previsões). O desafio metodológico desta integração será modificar a formulação de otimização para gerenciar sinais negativos, potencialmente removendo a restrição *long-only* para permitir operações de *short selling* nos ativos com previsão de ”Baixa”.

Adicionalmente, trabalhos futuros devem:

- Melhorar a acurácia do modelo de classificação através de arquiteturas mais sofisticadas (ex: **Transformers** ou modelos **LSTM com Atenção**).
- Implementar técnicas de *otimização robusta* para lidar com incerteza nos parâmetros.
- Avaliar o impacto de *custos de transação* no desempenho das estratégias.
- Expandir o universo de ativos e horizontes de previsão.

AGRADECIMENTOS

Agradeço ao Prof. Raul Ikeda Gomes da Silva pelas aulas de Algotrading e orientação durante o desenvolvimento deste trabalho.

REFERÊNCIAS

[1] H. M. Markowitz, *Portfolio Selection: Efficient Diversification of Investments*. John Wiley & Sons, 1959.

[2] R Core Team, *R: A Language and Environment for Statistical Computing*, R Foundation for Statistical Computing, Vienna, Austria, 2025. [Online]. Available: https://www.R-project.org/

[3] H. Wickham, M. Averick, J. Bryan, W. Chang, L. D. McGowan, R. François, G. Grolemund, A. Hayes, L. Henry, J. Hester, M. Kuhn, T. L. Pedersen, E. Miller, S. M. Bache, K. Müller, J. Ooms, D. Robinson, D. P. Seidel, V. Spinu, K. Takahashi, D. Vaughan, C. Wilke, K. Woo, and H. Yutani, “Welcome to the tidyverse,” *Journal of Open Source Software*, vol. 4, no. 43, p. 1686, 2019.

[4] D. Falbel and J. Luraschi, *torch: Tensors and Neural Networks with 'GPU' Acceleration*, 2025, r package version 0.16.1. [Online]. Available: https://CRAN.R-project.org/package=torch

[5] M. Dancho and D. Vaughan, *tidyquant: Tidy Quantitative Financial Analysis*, 2025, r package version 1.0.11. [Online]. Available: https://CRAN.R-project.org/package=tidyquant

[6] J. Ulrich, *TTR: Technical Trading Rules*, 2023, r package version 0.24.4. [Online]. Available: https://CRAN.R-project.org/package=TTR

[7] W. Freitas, *rbcb: R Interface to Brazilian Central Bank Web Services*, 2024, r package version 0.1.14. [Online]. Available: https://CRAN.R-project.org/package=rbcb

[8] A. Galanos, *rugarch: Univariate GARCH models.*, 2025, r package version 1.5-4.

[9] W. F. Sharpe, “Mutual fund performance,” *The Journal of Business*, vol. 39, no. 1, pp. 119–138, 1966.

[10] S. original by Berwin A. Turlach R port by Andreas Weingessel ¡Andreas.Weingessel@ci.tuwien.ac.at¿ Fortran contributions from Cleve Moler dpodi/LINPACK), *quadprog: Functions to Solve Quadratic Programming Problems*, 2019, r package version 1.5-8. [Online]. Available: https://CRAN.R-project.org/package=quadprog

APÊNDICE

A. Análise Exploratória de Dados

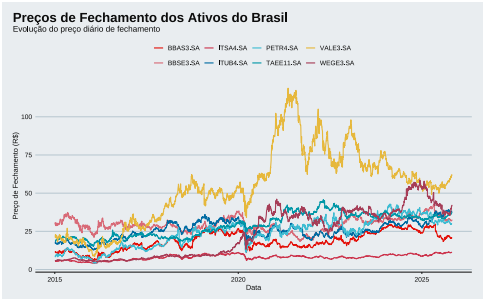


Figura 3. Preços de Fechamento dos Ativos do Brasil (2015-2025).

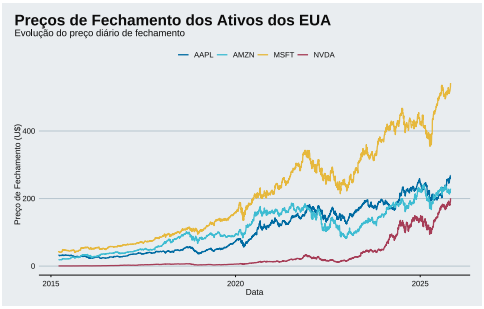


Figura 4. Preços de Fechamento dos Ativos dos EUA (2015-2025).

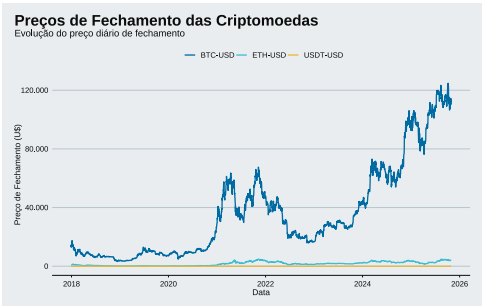


Figura 5. Preços de Fechamento das Criptomoedas (2015-2025).

A análise exploratória inicial dos dados é fundamental para compreender as características das séries temporais e justificar a modelagem. Os gráficos de preços de fechamento (Figuras 3 a 7) revelam, em primeiro lugar, um fato estilizado fundamental dos dados financeiros: a **não-estacionariedade**. Todas as séries de preços, com a exceção óbvia da *stablecoin* USDT-USD (Figura 5), exibem tendências estocásticas ou determinísticas claras, significando que suas médias e variâncias mudam ao longo do tempo. Esta observação valida a abordagem central do *script*, que foca na modelagem dos **retornos** (a primeira diferença dos preços), que são estacionários.

Em segundo lugar, os gráficos ilustram visualmente a **clusterização de volatilidade**. Quase todos os ativos exibem períodos de alta turbulência agrupados, seguidos por períodos

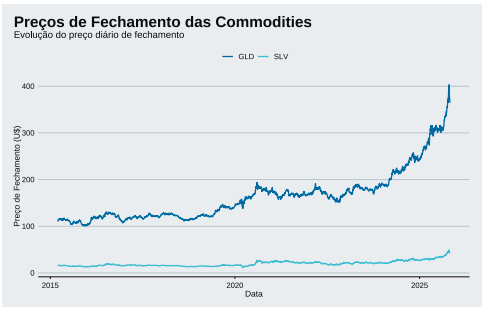


Figura 6. Preços de Fechamento das Commodities (2015-2025).

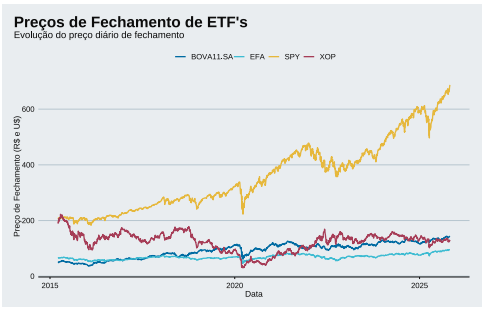


Figura 7. Preços de Fechamento dos ETFs (2015-2025).

de relativa calma. O exemplo mais evidente é o *crash* global no primeiro trimestre de 2020 (início da pandemia de COVID-19), visível em todas as classes de ativos, desde ações brasileiras (Figura 3) até os principais ETFs globais (Figura 7). Esta característica justifica a escolha de modelos de volatilidade condicional, como o eGARCH, utilizados na etapa de engenharia de *features*.

Em terceiro lugar, os gráficos fornecem forte evidência para a tese central deste *paper*: a existência de **regimes de mercado**. O período de 2015 a 2025 não é monolítico; ele se divide claramente em fases distintas:

1) Um período de tendência de alta (*Bull Market*) de 2016 a 2019.
2) O *crash* agudo e a recuperação em "V"de 2020.
3) Um *rally* de alta volatilidade e forte momentum (2020-2021).
4) Um mercado de baixa (*Bear Market*) ou lateralização (2022-2023), coincidindo com o aumento das taxas de juros globais.
5) Uma nova fase de tendência a partir de 2024.

A análise por classe de ativo revela dinâmicas distintas:

- **Ativos dos EUA (Figura 4):** Esta classe é dominada por ativos de "crescimento"(*growth*) e "momentum". A performance de NVDA, especialmente no período pós-2023, é um exemplo extremo de tendência exponencial, destacando-se de AAPL, AMZN e MSFT, que também mostram uma forte valorização de longo prazo.
- **Criptomoedas (Figura 5):** Representam a classe de ativos de maior volatilidade e comportamento especulativo. Os ciclos de *bull market* (como 2020-2021 e 2024) são quase

verticais, seguidos por ”crypto winters”(longos períodos de *drawdown*). A presença da USDT-USD, que aparece como uma linha reta próxima a 0 (devido à escala do eixo Y dominada por BTC e ETH), confirma sua natureza de *stablecoin*.

- **Ativos do Brasil (Figura 3):** O universo de ativos brasileiro é heterogêneo. PETR4.SA e VALE3.SA exibem comportamento cíclico, atrelado aos preços das *commodities* globais e ao risco local. O setor financeiro (representado por BBAS3.SA, ITUB4.SA, ITSA4.SA e BBSE3.SA) também demonstra um perfil cíclico, acompanhando os ciclos econômicos do país. Em contraste, WEGE3.SA demonstra uma tendência de crescimento mais consistente no longo prazo. TAEE11.SA, uma *utility* de energia, apresenta uma das menores volatilidades do grupo, alinhada ao seu perfil defensivo.
- **Commodities (Figura 6):** GLD (Ouro) e SLV (Prata) demonstram alta correlação entre si. Frequentemente vistas como ativos de ”porto seguro”ou *hedge* contra a inflação, suas séries de preços mostram longos períodos de lateralização (ex: 2015-2018) intercalados com tendências de alta (ex: 2019-2020).
- **ETFs (Figura 7):** Este gráfico sumariza as diferentes dinâmicas de mercado. SPY (S&P 500) e EFA (Mercados Desenvolvidos ex-EUA) mostram tendências de alta. BOVA11.SA (Ibovespa) reflete a natureza mais volátil do mercado brasileiro. XOP (Exploração de Petróleo e Gás), por sua vez, é o mais volátil, demonstrando o risco extremo do setor de energia, incluindo um colapso em 2020.

B. Análise de Correlação (GGally)

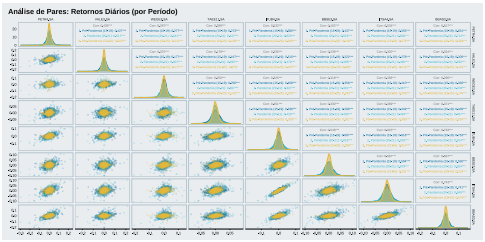


Figura 8. Análise de Pares (Correlação e Densidade) - Ativos do Brasil.

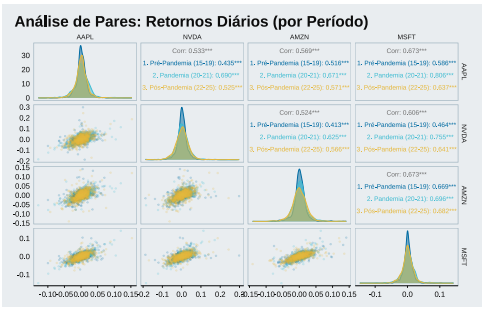


Figura 9. Análise de Pares (Correlação e Densidade) - Ativos dos EUA.

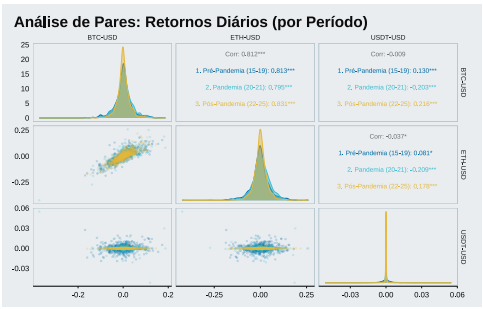


Figura 10. Análise de Pares (Correlação e Densidade) - Criptomoedas.

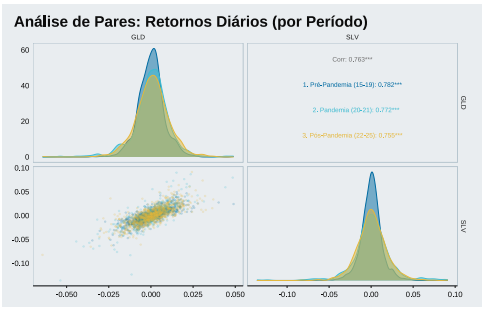


Figura 11. Análise de Pares (Correlação e Densidade) - Commodities.

A análise de correlação dos retornos diários, detalhada nas Figuras 8 a 12, é ainda mais central para a nossa tese. Estes gráficos `ggpairs` decompõem a correlação (ρ) em três regimes temporais: Pré-Pandemia (2015-19), Pandemia (2020-21) e Pós-Pandemia (2022-25). O objetivo é testar a estabilidade da matriz de covariância (Σ), um pilar fundamental da otimização de Média-Variância.

A principal conclusão é que a matriz de covariância é **altamente instável** e dependente do regime. Observamos um colapso quase universal da diversificação durante o período de crise (Pandemia), exatamente quando ela seria mais necessária.

- **ETFs Globais (Figura 12):** Este é o exemplo mais claro. A correlação entre o mercado brasileiro (BOVA11.SA) e o americano (SPY) salta de 0.473 (Pré-Pandemia) para 0.783 (Pandemia). O mesmo ocorre entre os EUA (SPY) e outros mercados desenvolvidos (EFA), que sobem de **0.832***** (Pré-Pandemia) para **0.910***** (Pandemia). Isso

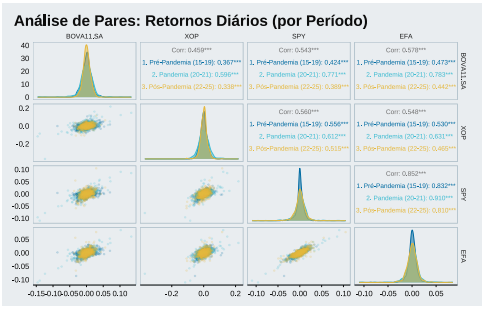


Figura 12. Análise de Pares (Correlação e Densidade) - ETF.

demonstra que, durante uma crise global, os benefícios da diversificação geográfica diminuem drasticamente, pois todos os mercados de risco se movem em conjunto.

- **Ativos dos EUA (Figura 9):** A diversificação setorial dentro dos EUA (neste caso, "Tech") também falha. A correlação entre Apple (AAPL) e Microsoft (MSFT) aumenta de 0.586 para 0.806 durante a pandemia. Os ativos de crescimento, vistos como distintos em tempos normais, tornam-se um bloco único de "risco beta"durante o *crash*.
- **Ativos do Brasil (Figura 8):** O mesmo padrão é observado localmente. A correlação entre as duas maiores *commodities* da bolsa, PETR4.SA e VALE3.SA, sobe de 0.426 para 0.617 no período de crise.
- **Criptomoedas (Figura 10):** Esta classe de ativos mostra uma dinâmica interna diferente. A correlação entre Bitcoin (BTC-USD) e Ethereum (ETH-USD) é *extremamente alta e estável* (sempre $\rho > 0.79$) em todos os regimes. Isso sugere que eles não são bons diversificadores um para o outro; eles pertencem à mesma classe de risco. Em contrapartida, a *stablecoin* (USDT-USD) tem correlação próxima de zero com ambos, confirmando seu papel como "porto seguro"ou ativo de caixa dentro do ecossistema cripto.
- **Commodities (Figura 11):** Ouro (GLD) e Prata (SLV) também mostram uma correlação alta e *muito estável* (sempre $\rho \approx 0.76$). Isso sugere que sua relação é mais estrutural (ambos são metais preciosos) do que dependente do regime de "risk-on/risk-off"que afeta as ações.

Esta instabilidade generalizada da matriz Σ é um problema conhecido como "estimation error"(erro de estimação). Confiar em uma matriz de covariância histórica de longo prazo para otimização (como fazem as estratégias *baseline* MSR e GMV) é problemático, pois ela não reflete as dinâmicas de correlação do regime atual. Isso justifica a busca por modelos de alocação táticos (como a integração do ML proposta) ou o uso de Otimização Robusta.

C. Performance de Retorno Cumulativo



Figura 13. Performance dos Ativos do Brasil (Retorno Cumulativo).

Finalmente, a análise da performance de retorno cumulativo (Figuras 13 a 17) ilustra a magnitude dos retornos e riscos (na forma de *drawdowns*) de uma estratégia passiva de *buy-and-hold*. Esta análise expõe diretamente o desafio de estimar o vetor de retornos esperados, $\boldsymbol{\mu}$.

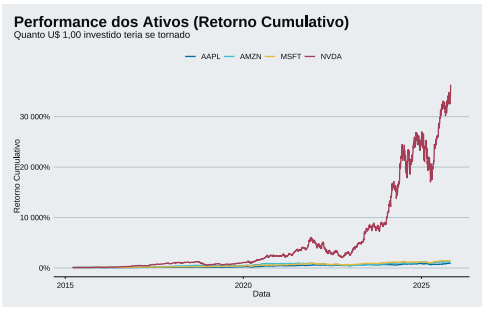


Figura 14. Performance dos Ativos dos EUA (Retorno Cumulativo).

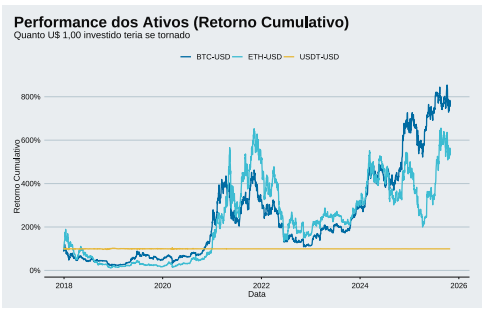


Figura 15. Performance das Criptomoedas (Retorno Cumulativo).

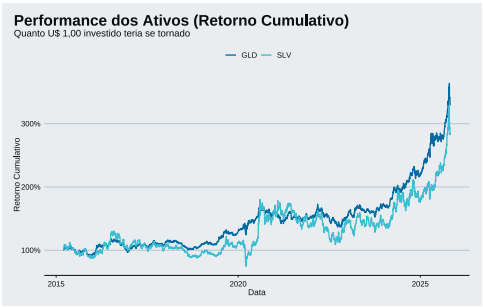


Figura 16. Performance das Commodities (Retorno Cumulativo).

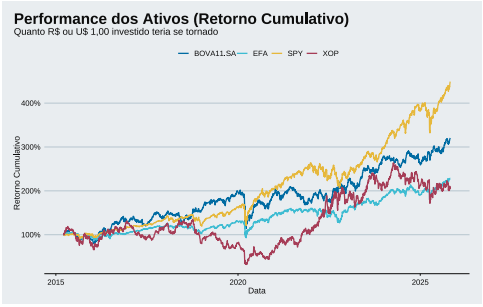


Figura 17. Performance dos ETF (Retorno Cumulativo).

A primeira observação é a **extrema assimetria positiva (positive skewness)** dos retornos de longo prazo. O desempenho do universo de ativos não é distribuído normalmente; ele é dominado por alguns poucos ”mega-vencedores”(*mega-winners*).

- **Ativos dos EUA (Figura 14):** Este é o exemplo mais extremo. O retorno cumulativo da NVDA (NVIDIA) eclipsa completamente os outros ativos, atingindo dezenas de milhares de pontos percentuais. Embora AAPL, MSFT e AMZN sejam, por si só, ativos de performance excepcional, eles parecem insignificantes em comparação.
- **Criptomoedas (Figura 15):** O mesmo padrão é observado, com ETH-USD e BTC-USD gerando retornos de centenas de pontos percentuais, enquanto a *stablecoin* (USDT-USD) corretamente retorna 0%.

Finalmente, a análise da performance de retorno cumulativo (Figuras 13 a 17) ilustra a magnitude dos retornos e riscos (na forma de *drawdowns*) de uma estratégia passiva de *buy-and-hold*. Esta análise expõe diretamente o desafio de estimar o vetor de retornos esperados, $\boldsymbol{\mu}$.

A primeira observação é a **extrema assimetria positiva (positive skewness)** dos retornos de longo prazo. O desempenho do universo de ativos não é distribuído normalmente; ele é dominado por alguns poucos ”mega-vencedores”(*mega-winners*).

- **Ativos dos EUA (Figura 14):** Este é o exemplo mais extremo. O retorno cumulativo da NVDA (NVIDIA) eclipsa completamente os outros ativos, atingindo dezenas de milhares de pontos percentuais. Embora AAPL, MSFT e AMZN sejam, por si só, ativos de performance excepcional, eles parecem insignificantes em comparação.
- **Criptomoedas (Figura 15):** O mesmo padrão é observado, com ETH-USD e BTC-USD gerando retornos de centenas de pontos percentuais, enquanto a *stablecoin* (USDT-USD) corretamente retorna 0%.

Esta assimetria torna a *média* histórica um estimador estatístico pobre para o $\boldsymbol{\mu}$ futuro. O retorno médio da NVDA foi massivo, mas ele foi entregue em ”saltos”(regimes de *momentum*) e não como um processo estável. A otimização de Média-Variância clássica, que foca apenas nos dois primeiros momentos (média e variância), falha em capturar essa característica de ”cauda-longa”(ou ”lotto ticket”), que é um tópico de estudo em portfólios de ordem superior (*high-order portfolios*).

A segunda observação é a **diferença fundamental nos perfis de risco-retorno**. Os ativos não são homogêneos:

- **Crescimento/Especulativo:** Ativos de tecnologia dos EUA (Figura 14) e Criptomoedas (Figura 15) oferecem retornos massivos, mas ao custo de *drawdowns* igualmente severos (ex: o ”crypto winter”visível em 2022-2023).
- **Valor/Cíclico:** Ativos brasileiros de crescimento como WEGE3.SA e cíclicos como PETR4.SA, VALE3.SA, e o setor financeiro (BBAS3.SA, ITUB4.SA, ITSA4.SA) (Figura 13), bem como o ETF XOP (Figura 17), mostram perfis de retorno variados, mas geralmente com maior volatilidade e *drawdowns* mais longos que os mercados desenvolvidos.
- **Porto Seguro/Defensivo:** As *Commodities* (Figura 16) e ativos de perfil mais defensivo do Brasil, como TAEE11.SA (utilities) e BBSE3.SA (seguros) (Figura 13), mostram retornos cumulativos mais baixos, mas também com *drawdowns* mais contidos.

Esta análise exploratória completa (preços, correlações e retornos) valida os dois principais desafios que este *paper* busca resolver: tanto o vetor de retornos esperados ($\boldsymbol{\mu}$) quanto a matriz de covariância (Σ) não são parâmetros estáveis. Eles são dinâmicos e dependentes do regime de mercado. Isso justifica a metodologia central proposta: o uso de *Machine Learning* para criar estimadores $\boldsymbol{\mu}$ adaptativos (baseados em previsões de regime) em vez de confiar em médias históricas estáticas.

D. Volatilidade dos Mercados (eGARCH Model)

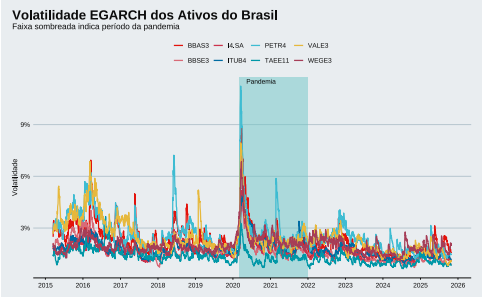


Figura 18. Volatilidade dos Ativos do Brasil.

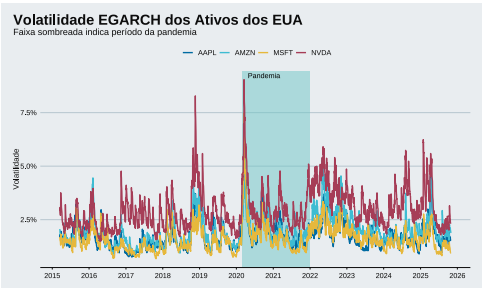


Figura 19. Volatilidade dos Ativos dos EUA.

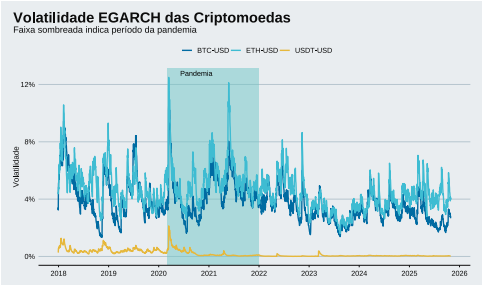


Figura 20. Volatilidade das Criptomoedas.

A análise da volatilidade condicional, modelada via eGARCH e apresentada nas Figuras 18 a 22, confirma visualmente fatos estilizados clássicos dos mercados financeiros.

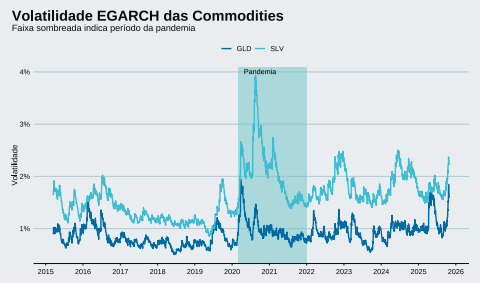


Figura 21. Volatilidade das Commodities.

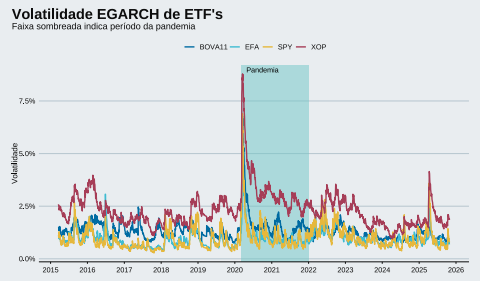


Figura 22. Volatilidade dos ETF.

A principal observação é a **clusterização da volatilidade**: períodos de baixa volatilidade são seguidos por períodos de alta volatilidade. O evento mais significativo no período de análise é o início da **pandemia em 2020**, que é claramente visível como um pico extremo de volatilidade em todas as classes de ativos, justificando sua designação como um ”regime”de mercado distinto.

A magnitude e o comportamento da volatilidade diferem significativamente entre as classes de ativos:

- **Criptomoedas (Figura 20):** Esta é, de longe, a classe de ativos mais volátil. BTC-USD e ETH-USD exibem volatilidade que ultrapassa 12% durante os picos da pandemia. Em contrapartida, a USDT-USD apresenta volatilidade próxima de zero, validando seu papel como *stablecoin*.
- **ETFs (Figura 22):** O ETF XOP (Petróleo e Gás) demonstra a maior volatilidade, com um pico em 2020 que ultrapassa 7.5%. O BOVA11 (Brasil) também é visivelmente mais volátil que seus pares de mercados desenvolvidos, SPY (EUA) e EFA.
- **Ativos dos EUA (Figura 19):** Mesmo dentro do setor de tecnologia, há diferenças claras. A NVDA se destaca como a mais volátil, com picos frequentes acima de 5% e 7.5%. MSFT e AAPL exibem níveis de volatilidade mais contidos.
- **Ativos do Brasil (Figura 18):** A volatilidade no mercado brasileiro é alta, com o pico da pandemia ultrapassando 9%. Ativos ligados a commodities, como PETR4 e VALE3, e ativos de crescimento como WEGE3, mostram picos mais elevados do que ativos de perfil mais defensivo.
- **Commodities (Figura 21):** A prata (SLV) é consistentemente mais volátil que o ouro (GLD). Durante o pico de 2020, a volatilidade do SLV chegou a ultrapassar 4%.

A inclusão desta volatilidade dinâmica como *feature* no modelo de Machine Learning é crucial, pois ela captura o ”estado”de estresse ou complacência do mercado, algo que médias móveis simples não conseguem fazer.

E. Modelo de Previsão de Regime

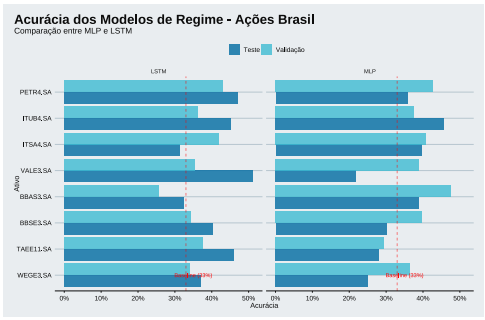


Figura 23. Acurácia dos Modelos de Regime - Ações Brasil.

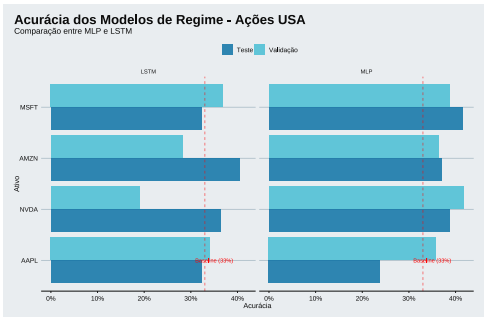


Figura 24. Acurácia dos Modelos de Regime - Ações EUA.

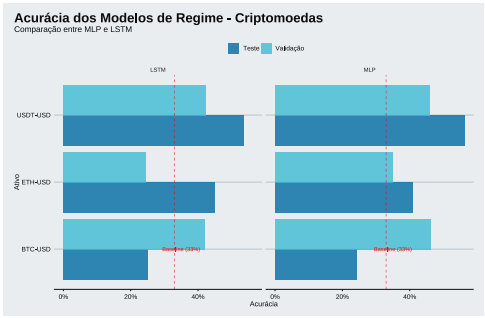


Figura 25. Acurácia dos Modelos de Regime - Criptomoedas

A análise da performance dos modelos de classificação de regime (Figuras 23 a 28) revela a eficácia das arquiteturas MLP e LSTM em superar o baseline aleatório (33%).

- **Performance por Ativo (Figura 28):** Observa-se que a acurácia varia significativamente. Por exemplo, em ’Ações Brasil’ (Figura 23), ambos os modelos demonstram forte capacidade preditiva para ativos como PETR4.SA, superando 40%. Em contraste, ’Commodities’ (Figura 26)

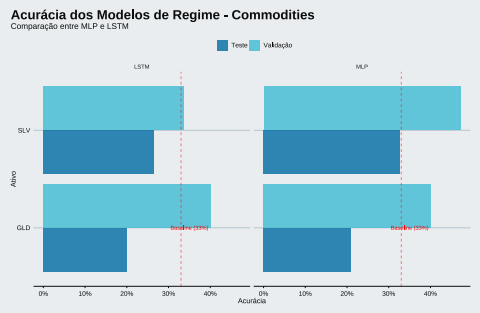


Figura 26. Acurácia dos Modelos de Regime - Commodities

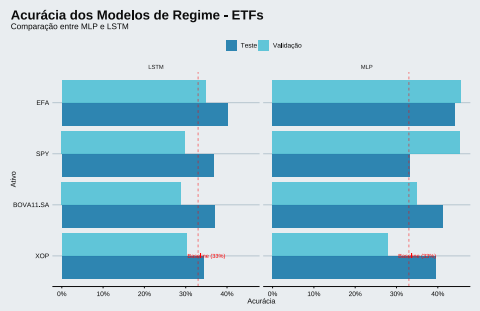


Figura 27. Acurácia dos Modelos de Regime - ETF

apresenta maior dificuldade, com acurácias de teste mais próximas do *baseline*.

- **Comparativo LSTM vs. MLP (Figura 28):** O sumário geral mostra que, em média (representado pela mediana no boxplot), ambas as arquiteturas superam o *baseline*. Nota-se uma dispersão maior na performance do MLP, enquanto o LSTM apresenta resultados mais consistentes em algumas classes. A classe 'Cripto' (Figura 25) mostra a maior mediana de acurácia, sugerindo que os regimes nesse mercado são mais facilmente identificáveis pelas *features* propostas.

F. Resultados do Backtest (Alocação de Portfólio)

A análise das curvas de patrimônio ilustra os resultados práticos da substituição do $\boldsymbol{\mu}$ histórico por sinais de *Machine Learning*.

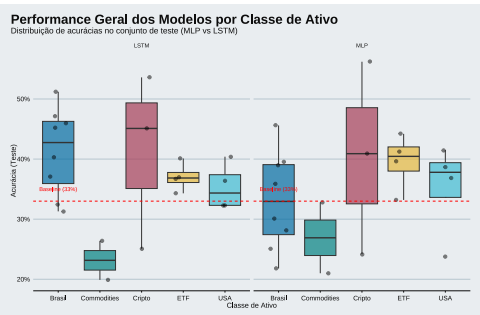


Figura 28. Acurácia dos Modelos de Regime - MLP vs LSTM

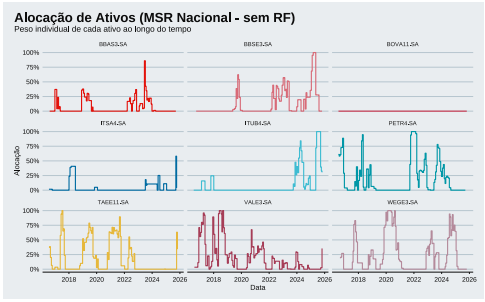


Figura 29. Alocação de Ativos (MSR Nacional) - Peso individual de cada ativo ao longo do tempo.

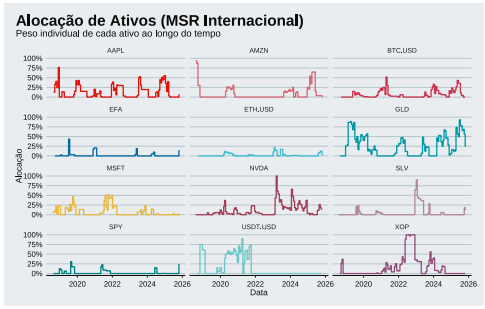


Figura 30. Alocação de Ativos (MSR Internacional) - Peso individual de cada ativo ao longo do tempo.



Figura 31. Desempenho Nacional ao longo do tempo.



Figura 32. Desempenho Internacional ao longo do tempo.

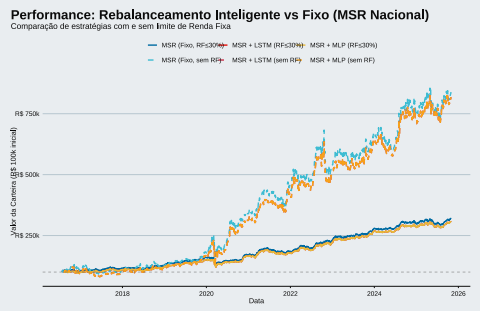


Figura 33. Desempenho Nacional Inteligente ao longo do tempo.

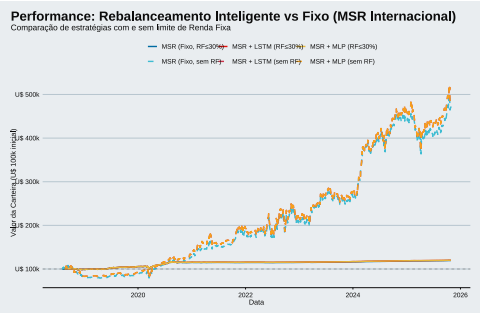


Figura 34. Desempenho Internacional Inteligente ao longo do tempo.

- **Comparação com Benchmarks (Figuras 31 e 32):** Ambas as carteiras (Nacional e Internacional) demonstram a clara superioridade das estratégias MSR (que buscam retorno) sobre as estratégias GMV (que buscam risco mínimo) em um período de tendência predominantemente de alta. No cenário internacional (Figura 32), as estratégias MSR baseadas em ”momentum”(Fixo, MLP e LSTM) conseguiram superar significativamente o benchmark 100% SPY, impulsionadas pela alocação em ”mega-winners”(como visto na Figura 30).
- **Performance Relativa (Figuras 33 e 34):** As subfiguras de ”zoom”permitem uma comparação direta entre as estratégias MSR.
  - No **Portfólio Nacional** (Figura 33), as estratégias ”sem RF”(linha pontilhada) superaram as com limite de RF, e o rebalanceamento inteligente (MSR + MLP) mostrou uma ligeira vantagem de performance sobre o MSR Fixo.
  - No **Portfólio Internacional** (Figura 34), os resultados são notavelmente similares. As estratégias de MSR Fixo, MSR+LSTM e MSR+MLP (sem RF) tiveram performances quase idênticas. Isso sugere que, em um mercado com tendências tão fortes (dominado por XOP, BTC e NVDA), o ”timing”do rebalanceamento (fixo vs. inteligente) foi menos importante do que o simples fato de estar alocado na classe de ativos correta.

A análise visual confirma que, embora a Média-Variância clássica sofra de instabilidade teórica, sua aplicação como um ”caçador de momentum”(MSR Fixo) se mostrou uma estratégia robusta. A introdução de rebalanceamento inteligente (MLP/LSTM) não prejudicou a performance e, no caso nacional, ofereceu uma melhoria marginal, validando sua viabilidade como um substituto mais estável para o $\boldsymbol{\mu}$ histórico.