Insper

Ciências Econômicas

Predição Conformal Aplicada à Estimação do Efeito de Tratamento Individual (ITE)

Hicham Munir Tayfour

São Paulo
2026

Hicham Munir Tayfour

Predição Conformal Aplicada à Estimação do Efeito de Tratamento Individual (ITE)

TCC apresentado ao Curso de Graduação em Ciências Econômicas do Insper como requisito parcial para a obtenção do título de Bacharel em Economia.

Insper

Orientador: Paulo Cilas Marques Filho

São Paulo

2026

Tayfour, Hicham Munir
Predição Conformal Aplicada à Estimação do Efeito de Tratamento Individual (ITE) / Hicham Munir Tayfour. – São Paulo, 2026.
101 f.

Trabalho de Conclusão de Curso – Insper, 2026.
Orientador: Paulo Cilas Marques Filho

1. Predição Conformal. 2. Deslocamento de Covariadas. 3. Efeito de Tratamento Individual. 4. Inferência Causal. 5. Quantificação de Incerteza. I. Tayfour, Hicham Munir. II. Predição Conformal Aplicada à Estimação do Efeito de Tratamento Individual (ITE)

Hicham Munir Tayfour

Predição Conformal Aplicada à Estimação do Efeito de Tratamento Individual (ITE)

TCC apresentado ao Curso de Graduação em Ciências Econômicas do Insper como requisito parcial para a obtenção do título de Bacharel em Economia.

Paulo Cilas Marques Filho
Orientador

Hugo Valesini Gegembauer
Convidado 1

São Paulo

2026

O principal objetivo da educação
é criar pessoas capazes de fazer
coisas novas e não simplesmente repetir
o que as outras gerações fizeram.

AGRADECIMENTOS

Dedico este trabalho a todos que, direta ou indiretamente, contribuíram para a sua realização. Expresso minha profunda gratidão ao Prof. Paulo Cilas Marques Filho, cuja orientação foi fundamental não apenas para a conclusão deste projeto, mas também para o meu amadurecimento intelectual, ensinando-me a caminhar com autonomia. À Profa. Isabela Brandão Furtado e ao Prof. Paulo C.M.F. , agradeço pela confiança e pelo papel essencial em minha trajetória acadêmica no Insper. Ao Prof. Hugo Valesini Gegembauer, deixo um agradecimento especial por ter guiado meus primeiros passos na vida acadêmica e por compor a banca avaliadora deste trabalho. Também agradeço ao Insper e aos demais professores, que contribuíram para a minha formação.

Aos amigos que a faculdade me deu, Beatriz, Júlia, Enrico, Enzo e Fabrízio, agradeço pela amizade, paciência, apoio e imensa solidariedade desde que nos conhecemos até esta última fase. Um agradecimento especial à turma do cursinho para a ANPEC, que transformou as entregas do TCC II em algo mais leve e divertido, contribuindo direta e indiretamente para este trabalho. Agradeço também aos meus tios Mageda, Najla e Paulo, que me receberam de braços abertos para que eu pudesse estar onde estou hoje; ao meu primo Munir, que me deu coragem para seguir esse caminho; às minhas irmãs Najwa e Mariam, que sempre estiveram comigo nessa jornada, me apoiando, consolando e incentivando; e aos meus demais familiares, pelo apoio, incentivo e preocupação.

Ao meu melhor amigo Pedro, alguém que considero como um irmão, agradeço por uma amizade que resiste aos longos intervalos de silêncio e que, a cada conversa, parece nunca ter sido interrompida. Por fim, dedico e agradeço imensamente este trabalho aos meus pais, Naheda e Munir, que aceitaram e abraçaram meu sonho, apoiaram minhas escolhas, cuidaram de mim nos dias mais difíceis e me acompanharam até este momento. Este trabalho é para vocês.

“ A economia é como o clima:
todo mundo fala sobre ela,
mas ninguém faz nada a respeito.
Robert Orben “

RESUMO

A estimação do Efeito de Tratamento Individual (ITE) é central na inferência causal, mas algoritmos de aprendizado de máquina falham em fornecer quantificação de incerteza rigorosa em amostras finitas. Para transpor essa lacuna, aplicamos a Predição Conformal Ponderada, à inferência contrafactual. A metodologia lida com o Deslocamento de Covariadas reponderando os escores de calibração. Confrontamos modelos heurísticos (florestas aleatórias, florestas quantílicas e árvores bayesianas) em simulações sob forte confusão e nas bases reais STAR e HI. Os resultados atestam o postulado: a calibração reponderada preserva a validade marginal exata do ITE. Contudo, diagnosticamos que, sob violação de positividade, a garantia inflexível de cobertura induz rigorosamente intervalos triviais (infinitos). Isso evidencia o *trade-off* estrutural entre validade matemática absoluta e utilidade prática em regiões desprovidas de suporte comum.

Palavras-chave: Predição Conformal; Efeito de Tratamento Individual (ITE); Inferência Causal; Deslocamento de Covariadas; Quantificação de Incerteza.

ABSTRACT

Estimating the Individual Treatment Effect (ITE) is central to causal inference, yet machine learning algorithms fail to provide rigorous finite-sample uncertainty quantification. To bridge this gap, we apply Weighted Conformal Prediction (WCP), via *Split Conformal* and Conformalized Quantile Regression (CQR), to counterfactual inference. The methodology neutralizes covariate shift by reweighting the calibration scores. We confront heuristic models (quantile forests and Bayesian trees) in simulations under strong confounding and on the STAR and HI empirical datasets. Results attest to the *distribution-free* postulate: reweighted calibration preserves the exact marginal validity of the ITE. Crucially, we diagnose that under positivity violations (*poor overlap*), the inflexible coverage guarantee rigorously induces trivial (infinite) intervals. This highlights the structural trade-off between absolute mathematical validity and practical utility in regions devoid of common support.

Keywords: Conformal Prediction; Individual Treatment Effect (ITE); Causal Inference; Covariate Shift; Uncertainty Quantification.

LISTA DE ILUSTRAÇÕES

Figura 1 – Intervalos conformais para o Efeito Individual de Tratamento (ITE), com cobertura empírica almejada de 90%. A figura compara o comportamento estrutural dos algoritmos preditivos em uma amostra de 30 indivíduos para cada base empírica. 39
Figura 2 – Processo Gerador HMC (DGP 1), em regime de densidade $n_{\text{cal}} = 5000$: Diagnóstico visual do impacto do viés de seleção sobre os intervalos de predição do ITE. 57
Figura 3 – Processo Gerador HMC Complexo (DGP 2), em regime de densidade $n_{\text{cal}} = 5000$: Diagnóstico visual do impacto do viés de seleção sobre os intervalos de predição do ITE. 58
Figura 4 – Processo Gerador Hahn (DGP 3), em regime de densidade $n_{\text{cal}} = 5000$: Diagnóstico visual do impacto do viés de seleção sobre os intervalos de predição do ITE. 59
Figura 5 – Processo Gerador Lei Complexo (DGP 4), em regime de densidade $n_{\text{cal}} = 5000$: Diagnóstico visual do impacto do viés de seleção sobre os intervalos de predição do ITE. 60

LISTA DE TABELAS

Tabela 1 Matriz de Estresse dos DGPs 28
Tabela 2 Resultados do Experimento DGP 1 (HMC) 32
Tabela 3 Resultados do Experimento DGP 2 (HMC Complexo) 33
Tabela 4 Resultados do Experimento DGP 3 (Hahn) 34
Tabela 5 Resultados do Experimento DGP 4 (Lei Complexo) 35
Tabela 6 Resultados do Experimento 1 (HI) 37
Tabela 7 Resultados do Experimento 2 (STAR) 38

LISTA DE ABREVIATURAS E SIGLAS

ATE	Efeito Médio de Tratamento (*Average Treatment Effect*)
BART	Árvores Bayesianas Aditivas de Regressão (*Bayesian Additive Regression Trees*)
CATE	Efeito Médio Condicional de Tratamento (*Conditional Average Treatment Effect*)
CDF	Função de Distribuição Acumulada (*Cumulative Distribution Function*)
CP	Predição Conformal (*Conformal Prediction*)
CQR	Regressão Quantílica Conformalizada (*Conformalized Quantile Regression*)
DGP	Processo Gerador de Dados (*Data Generating Process*)
HI	Base *Health Insurance and Hours Worked By Wives*
IPS	Escore de Propensão Inverso (*Inverse Propensity Score*)
ITE	Efeito de Tratamento Individual (*Individual Treatment Effect*)
MVP	Propriedade de Validade Marginal (*Marginal Validity Property*)
PS	Escore de Propensão (*Propensity Score*)
QRF	Floresta de Regressão Quantílica (*Quantile Regression Forest*)
RF	Floresta Aleatória (*Random Forest*)
STAR	Experimento *Student/Teacher Achievement Ratio*
SUTVA	Suposição de Valor de Tratamento Unitário Estável (*Stable Unit Treatment Value Assumption*)
WCP	Predição Conformal Ponderada (*Weighted Conformal Prediction*)

LISTA DE SÍMBOLOS

α	Nível de significância.
$1-\alpha$	Nível nominal de cobertura.
$\mathbb{P}(\cdot)$	Medida de probabilidade.
$\perp\!\!\!\perp$	Independência condicional.
$\mathbf{1}\{\cdot\}$	Função indicadora.
∞	Limite infinito, usado para intervalos triviais ou degenerados.
$\Phi(\cdot)$	Função de distribuição acumulada da Normal padrão.
$\mathcal{N}(\cdot,\cdot)$	Distribuição Normal.
n	Tamanho amostral genérico.
n_{trn}	Tamanho da amostra de treinamento nas simulações.
n_{cal}	Tamanho da amostra de calibração.
n_{cal0}	Número de unidades de controle na amostra de calibração.
n_{tst}	Tamanho da amostra de teste nas simulações.
D_{train}	Subconjunto de treinamento.
D_{cal}	Subconjunto de calibração.
D_{test}	Subconjunto de teste.
D^0_{cal}	Subconjunto de calibração com unidades de controle ($T=0$).
D^1_{test}	Subconjunto de teste com unidades tratadas ($T=1$).
X_i	Vetor de covariadas da unidade i.
T_i	Indicador binário de tratamento da unidade i.
Y_i	Desfecho observado da unidade i.
Y_i^{obs}	Desfecho factual observado.
$Y_i(1)$	Resultado potencial sob tratamento.
$Y_i(0)$	Resultado potencial sob controle.

τ_i	Efeito de tratamento individual verdadeiro da unidade i.
$e(x)$	Escore de propensão, $\mathbb{P}(T = 1 \mid X = x)$.
$\hat{e}(x)$	Escore de propensão estimado.
$e^{\text{true}}(x)$	Escore de propensão verdadeiro, quando conhecido nas simulações.
$\hat{\mu}(X)$	Modelo preditivo ajustado.
$\hat{\mu}_0(X)$	Modelo preditivo ajustado no grupo de controle para estimar $Y(0)$.
R_i	Escore de não-conformidade da observação i.
$R_{(i)}$	Escore de não-conformidade ordenado.
$\mathbf{R}_{\text{ext}}$	Vetor de escores ordenados acrescido de ∞.
$\hat{q}$	Quantil empírico dos escores de não-conformidade.
$\hat{q}_{\alpha/2}(X)$	Estimador do quantil condicional inferior.
$\hat{q}_{1-\alpha/2}(X)$	Estimador do quantil condicional superior.
$\hat{C}(X_{n+1})$	Intervalo de predição conformal para uma nova unidade.
$\hat{C}^{(k)}_{\text{ITE},j}$	Intervalo conformal estimado para o ITE da unidade j sob a especificação k do PS.
$L^{(k)}_{Y(0),j}, U^{(k)}_{Y(0),j}$	Limites inferior e superior do intervalo contrafactual para $Y(0)$.
$\hat{r}_j$	Erro conformal ajustado para a unidade alvo j.
$\mathcal{A}_\mu$	Algoritmo usado para ajustar o modelo de desfecho.
$\mathcal{A}_e$	Algoritmo usado para ajustar o modelo de escore de propensão.
$\mathcal{S}$	Função genérica de escore de não-conformidade.
μ_i	Superfície prognóstica ou resposta média estrutural da unidade i.
σ	Escala ou desvio-padrão do ruído nos DGPs.
ε_i	Termo de erro aleatório.
ρ	Parâmetro de correlação no DGP Lei Complexo.
$\mathbf{\Sigma}$	Matriz de covariância das covariadas simuladas.
$F_{\text{Beta}}(\cdot)$	Função de distribuição acumulada da distribuição Beta.
$P_{\text{cal}}(X)$	Distribuição das covariadas na amostra de calibração.
$P_{\text{train}}(X)$	Distribuição das covariadas na população de treino.

$P_{\text{test}}(X)$	Distribuição das covariadas na população alvo de teste.
$w(x)$	Peso de importância ou razão de verossimilhança.
$w_{\text{cal},i}^{(k)}$	Peso da unidade de calibração i sob a especificação k do PS.
$w_{\text{test},j}^{(k)}$	Peso da unidade de teste j sob a especificação k do PS.
thr_j	Limiar ponderado usado para selecionar o erro conformal da unidade j.
$C_m(n_{\text{cal}}, \alpha)$	Cobertura empírica em um lote de teste de tamanho m.
$\text{Cob}^{(k)}$	Cobertura empírica sob a especificação k do PS.
$\text{Triv}^{(k)}$	Proporção de intervalos infinitos sob a especificação k do PS.
$\text{Larg}^{(k)}$	Largura mediana dos intervalos sob a especificação k do PS.

SUMÁRIO

1 INTRODUÇÃO 17
1.1 O Problema Fundamental e a Heterogeneidade de Tratamento 17
1.2 A Ilusão da Pontualidade: Limitações do Aprendizado de Máquina 17
1.3 A Garantia *Distribution-Free*: Predição Conformal 18
1.4 Contribuição e Estrutura da Tese 18
1.4.1 Principais Achados 19
1.4.2 Estrutura da Tese 19

2 FUNDAMENTAÇÃO TEÓRICA 21
2.1 O Arcabouço de Resultados Potenciais e o Desafio Contrafactual 21
2.2 Permutabilidade e a Garantia de Vovk & Gammerman 22
2.3 Split Conformal e a Distribuição Universal da Cobertura . . 22
2.3.1 A Geometria Beta-Binomial da Cobertura Empírica 23
2.4 Quebra de Paradigma: Transição para o Deslocamento de Covariadas 23

3 DESLOCAMENTO DE COVARIADAS (*COVARIATE SHIFT*) E INFERÊNCIA CAUSAL 24
3.1 A Quebra de Permutabilidade pelo Deslocamento de Covariadas 24
3.2 Inferência Causal como Predição sob Deslocamento de Covariadas 25
3.3 A Solução Teórica: Predição Conformal Ponderada (WCP) . 25
3.3.1 O Escore de Propensão e a Razão de Verossimilhança 25
3.3.2 O Rigor Frente à Falta de Sobreposição (*Poor Overlap*) 26

4 RESULTADOS EMPÍRICOS: SIMULAÇÕES E DADOS REAIS 27
4.1 Arquitetura Experimental e Engenharia de Avaliação 27
4.1.1 A Mecânica dos Processos Geradores de Dados (DGPs) 27

4.1.2 O Protocolo Conformal: WCP como Camada de Calibração Contrafactual . . . 28
4.1.3 Sistema de Métricas . . . 29
4.1.4 Camada de Inferência: Modelos Regressivos . . . 30
4.2 Ensaios Sintéticos: Validação Universal sob Deslocamento de Covariadas . . . 31
4.3 Transição para o Observacional: Aplicações em Dados Reais 36
4.3.1 Experimento 1: Estresse Absoluto (HI Health Insurance) . . . 37
4.3.2 Experimento 2: Randomização Controlada (STAR Tennessee) . . . 37
4.3.3 Síntese Comparativa Empírica e Visuais de Contrafactuais . . . 38

5 DISCUSSÃO E CONCLUSÃO . . . 40
5.1 Interpretação dos Resultados e Papel da Sobreposição . . . 40
5.2 Implicações para Aplicações Empíricas . . . 41
5.3 Limitações . . . 42
5.4 Conclusão . . . 42

REFERÊNCIAS . . . 44

APÊNDICES 48

APÊNDICE A – METODOLOGIA EXPERIMENTAL E RESULTADOS VISUAIS . . . 49
A.1 Arquitetura e Parametrização da Simulação . . . 49
A.2 Formalização Algorítmica: Pseudocódigos . . . 50
A.3 Portfólio Visual de Incerteza Contrafactual . . . 56

APÊNDICE B – CÓDIGOS EM R . . . 61
B.1 Configurações gráficas compartilhadas . . . 61
B.2 Propensity Score conhecido . . . 66
B.3 Propensity Score desconhecido . . . 76
B.4 Aplicação com dados do projeto STAR . . . 86
B.5 Aplicação com dados de seguro de saúde . . . 94

1 INTRODUÇÃO

1.1 O PROBLEMA FUNDAMENTAL E A HETEROGENEIDADE DE TRATAMENTO

A estimação de efeitos causais e a compreensão de sua heterogeneidade formam o alicerce da tomada de decisão baseada em dados em áreas críticas, como políticas públicas, medicina personalizada e economia aplicada. Tradicionalmente, a literatura foca no Efeito Médio de Tratamento (ATE). No entanto, o ATE frequentemente mascara variações relevantes no nível do indivíduo; uma intervenção benéfica na média pode ser ineficaz ou até prejudicial para subgrupos específicos. Para reduzir esse risco, a inferência causal moderna busca estimar o Efeito de Tratamento Individual (ITE). Sob o olhar do modelo de resultados potenciais de Rubin (1974) e Neyman (1923), estimar o ITE exige superar o problema fundamental da inferência causal: a impossibilidade de observar simultaneamente os resultados factuais e contrafactuais para a mesma unidade (Lei; Candès, 2021).

1.2 A ILUSÃO DA PONTUALIDADE: LIMITAÇÕES DO APRENDIZADO DE MÁQUINA

Para estimar o contrafactual e, consequentemente, o Efeito Médio Condicional de Tratamento (CATE), a literatura recente adotou em peso modelos flexíveis de aprendizado de máquina (*machine learning*). Apesar dos métodos baseados em árvores e florestas terem uma capacidade preditiva e adaptação a não linearidades, eles sofrem de uma limitação estatística relevante: a ausência de quantificação de incerteza rigorosa em amostras finitas. Na prática, previsões pontuais geradas por algoritmos clássicos podem transmitir uma falsa sensação de precisão. Decisões de alto risco não podem depender apenas de estimativas pontuais ou de intervalos de confiança assintóticos que falham quando as premissas distributivas do modelo usado não se verificam na realidade empírica.

1.3 A GARANTIA *DISTRIBUTION-FREE*: PREDIÇÃO CONFORMAL

Para eliminar essa lacuna teórica, a Predição Conformal (*Conformal Prediction*, CP), cujos fundamentos matemáticos foram estabelecidos por Vovk, Gammerman e Shafer (2005), surge como a ferramenta metodológica ideal. Na sua versão mais eficiente, a Predição Conformal Dividida (*Split Conformal Prediction*), a metodologia permite construir conjuntos de predição com a chamada Propriedade de Validade Marginal (*Marginal Validity Property*, MVP). A força desta estrutura está no fato de ser estritamente livre de distribuição (*distribution-free*): a garantia de que o intervalo conterá a verdadeira resposta não observada com probabilidade nominal $1-\alpha$ depende única e exclusivamente do tamanho da amostra de calibração (n_{cal}) e da permutabilidade (*exchangeability*) da sequência de dados empíricos, sendo o processo completamente agnóstico à exatidão teórica do algoritmo preditivo usado.

O salto em direção à inferência causal ocorre ao tratarmos a estimação do ITE não como um problema clássico, mas como uma robusta tarefa de predição de contrafactuais não observados, operando rigorosamente sob o arcabouço desenvolvido por Lei e Candès (2021).

1.4 CONTRIBUIÇÃO E ESTRUTURA DA TESE

O foco deste trabalho é implementar, sistematizar e avaliar a Predição Conformal Ponderada (*Weighted Conformal Prediction*, WCP), operacionalizada na forma dividida (Split Conformal) e aplicada a um conjunto diversificado de modelos preditivos base, englobando regressão quantílica, métodos de regularização bayesiana e estimadores de média condicional. Em dados observacionais, a premissa fundamental de permutabilidade conformal é violada devido ao viés de seleção: as distribuições de covariadas divergem entre os grupos de tratados e controles, caracterizando um forte deslocamento de covariadas. Para restaurar a validade marginal em amostras finitas neste cenário adverso, o trabalho usa o Escore de Propensão (*Propensity Score*, PS) para reponderar a função de distribuição empírica dos escores de calibração, adaptando a incerteza à assimetria imposta pela mudança de distribuição (Lei; Candès, 2021; Tibshirani et al., 2019).

A arquitetura experimental desta pesquisa testa os limites de quebra do WCP em duas frentes de avaliação. A primeira envolve simulações robustas através de Processos Geradores de Dados (DGPs). Destacam-se o DGP desenhado com forte não linearidade e os DGPs inspirados na literatura de BART causal (Carvalho, 2019a; Hahn; Murray; Carvalho, 2020), pensados especificamente para induzir severa falta de sobreposição (*poor overlap*) no espaço de covariadas. Por meio desses cenários controlados, avaliamos a universalidade da distribuição de cobertura e investigamos sob quais condições de confusão os algoritmos com regularização bayesiana implícita, como o *Bayesian Additive Regression Trees* (BART), entregam intervalos contrafactuais mais estreitos e eficientes que os métodos puramente embasados em florestas de quantis.

A segunda frente aplica o método empírico a dados observacionais amplamente estudados: o ensaio randomizado STAR (*Student/Teacher Achievement Ratio*) do Tennessee, e o clássico estudo observacional HI (*Health Insurance and Hours Worked By Wives*).

1.4.1 PRINCIPAIS ACHADOS

Os resultados empíricos expõem o funcionamento da teoria de Vovk sob perturbação extrema. Na base observacional HI, evidenciamos que a variância explosiva da razão de verossimilhança provocada por valores de propensão muito próximos de 0 ou 1 faz com que um único ponto estatístico domine a distribuição empírica de calibração. Nestas circunstâncias, para manter a garantia de cobertura *distribution-free*, o algoritmo conformal penaliza a incerteza e faz com que a largura da predição divirja para o infinito. Este fenômeno revela uma limitação prática importante: frente a uma severa violação de sobreposição (*poor overlap*), a incerteza teórica sobre o contrafactual é tão alta que o intervalo deixa de ser útil para decisões direcionais (Lei; Candès, 2021).

1.4.2 ESTRUTURA DA TESE

Este trabalho está organizado através da seguinte estrutura: o Capítulo 2 revisa a álgebra e as garantias matemáticas fundamentais da Predição Conformal clássica, demonstrando o papel da permutabilidade sobre a amostra de calibração; o Capítulo 3 expande a análise para cenários submetidos a deslocamento de covariadas, detalhando as equações de reponderação de verossimilhança; o Capítulo 4 apresenta a inferência contrafactual com

a bateria de simulações em DGPs e aplicações reais; por fim, o Capítulo 5 discute as limitações práticas e sintetiza as conclusões do trabalho.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, estabelecemos os alicerces matemáticos que sustentam a arquitetura metodológica do trabalho. A progressão teórica parte da formalização da inferência causal como um problema de predição de contrafactuais, passa pela validade *distribution-free* da Predição Conformal clássica e pela mecânica da Predição Conformal Dividida em amostras finitas, e culmina na discussão das condições sob as quais essas garantias precisam ser ajustadas diante de deslocamento de covariadas. O foco, portanto, recai sobre a construção de garantias de incerteza para estimativas contrafactuais, sem restringir a fundamentação do trabalho a uma família específica de modelos preditivos.

2.1 O ARCABOUÇO DE RESULTADOS POTENCIAIS E O DESAFIO CONTRAFACTUAL

A avaliação de políticas e o estudo de heterogeneidade de efeitos exigem uma linguagem estritamente formal. Adotamos a estrutura de resultados potenciais de Neyman (1923) e Rubin (1974). Para uma unidade i, definimos a existência de dois resultados potenciais latentes: $Y_i(1)$, caso a unidade seja submetida à intervenção, e $Y_i(0)$, caso pertença ao grupo de controle. O Efeito de Tratamento Individual (ITE) é definido como:

$$\tau_i = Y_i(1) - Y_i(0) \tag{2.1}$$

A complexidade fundamental da inferência causal decorre do fato de que é impossível observar simultaneamente $Y_i(1)$ e $Y_i(0)$ para a mesma unidade empírica. Observamos exclusivamente o desfecho factual, vinculado ao tratamento efetivamente recebido $T_i \in \{0, 1\}$, tal que $Y_i^{obs} = Y_i(T_i)$. O desfecho não observado, $Y_i(1 - T_i)$, constitui o contrafactual.

Conforme apontado por Carvalho (2019a), estimar o ITE requer isolar o verdadeiro efeito do tratamento do viés de seleção induzido por variáveis de confusão (fatores que afetam tanto T quanto Y). Sob as suposições clássicas de Valor de Tratamento Estável (SUTVA), Sobreposição Estrita ($0 < \mathbb{P}(T_i = 1 \mid X_i) < 1$) e Ignorabilidade Forte

$((Y_i(0), Y_i(1)) \perp\!\!\!\perp T_i \mid X_i)$, a estimação do ITE converte-se rigorosamente em uma tarefa de predição não-supervisionada de dados faltantes.

2.2 PERMUTABILIDADE E A GARANTIA DE VOVK & GAMMERMAN

A predição pontual de contrafactuais por algoritmos modernos é insuficiente sem garantias de incerteza. Para isso, recorremos à Predição Conformal (CP), cuja validade matemática repousa sobre a suposição de **permutabilidade** (*exchangeability*) formulada por Vovk, Gammerman e Shafer (2005). Formalmente, uma sequência de variáveis aleatórias $Z_1, \ldots, Z_n, Z_{n+1}$ é permutável se a sua distribuição de probabilidade conjunta for estritamente invariante sob qualquer permutação de seus índices. Sendo uma condição mais fraca e abrangente que a premissa de independência e idêntica distribuição (i.i.d.), a permutabilidade assegura que o posto de um novo dado estatístico seja uniformemente distribuído na amostra.

O motor da CP é o **escore de não-conformidade** R_i, uma função que mensura o grau de atipicidade de uma observação em relação ao modelo preditivo subjacente $\hat{\mu}$ ($R_i = |Y_i - \hat{\mu}(X_i)|$). A propriedade fundamental extraída dessa simetria é a **validade marginal em amostras finitas** (*Marginal Validity Property* - MVP):

$$\mathbb{P}\{Y_{n+1} \in \hat{C}(X_{n+1})\} \geq 1 - \alpha \tag{2.2}$$

Essa garantia de cobertura é *distribution-free*: ela independe de premissas assintóticas, da verdadeira distribuição geradora dos dados, e não exige que a heurística preditiva $\hat{\mu}$ esteja corretamente especificada.

2.3 SPLIT CONFORMAL E A DISTRIBUIÇÃO UNIVERSAL DA COBERTURA

Dada a ineficiência computacional da abordagem conformal completa (*Full Conformal*), esta pesquisa fundamenta-se no algoritmo de Predição Conformal Dividida (*Split Conformal Prediction*). O procedimento divide os dados aleatoriamente em um conjunto de treino (para ajustar $\hat{\mu}$) e um conjunto de calibração de tamanho n_{cal}.

Para uma taxa de erro nominal α, ordenamos os escores de calibração. A permutabilidade garante que o novo escore de teste R_{n+1} tenha a mesma probabilidade de cair em qualquer

um dos $n_{cal} + 1$ intervalos criados por esses escores. O limite de inclusão é determinado pelo quantil empírico exato:

$$\hat{q} = \text{Quantil}\left(\lceil (1-\alpha)(n_{cal}+1) \rceil; \{R_i\}_{i \in \mathcal{I}_{cal}}\right) \tag{2.3}$$

2.3.1 A GEOMETRIA BETA-BINOMIAL DA COBERTURA EMPÍRICA

A garantia marginal de $1 - \alpha$, embora robusta, refere-se à expectativa sobre múltiplas amostras. Para a prática causal, é necessário mapear a variância dessa cobertura em um lote finito de predições futuras. Conforme demonstrado de forma pioneira por Marques (2025), devido à simetria de de Finetti e à permutabilidade atrelada ao limite superior do Split Conformal, a cobertura empírica $C_m(n_{cal}, \alpha)$ de um lote de teste de tamanho m segue uma distribuição estatística exata e fechada.

Quando o horizonte preditivo cresce indefinidamente ($m \to \infty$), a distribuição da cobertura empírica converge quase certamente para a distribuição universal **Beta**:

$$C_\infty \sim \text{Beta}\left(\lceil (1-\alpha)(n_{cal}+1) \rceil, \lfloor \alpha(n_{cal}+1) \rfloor\right) \tag{2.4}$$

Este postulado matemático prova que a flutuação da validade do nosso modelo contrafactual não depende de parâmetros ocultos dos dados, mas exclusivamente do tamanho da amostra de calibração (n_{cal}) fornecida ao algoritmo.

2.4 QUEBRA DE PARADIGMA: TRANSIÇÃO PARA O DESLOCAMENTO DE COVARIADAS

Até este ponto, a matemática da permutabilidade assume que tratamos de sequências oriundas do mesmo processo gerador. Porém, em inferência causal estrita (como no experimento observacional *Health Insurance*), o viés de seleção rompe a permutabilidade. A distribuição marginal das covariáveis de um indivíduo tratado ($T = 1$) difere sistematicamente da população de calibração base (controle, $T = 0$). O Deslocamento de Covariadas (*Covariate Shift*) inviabiliza o algoritmo de Predição Conformal Dividida padrão. A restauração destas garantias universais exige uma reponderação rigorosa baseada na razão de verossimilhança dos escores de propensão, a qual formalizaremos matematicamente a seguir.

3 DESLOCAMENTO DE COVARIADAS (*COVARIATE SHIFT*) E INFERÊNCIA CAUSAL

A validade da Predição Conformal clássica, cujos fundamentos de Vovk, Gammerman e Shafer (2005) foram estabelecidos no Capítulo 2, depende fundamentalmente da permutabilidade entre as amostras de calibração e teste. Em ambientes de economia aplicada e estudos observacionais, essa simetria colapsa devido ao viés de seleção. Este capítulo formaliza a quebra de permutabilidade provocada pelo deslocamento de covariadas, sua ligação intrínseca à estimação contrafactual e a adoção da Predição Conformal Ponderada (*Weighted Conformal Prediction*, WCP) como o mecanismo matemático para a restauração das garantias de cobertura.

3.1 A QUEBRA DE PERMUTABILIDADE PELO DESLOCAMENTO DE COVARIADAS

O fenômeno de deslocamento de covariadas surge quando a distribuição marginal das características difere entre a população de calibração, $P_{\text{cal}}(X)$, e a população alvo de teste, $P_{\text{test}}(X)$. Assume-se, contudo, que o mecanismo gerador do desfecho permanece inalterado, ou seja, a distribuição condicional $P(Y \mid X)$ é invariante (Tibshirani et al., 2019).

Sob deslocamento de covariadas, os pares estatísticos (X_i, Y_i) da amostra de calibração e o novo indivíduo de teste (X_{n+1}, Y_{n+1}) perdem a propriedade de permutabilidade. Se a probabilidade de ocorrência do indivíduo de teste se concentra em uma região do espaço pouco representada na calibração, a distribuição empírica dos escores de não-conformidade se torna enviesada. Aplicar o algoritmo de Predição Conformal Dividida simples neste cenário destrói a garantia matemática de cobertura marginal $1 - \alpha$, gerando intervalos artificialmente estreitos e estatisticamente inválidos.

3.2 INFERÊNCIA CAUSAL COMO PREDIÇÃO SOB DESLOCAMENTO DE COVARIADAS

O avanço crucial documentado por Lei e Candès (2021) reside na percepção de que a predição de contrafactuais sob confundimento observacional é, por definição, um problema de predição submetido a deslocamento de covariadas.

Na estimação do Efeito de Tratamento Individual (ITE), o desfecho contrafactual $Y_i(0)$ de um indivíduo efetivamente tratado ($T_i = 1$) não é observável. O modelo preditivo deve ser treinado e calibrado unicamente com a população de controle ($T = 0$). Consequentemente:

- A distribuição da amostra de calibração é regida por $P(X \mid T = 0)$.
- A distribuição do ponto de teste (indivíduo alvo) é regida por $P(X \mid T = 1)$.

Sob a premissa de que os indivíduos com maior probabilidade de receber o tratamento possuem características basais distintas daqueles que não o recebem, conclui-se que $P(X \mid T = 0) \neq P(X \mid T = 1)$. Para que a incerteza *distribution-free* assimilada no grupo de controle seja extrapolada para o grupo tratado, o algoritmo conformal necessita de uma correção matemática capaz de reequilibrar o espaço de covariadas.

3.3 A SOLUÇÃO TEÓRICA: PREDIÇÃO CONFORMAL PONDERADA (WCP)

Para restaurar a promessa universal de validade marginal, Tibshirani et al. (2019) introduziram a Predição Conformal Ponderada. A metodologia abandona a premissa de pesos uniformes $\left(\frac{1}{n_{\text{cal}}+1}\right)$ e repondera a função de distribuição empírica dos escores de calibração. A correção de viés é ditada pela razão de verossimilhança entre as distribuições marginal de teste e treino: $w(x) = \frac{dP_{\text{test}}(x)}{dP_{\text{train}}(x)}$.

3.3.1 O ESCORE DE PROPENSÃO E A RAZÃO DE VEROSSIMILHANÇA

Na intersecção formal com a inferência causal, a probabilidade de um indivíduo receber o tratamento é o Escore de Propensão (*Propensity Score*, PS), denotado por $e(x) = \mathbb{P}(T =$

$1 \mid X)$. Pela aplicação do Teorema de Bayes sobre as distribuições de probabilidade, a razão de verossimilhança para a predição do contrafactual $Y(0)$ no grupo tratado é traduzida na exata razão de chances (*odds*) do PS:

$$w(X_i) = \frac{e(X_i)}{1 - e(X_i)} \tag{3.1}$$

Matematicamente, um indivíduo de calibração (controle) cujas covariadas X_i sejam altamente associadas ao tratamento (alto $e(X_i)$) receberá um peso expressivo na distribuição empírica. Essa reponderação atua para espelhar as características da população de teste, calibrando os quantis do erro contrafactual de forma agnóstica ao modelo base.

3.3.2 O RIGOR FRENTE À FALTA DE SOBREPOSIÇÃO (*POOR OVERLAP*)

A formulação do peso $w(X_i)$ expõe o método ao exame severo quando a suposição de sobreposição (*overlap*) é ameaçada. Se um indivíduo possui $e(x) \to 1$, o denominador na razão aproxima-se de zero, gerando uma explosão de variância no estimador dos pesos ($w(x) \to \infty$).

Quando essa variância explosiva ocorre, um único escore de não-conformidade passa a dominar a soma acumulada de probabilidades na calibração ponderada. Como será demonstrado empiricamente na aplicação à base observacional *Health Insurance* (HI), o algoritmo conformal responde a esse fenômeno forçando a largura do intervalo preditivo a divergir para o infinito (∞). Esse comportamento deve ser lido como uma limitação substantiva do desenho de dados: diante de uma extrapolação contrafactual sem lastro de similaridade, o limite *distribution-free* preserva a cobertura apenas ao custo de intervalos sem utilidade direcional (Lei; Candès, 2021).

4 RESULTADOS EMPÍRICOS: SIMULAÇÕES E DADOS REAIS

Este capítulo apresenta a avaliação empírica da metodologia em duas etapas. Primeiro, a camada conformal é testada em ambientes de simulação controlados, nos quais a ”verdade”contrafactual é conhecida e o grau de perturbação distributiva é manipulável. Em seguida, o procedimento é aplicado a bases reais, nas quais a cobertura *distribution-free* enfrenta os limites práticos impostos pelo viés de seleção e pela não-observabilidade inerente ao problema causal fundamental.

4.1 ARQUITETURA EXPERIMENTAL E ENGENHARIA DE AVALIAÇÃO

As execuções de código foram implementadas em R, com desenvolvimento no RStudio (R Core Team, 2026; Posit team, 2026). A manipulação de dados e a construção dos fluxos de simulação utilizaram principalmente o `tidyverse` e funções auxiliares do pacote `MASS`; os modelos preditivos foram estimados com `ranger`, `dbarts` e `catboost`; e a produção das tabelas e figuras empregou recursos de `scales`, `showtext`, `systemfonts` e `labelled` (Wickham; Averick et al., 2019; Venables; Ripley, 2002; Wright; Ziegler, 2017; Dorie; Chipman; McCulloch, 2026; Dorogush; Ershov; Gulin, 2018; Prokhorenkova et al., 2017; Wickham; Pedersen; Seidel, 2025; Qiu, 2026; Pedersen; Ooms; Govett, 2026; Larmarange, 2025).

4.1.1 A MECÂNICA DOS PROCESSOS GERADORES DE DADOS (DGPS)

Na inferência causal empírica, a impossibilidade de observar o verdadeiro Efeito de Tratamento Individual (ITE) impede a validação direta da cobertura estatística (Lei; Candès, 2021). Assim, a certificação das garantias conformais obriga o uso de Processos Geradores de Dados (DGPs).

Definimos quatro arquiteturas de DGPs (cujas equações exatas e parametrizações encontram-se detalhadas no Apêndice A), parametrizadas para testar sistematicamente as fronteiras operacionais dos algoritmos sob diferentes vetores de estresse estatístico:

Tabela 1 – Matriz de Estresse dos DGPs Implementados

DGP	ITE	Principal Desafio	Foco da Validação
`Hmc`	Homogêneo	Falha de *Overlap*	Estabilidade dos Pesos IPS
`Hmc_Complex`	Homogêneo	Alta Dimensionalidade	Eficiência e Esparsidade
`Lei_Complex`	Heterogêneo	Heterocedasticidade	Cobertura Local (CQR)
`Hahn`	Heterogêneo	Não-linearidade ($sen(\cdot)$)	Propagação de Incerteza

1. **Lei Complex (Lei; Candès, 2021):** Estabelece uma linha de base com deslocamento de covariadas brando e presença de heterocedasticidade condicional.

2. **Hahn (Hahn, 2021):** Induz uma perturbação geométrica, forçando os modelos a lidarem com uma superfície de resposta caracterizada por extrema não-linearidade funcional.

3. **HMC e HMC Complex (Carvalho, 2019a; Hahn; Murray; Carvalho, 2020):** Projetados explicitamente para quebrar a premissa de positividade, induzindo severas violações de sobreposição (*poor overlap*) e precipitando o risco de variância explosiva na razão de verossimilhança.

4.1.2 O PROTOCOLO CONFORMAL: WCP COMO CAMADA DE CALIBRAÇÃO CONTRAFACTUAL

A mecânica de inferência segue a Predição Conformal Ponderada em formato dividido. A WCP é tratada como uma camada de calibração comum aos diferentes regressores avaliados, e não como uma metodologia dependente de um modelo preditivo específico. Assim, florestas, modelos bayesianos, versões normalizadas e regressores quantílicos entram apenas como motores de predição para o contrafactual; a garantia conformal decorre da reponderação dos escores de calibração sob deslocamento de covariadas (Lei; Candès, 2021; Tibshirani et al., 2019):

1. **Particionamento e Foco Causal:** Subdivisão dos dados em conjuntos disjuntos D_{train}, D_{cal} e D_{test}. É isolada a calibração unicamente sobre o grupo não tratado ($D^0_{\text{cal}} = \{(X_i, Y_i) \in D_{\text{cal}} : T_i = 0\}$), projetando a inferência contrafactual para o grupo tratado ($D^1_{\text{test}} = \{(X_j, Y_j) \in D_{\text{test}} : T_j = 1\}$).

2. **Treinamento:** Ajuste algorítmico do modelo estrutural $\hat{\mu}_0$ empregando exclusivamente unidades de controle em D_{train}, paralelamente ao ajuste da função de propensão de tratamento, o PS $\hat{e}(X)$.

3. **Vetorização de Calibração:** Cálculo dos escores de não-conformidade $R_i = |Y_i - \hat{\mu}_0(X_i)| \; \forall i \in D^0_{\text{cal}}$. A permutabilidade é quebrada intencionalmente, ordenando o vetor e concatenando o limite de domínio $\mathbf{R}_{\text{ext}} = (R_{(1)}, \ldots, R_{(n_{\text{cal0}})}, \infty)$.

4. **Dualidade do Escore de Propensão:** Bifurcação algorítmica para auditoria teórica, processando a calibração sob $e^{\text{true}}(X)$ ($k = 1$, probabilidade do oráculo livre de ruído) e $\hat{e}(X)$ ($k = 2$, probabilidade estimada).

5. **Reponderação da Distribuição Empírica:** A essência da solução geométrica para o viés de seleção. Para cada ponto contrafactual $j \in D^1_{\text{test}}$, os dados de calibração são recalibrados sob o peso amostral $w^{(k)}_{\text{cal},i} = \frac{e^{(k)}(X_{(i)})}{1-e^{(k)}(X_{(i)})}$ e o peso-alvo $w^{(k)}_{\text{test},j} = \frac{e^{(k)}(X_j)}{1-e^{(k)}(X_j)}$. A fronteira nominal é definida por:

$$\text{thr}_j = (1-\alpha)\left(\sum_{i=1}^{n_{\text{cal0}}} w^{(k)}_{\text{cal},i} + w^{(k)}_{\text{test},j}\right),$$

   A extração do erro ajustado $\hat{r}_j$ gera a estimativa contrafactual válida:

$$[L^{(k)}_{Y(0),j}, U^{(k)}_{Y(0),j}] = [\hat{\mu}_0(X_j) - \hat{r}_j, \hat{\mu}_0(X_j) + \hat{r}_j].$$

6. **Síntese do Intervalo Causal (ITE):** Operação algébrica final ancorada no dado observável empírico $Y_j = Y_j(1) \; \forall j \in D^1_{\text{test}}$:

$$\hat{C}^{(k)}_{\text{ITE},j} = \left[Y_j - U^{(k)}_{Y(0),j},\; Y_j - L^{(k)}_{Y(0),j}\right].$$

4.1.3 SISTEMA DE MÉTRICAS

A auditoria dos limites de predição sustenta-se nas seguintes medidas:

- **Cobertura Empírica Marginal:** O vetor central de avaliação, quantificando a proporção exata de ensaios nos quais a banda preditiva contém o verdadeiro resultado não observado (ITE).

- **Densidade de Incerteza Absoluta (*Triv.* / $\pm\infty$):** Mensuração explícita da vulnerabilidade distributiva, documentando a proporção de intervalos cujos limites divergem, retratando o colapso analítico sob ausência de suporte estrutural (*poor overlap*).
- **Índice de Inconclusão Prática (*Inconc.*):** Métrica que registra a proporção de intervalos de ITE que contêm zero. Nesses casos, o intervalo pode preservar cobertura, mas não permite afirmar a direção do efeito individual.
- **Eficiência Predicional (Largura):** O custo-benefício do *trade-off* de validação, mapeando a amplitude informacional gerada por diferentes regressores de aprendizado de máquina.

4.1.4 CAMADA DE INFERÊNCIA: MODELOS REGRESSIVOS

A garantia de validade de Vovk, Gammerman e Shafer (2005) reduz a dependência da especificação correta do algoritmo preditivo subjacente. Contudo, a utilidade empírica, medida pela estreiteza do intervalo, ainda depende da qualidade desse modelo. Avaliamos os seguintes modelos:

1. **QRF (*Quantile Regression Forest*):** Motor base fundamentado em aprendizado de quantis condicionais, notabilizado pela aderência à premissa de distribuição flexível e variância adaptativa (Meinshausen, 2006).
2. **BART (*Bayesian Additive Regression Trees*):** Estrutura de indução não-paramétrica munida de *priors* bayesianos regularizadores de alta estabilidade teórica na mitigação dimensional, com expressiva adequação à resposta contrafactual. Na implementação, a dispersão posterior local do BART é usada para escalar o erro conformal, permitindo intervalos de largura variável conforme a incerteza preditiva de cada indivíduo (Hahn; Murray; Carvalho, 2020).
3. **CatBoost Quantílico:** Variedade de impulsionamento em gradiente (*gradient boosting*) adaptado para respostas baseadas em assimetria, visando contornar perturbações sistêmicas por otimização intensiva.

4. **Random Forest (RF) Padrão:** Abordagem de controle baseada exclusivamente na estimativa da média condicional, evidenciando a ineficiência de gerar intervalos de tamanho constante sob heterocedasticidade.

5. **Random Forest (RF) Normalizada:** Método conformal localmente adaptativo que escalona resíduos pela dispersão, servindo de contraexemplo por subestimar erros devido ao viés de otimização do treinamento.

4.2 ENSAIOS SINTÉTICOS: VALIDAÇÃO UNIVERSAL SOB DESLOCAMENTO DE COVARIADAS

O detalhamento contida nas Tabelas 2, 3, 4 e 5 evidencia a dependência da WCP ao paradigma da permutabilidade ponderada. As respostas dos processos simulam de perto o grau de vulnerabilidade esquematizado: ambientes submetidos a leve deslocamento produzem calibrações estáveis; inversamente, processos atrelados à deficiência de sobreposição severa incorrem no comportamento de saturação nominal (*infinite bands*) frente a calibradores escassos.

No DGP de referência, Lei Complex (Lei; Candès, 2021) (Tabela 5), o marcador de degeneração é nulo (*Triv.*$= 0$), e a cobertura estabiliza consistentemente próxima dos níveis nominais (entre $0{,}87$ e $0{,}94$), associada a larguras eficientes ($1{,}62$ a $1{,}94$). Ainda assim, a proporção de intervalos que contêm zero permanece em torno de $0{,}25$ a $0{,}31$. Isso decorre da combinação entre efeitos heterogêneos próximos de zero em parte do suporte e ruído heterocedástico; portanto, validade de cobertura não implica capacidade de decidir o sinal do efeito em todos os indivíduos.

Nos DGPs HMC e HMC Complex (Carvalho, 2019a; Hahn; Murray; Carvalho, 2020) (Tabelas 2 e 3), a leitura é diferente. No HMC, o efeito verdadeiro é constante e negativo, mas sua magnitude é pequena diante do ruído e da incerteza induzida pela falta de sobreposição; por isso, mesmo com $n_{cal} = 10000$, cerca de 70% a 80% dos intervalos ainda contêm zero. No HMC Complex, a falha de suporte aparece de forma mais aguda em $n_{cal} = 200$, com intervalos infinitos, mas a inconclusão cai para patamares próximos de $0{,}09$ a $0{,}30$ quando a calibração aumenta, pois o efeito constante de maior magnitude torna o sinal mais identificável.

Tabela 2 – Resultados do Experimento DGP 1 (Carlos Carvalho)

Modelo	n_{cal}	n_{cal0}	PS Conhecido				PS Estimado			
			Triv.	**Inconc.**	**Cobert.**	**Méd.**	**Triv.**	**Inconc.**	**Cobert.**	**Méd.**
Tamanho de Calibração: 200										
Random Forest	200	101	0,000	0,547	0,802	2,070	0,024	0,398	0,659	∞
Quantile Forest Reg.	200	101	0,000	0,607	0,843	2,410	0,024	0,517	0,750	∞
BART	200	101	0,000	0,785	0,929	3,690	0,024	0,342	0,513	∞
RF Normalizada	200	101	0,000	0,789	0,948	3,570	0,024	0,519	0,762	∞
CatBoost Quantílico	200	101	0,000	0,659	0,822	2,430	0,024	0,510	0,661	∞
Tamanho de Calibração: 500										
Random Forest	500	259	0,000	0,752	0,924	2,960	0,022	0,777	0,934	∞
Quantile Forest Reg.	500	259	0,000	0,717	0,918	2,930	0,022	0,755	0,935	∞
BART	500	259	0,000	0,754	0,906	3,500	0,022	0,738	0,897	∞
RF Normalizada	500	259	0,000	0,794	0,949	3,500	0,022	0,760	0,927	∞
CatBoost Quantílico	500	259	0,000	0,762	0,897	2,950	0,022	0,790	0,914	∞
Tamanho de Calibração: 1000										
Random Forest	1000	485	0,000	0,734	0,923	2,870	0,006	0,705	0,909	∞
Quantile Forest Reg.	1000	485	0,000	0,718	0,927	2,970	0,006	0,710	0,919	∞
BART	1000	485	0,000	0,796	0,930	3,720	0,006	0,694	0,882	∞
RF Normalizada	1000	485	0,000	0,667	0,883	2,720	0,006	0,626	0,855	∞
CatBoost Quantílico	1000	485	0,000	0,782	0,915	3,070	0,006	0,725	0,875	∞
Tamanho de Calibração: 5000										
Random Forest	5000	2477	0,000	0,732	0,928	2,830	0,000	0,683	0,902	2,600
Quantile Forest Reg.	5000	2477	0,000	0,715	0,924	2,900	0,000	0,661	0,889	2,610
BART	5000	2477	0,000	0,793	0,916	3,520	0,000	0,640	0,847	2,620
RF Normalizada	5000	2477	0,000	0,757	0,928	3,160	0,000	0,716	0,906	2,920
CatBoost Quantílico	5000	2477	0,000	0,776	0,916	2,960	0,000	0,726	0,880	2,710
Tamanho de Calibração: 10000										
Random Forest	10000	5000	0,000	0,706	0,900	2,720	0,000	0,693	0,893	2,670
Quantile Forest Reg.	10000	5000	0,000	0,710	0,913	2,880	0,000	0,714	0,914	2,900
BART	10000	5000	0,000	0,744	0,909	3,490	0,000	0,687	0,871	2,970
RF Normalizada	10000	5000	0,000	0,737	0,912	3,080	0,000	0,733	0,909	3,050
CatBoost Quantílico	10000	5000	0,000	0,786	0,917	3,060	0,000	0,807	0,925	3,170

Notas: *Triv.* indica a proporção de intervalos não informativos, com pelo menos um limite infinito; *Inconc.* indica a proporção de intervalos de ITE que incluem zero; *Cobert.* indica a cobertura empírica do efeito verdadeiro τ; *Méd.* indica a largura média do intervalo de ITE, calculada como limite superior menos limite inferior.

Tabela 3 – Resultados do Experimento DGP 2 (Carlos Carvalho)

Modelo	n_{cal}	n_{cal0}	PS Conhecido				PS Estimado			
			Triv.	**Inconc.**	**Cobert.**	**Méd.**	**Triv.**	**Inconc.**	**Cobert.**	**Méd.**
Tamanho de Calibração: 200										
Random Forest	200	94	0,335	0,456	0,965	∞	0,231	0,359	0,949	∞
Quantile Forest Reg.	200	94	0,335	0,487	0,959	∞	0,231	0,380	0,922	∞
BART	200	94	0,335	0,719	0,977	∞	0,231	0,524	0,952	∞
RF Normalizada	200	94	0,335	0,528	0,980	∞	0,231	0,422	0,969	∞
CatBoost Quantílico	200	94	0,335	0,442	0,955	∞	0,231	0,335	0,932	∞
Tamanho de Calibração: 500										
Random Forest	500	264	0,000	0,137	0,916	3,940	0,000	0,141	0,917	3,970
Quantile Forest Reg.	500	264	0,000	0,189	0,918	4,450	0,000	0,160	0,903	4,170
BART	500	264	0,000	0,288	0,931	4,700	0,000	0,298	0,929	4,790
RF Normalizada	500	264	0,000	0,161	0,913	4,150	0,000	0,105	0,871	3,570
CatBoost Quantílico	500	264	0,000	0,111	0,914	3,790	0,000	0,118	0,922	3,860
Tamanho de Calibração: 1000										
Random Forest	1000	484	0,000	0,123	0,898	3,720	0,000	0,108	0,886	3,560
Quantile Forest Reg.	1000	484	0,000	0,162	0,906	4,110	0,000	0,153	0,904	4,040
BART	1000	484	0,000	0,272	0,918	4,430	0,000	0,236	0,898	4,170
RF Normalizada	1000	484	0,000	0,148	0,912	3,960	0,000	0,147	0,912	3,940
CatBoost Quantílico	1000	484	0,000	0,094	0,898	3,560	0,000	0,089	0,893	3,490
Tamanho de Calibração: 5000										
Random Forest	5000	2553	0,000	0,114	0,904	3,760	0,000	0,099	0,889	3,600
Quantile Forest Reg.	5000	2553	0,000	0,138	0,891	4,000	0,000	0,120	0,874	3,810
BART	5000	2553	0,000	0,209	0,896	4,070	0,000	0,203	0,891	3,990
RF Normalizada	5000	2553	0,000	0,117	0,903	3,800	0,000	0,105	0,888	3,660
CatBoost Quantílico	5000	2553	0,000	0,101	0,917	3,760	0,000	0,090	0,904	3,610
Tamanho de Calibração: 10000										
Random Forest	10000	4973	0,000	0,152	0,923	4,050	0,000	0,148	0,922	4,000
Quantile Forest Reg.	10000	4973	0,000	0,140	0,890	3,970	0,000	0,144	0,891	4,000
BART	10000	4973	0,000	0,210	0,890	4,010	0,000	0,196	0,884	3,910
RF Normalizada	10000	4973	0,000	0,150	0,912	4,020	0,000	0,150	0,912	4,030
CatBoost Quantílico	10000	4973	0,000	0,107	0,917	3,730	0,000	0,107	0,917	3,730

Notas: *Triv.* indica a proporção de intervalos não informativos, com pelo menos um limite infinito; *Inconc.* indica a proporção de intervalos de ITE que incluem zero; *Cobert.* indica a cobertura empírica do efeito verdadeiro τ; *Méd.* indica a largura média do intervalo de ITE, calculada como limite superior menos limite inferior.

Tabela 4 – Resultados do Experimento DGP 3 (YoungStatS - Richard Hahn)

Modelo	n_{cal}	n_{cal0}	**PS Conhecido**				**PS Estimado**			
			Triv.	**Inconc.**	**Cobert.**	**Méd.**	**Triv.**	**Inconc.**	**Cobert.**	**Méd.**
Tamanho de Calibração: 200										
Random Forest	200	92	0,000	0,908	0,909	10,600	0,000	0,747	0,753	7,170
Quantile Forest Reg.	200	92	0,000	0,961	0,963	12,600	0,000	0,951	0,955	12,100
BART	200	92	0,000	0,906	0,911	11,100	0,000	0,623	0,628	4,940
RF Normalizada	200	92	0,000	0,920	0,923	17,000	0,000	0,776	0,787	9,550
CatBoost Quantílico	200	92	0,000	0,978	0,975	12,400	0,000	0,446	0,448	3,320
Tamanho de Calibração: 500										
Random Forest	500	251	0,000	0,885	0,887	9,800	0,000	0,607	0,616	5,360
Quantile Forest Reg.	500	251	0,000	0,908	0,914	10,600	0,000	0,858	0,866	9,310
BART	500	251	0,000	0,937	0,942	11,200	0,000	0,397	0,419	2,870
RF Normalizada	500	251	0,000	0,878	0,884	13,000	0,000	0,805	0,814	10,300
CatBoost Quantílico	500	251	0,000	0,954	0,951	10,900	0,000	0,248	0,252	1,760
Tamanho de Calibração: 1000										
Random Forest	1000	501	0,000	0,870	0,882	9,590	0,000	0,018	0,018	0,154
Quantile Forest Reg.	1000	501	0,000	0,859	0,870	9,400	0,000	0,006	0,007	-4,270
BART	1000	501	0,000	0,825	0,833	7,700	0,000	0,118	0,121	0,795
RF Normalizada	1000	501	0,000	0,849	0,856	11,900	0,000	0,019	0,017	0,147
CatBoost Quantílico	1000	501	0,000	0,830	0,821	7,460	0,000	0,180	0,180	1,280
Tamanho de Calibração: 5000										
Random Forest	5000	2442	0,000	0,907	0,913	10,400	0,000	0,007	0,005	0,045
Quantile Forest Reg.	5000	2442	0,000	0,894	0,904	10,500	0,000	0,020	0,024	-2,830
BART	5000	2442	0,000	0,900	0,904	9,480	0,000	0,049	0,049	0,332
RF Normalizada	5000	2442	0,000	0,904	0,904	14,400	0,000	0,001	0,001	0,010
CatBoost Quantílico	5000	2442	0,000	0,916	0,907	9,540	0,000	0,004	0,003	-0,312
Tamanho de Calibração: 10000										
Random Forest	10000	4838	0,000	0,904	0,904	10,000	0,000	0,054	0,051	0,384
Quantile Forest Reg.	10000	4838	0,000	0,885	0,896	10,100	0,000	0,033	0,034	-2,270
BART	10000	4838	0,000	0,896	0,900	9,550	0,000	0,001	0,000	0,003
RF Normalizada	10000	4838	0,000	0,902	0,911	14,300	0,000	0,015	0,017	0,123
CatBoost Quantílico	10000	4838	0,000	0,905	0,903	9,090	0,000	0,004	0,003	-0,321

Notas: *Triv.* indica a proporção de intervalos não informativos, com pelo menos um limite infinito; *Inconc.* indica a proporção de intervalos de ITE que incluem zero; *Cobert.* indica a cobertura empírica do efeito verdadeiro τ; *Méd.* indica a largura média do intervalo de ITE, calculada como limite superior menos limite inferior.

Tabela 5 – Resultados do Experimento DGP 4 (Lei & Candès)

Modelo	n_{cal}	n_{cal0}	PS Conhecido				PS Estimado			
			Triv.	**Inconc.**	**Cobert.**	**Méd.**	**Triv.**	**Inconc.**	**Cobert.**	**Méd.**
Tamanho de Calibração: 200										
Random Forest	200	118	0,000	0,257	0,895	1,670	0,000	0,270	0,903	1,710
Quantile Forest Reg.	200	118	0,000	0,276	0,911	1,790	0,000	0,286	0,923	1,870
BART	200	118	0,000	0,264	0,898	1,760	0,000	0,269	0,908	1,810
RF Normalizada	200	118	0,000	0,257	0,885	1,640	0,000	0,264	0,896	1,700
CatBoost Quantílico	200	118	0,000	0,272	0,910	1,790	0,000	0,293	0,927	1,880
Tamanho de Calibração: 500										
Random Forest	500	305	0,000	0,290	0,929	1,840	0,000	0,293	0,936	1,880
Quantile Forest Reg.	500	305	0,000	0,297	0,935	1,920	0,000	0,300	0,939	1,940
BART	500	305	0,000	0,275	0,916	1,810	0,000	0,283	0,921	1,870
RF Normalizada	500	305	0,000	0,290	0,923	1,840	0,000	0,288	0,923	1,830
CatBoost Quantílico	500	305	0,000	0,307	0,938	1,940	0,000	0,306	0,937	1,940
Tamanho de Calibração: 1000										
Random Forest	1000	586	0,000	0,256	0,890	1,620	0,000	0,259	0,895	1,650
Quantile Forest Reg.	1000	586	0,000	0,253	0,888	1,660	0,000	0,249	0,884	1,630
BART	1000	586	0,000	0,248	0,870	1,620	0,000	0,258	0,887	1,680
RF Normalizada	1000	586	0,000	0,259	0,889	1,660	0,000	0,261	0,895	1,690
CatBoost Quantílico	1000	586	0,000	0,251	0,882	1,630	0,000	0,256	0,886	1,670
Tamanho de Calibração: 5000										
Random Forest	5000	2938	0,000	0,268	0,911	1,720	0,000	0,267	0,908	1,700
Quantile Forest Reg.	5000	2938	0,000	0,266	0,904	1,730	0,000	0,267	0,907	1,730
BART	5000	2938	0,000	0,272	0,912	1,800	0,000	0,268	0,904	1,750
RF Normalizada	5000	2938	0,000	0,274	0,911	1,740	0,000	0,274	0,911	1,740
CatBoost Quantílico	5000	2938	0,000	0,270	0,904	1,720	0,000	0,270	0,905	1,730
Tamanho de Calibração: 10000										
Random Forest	10000	5812	0,000	0,264	0,902	1,680	0,000	0,263	0,902	1,670
Quantile Forest Reg.	10000	5812	0,000	0,268	0,900	1,710	0,000	0,267	0,899	1,710
BART	10000	5812	0,000	0,266	0,897	1,740	0,000	0,266	0,898	1,720
RF Normalizada	10000	5812	0,000	0,273	0,901	1,710	0,000	0,273	0,900	1,700
CatBoost Quantílico	10000	5812	0,000	0,269	0,906	1,710	0,000	0,270	0,906	1,710

Notas: *Triv.* indica a proporção de intervalos não informativos, com pelo menos um limite infinito; *Inconc.* indica a proporção de intervalos de ITE que incluem zero; *Cobert.* indica a cobertura empírica do efeito verdadeiro τ; *Méd.* indica a largura média do intervalo de ITE, calculada como limite superior menos limite inferior.

Submetido à fronteira de não linearidade do DGP Hahn (Hahn, 2021) (Tabela 4), a fragilidade transita para o mecanismo de estimação do PS. Com PS conhecido, a cobertura fica entre $0{,}82$ e $0{,}98$, mas a inconclusão é alta porque o efeito verdadeiro varia em $[-1, 0]$ e parte relevante dos indivíduos tem efeito muito próximo de zero. Com PS estimado, especialmente sob $n_{cal} \geq 1000$, surgem larguras negativas e coberturas quase nulas, o que não deve ser interpretado como precisão; trata-se de instabilidade numérica e estatística da estimação de propensão em uma superfície reativa não linear.

Notamos que a utilidade algorítmica é contextual. Sob simetria probabilística razoável, as disparidades entre as estruturas heurísticas (QRF, BART, CatBoost, variantes RF) são amortecidas pela camada conformal. Nas provações extremas de falta de permutabilidade, o suporte comum e o escalonamento empírico da calibração (n_{cal}) tornam-se elementos fundamentais à extração de utilidade analítica, superando o papel modelador basal.

4.3 TRANSIÇÃO PARA O OBSERVACIONAL: APLICAÇÕES EM DADOS REAIS

O ambiente sintético (DGPs) permitiu avaliar a validade marginal em amostras finitas sob condições controladas. A etapa aplicada expõe a metodologia à complexidade de dados observacionais e experimentais clássicos da literatura. Para tal, selecionamos o ensaio educacional STAR (Finn; Achilles, 1990; Krueger, 1999) e a base observacional HI (*Health Insurance and Hours Worked By Wives*), originada de Olson (1998).

A escolha destas bases não é aleatória. O STAR fornece um experimento randomizado em educação, enquanto o HI oferece um desenho observacional com forte risco de seleção: a cobertura por seguro-saúde do cônjuge pode alterar a oferta de trabalho das esposas, mas a atribuição não é randomizada. As abordagens clássicas dessas aplicações fornecem estimativas médias ou pontuais; aqui, o objetivo é avaliar quanta incerteza individual surge quando a inferência contrafactual é feita com garantias conformais.

O presente trabalho aplica a WCP (Lei; Candès, 2021; Tibshirani et al., 2019) para avaliar estimativas heterogêneas com intervalos de predição contrafactual de garantia *distribution-free* (Vovk; Gammerman; Shafer, 2005). A seguir, avaliamos como o modelo se comporta quando os contrafactuais não são observáveis e a inferência depende exclusivamente do

suporte comum entre os grupos.

4.3.1 EXPERIMENTO 1: ESTRESSE ABSOLUTO (HI HEALTH INSURANCE)

O resumo avaliativo empírico sob as propriedades da base *Health Insurance* consolida-se na Tabela 6.

Tabela 6 – Resultados do Experimento 1 (HI Health Insurance)

Modelo	n_{cal}	n_{cal0}	**Triv.**	**Cobertura Zero**	**Largura Média**
Random Forest	5530	2700	0,00253	0,890	∞
Quantile Forest Regression	5530	2700	0,00253	0,962	∞
BART	5530	2700	0,00253	0,935	∞
Random Forest Normalizada	5530	2700	0,00253	0,870	∞
CatBoost Quantílico	5530	2700	0,00253	0,878	∞

Notas: *Triv.* indica a proporção de intervalos não informativos, com pelo menos um limite infinito; *Cobertura Zero* indica a proporção de intervalos de ITE que incluem zero; *Largura Média* indica a média do limite superior menos o limite inferior. Valores iguais a ∞ indicam divergência da largura média.

Os resultados mostram uma limitação operacional severa: apesar de um índice mínimo de instabilidade pontual (*Triv.* $= 0{,}00253$), a média operacional da largura diverge para ∞ sobre toda a classe de preditores. Havendo falha de sobreposição no espaço vetorial real, a resposta *distribution-free* preserva a cobertura ao custo de incerteza total.

Tal comportamento é sustentado no indicador **Cobertura Zero**. QRF e BART assumem os patamares de maior indecisão empírica ($0{,}962$ e $0{,}935$, respectivamente). No HI, a preservação estrita da métrica marginal subordina a precisão pragmática a limites de pouca resolução descritiva.

4.3.2 EXPERIMENTO 2: RANDOMIZAÇÃO CONTROLADA (STAR TENNESSEE)

Os indicadores obtidos na base STAR documentam a resiliência geométrica conformal (Tabela 7).

Nesse cenário, a robustez é confirmada: os colapsos direcionais foram eliminados (*Triv.* $= 0$), mantendo a eficiência em intervalos controlados (larguras entre $90{,}7$ e $106{,}0$). Esse

Tabela 7 – Resultados do Experimento 2 (STAR Tennessee)

Modelo	n_{cal}	n_{cal0}	**Triv.**	**Cobertura Zero**	**Largura Média**
Random Forest	5662	3939	0,00000	0,863	92,0
Quantile Forest Regression	5662	3939	0,00000	0,894	106,0
BART	5662	3939	0,00000	0,833	90,7
Random Forest Normalizada	5662	3939	0,00000	0,873	95,0
CatBoost Quantílico	5662	3939	0,00000	0,892	99,6

Notas: *Triv.* indica a proporção de intervalos não informativos, com pelo menos um limite infinito; *Cobertura Zero* indica a proporção de intervalos de ITE que incluem zero; *Largura Média* indica a média do limite superior menos o limite inferior. Valores iguais a ∞ indicam divergência da largura média.

patamar de estabilidade mostra que a instabilidade dos pesos foi mitigada graças à base sólida de suporte comum entre os estudantes do experimento.

Na **Cobertura Zero**, o QRF ($0{,}894$) e o CatBoost ($0,892$) apresentam resultados semelhantes à configuração padrão do RF. Por outro lado, o efeito regularizador do BART ($0{,}833$) resulta em intervalos mais estreitos ($90{,}7$), evidenciando o *trade-off* de eficiência em comparação ao modelo QRF, que é mais adaptativo e gera larguras maiores ($106{,}0$).

4.3.3 SÍNTESE COMPARATIVA EMPÍRICA E VISUAIS DE CONTRAFACTUAIS

A diferença estrutural entre as bases, com o HI sofrendo pela falta de sobreposição e o STAR apresentando a estabilidade de ensaios randomizados, revela os limites da inferência causal *distribution-free*. Em resumo, os resultados mostram que a utilidade dos intervalos depende menos de uma família específica de modelos e mais da interação entre suporte comum, qualidade preditiva e reponderação conformal.

Para ilustrar esse contraste, a Figura 1 apresenta os intervalos contrafactuais individuais (ITE) de 30 indivíduos em ambas as bases. A explosão dos limites no HI é visível quando comparada à estabilidade no STAR, o que reforça que a qualidade do suporte comum é o fator determinante para a utilidade dos intervalos.

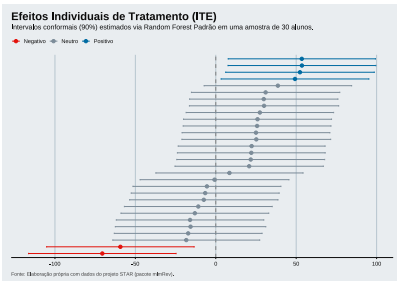
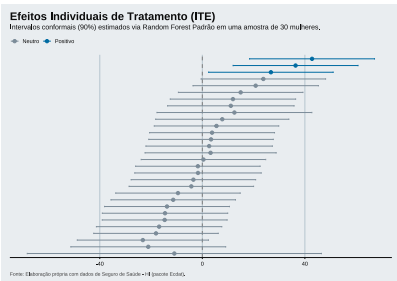
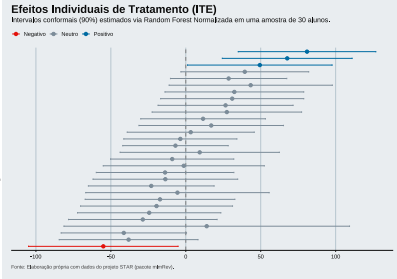
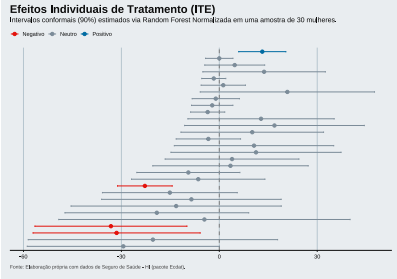
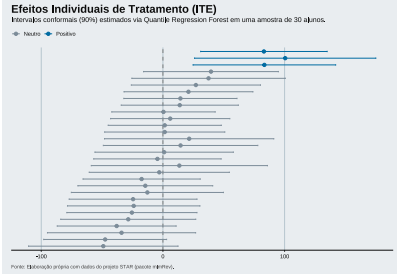
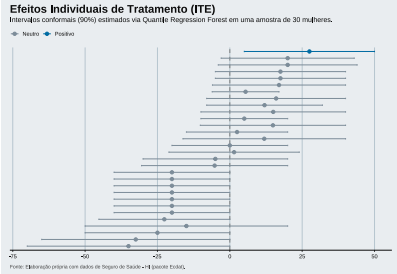
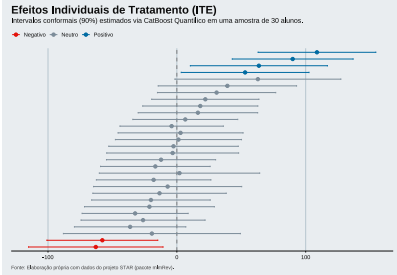
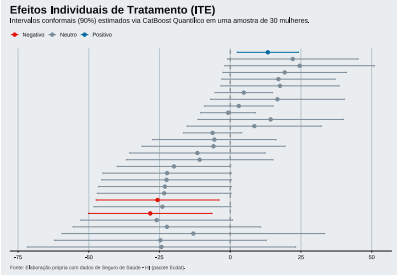
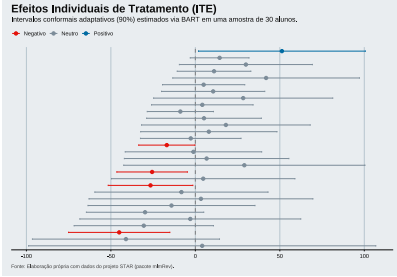
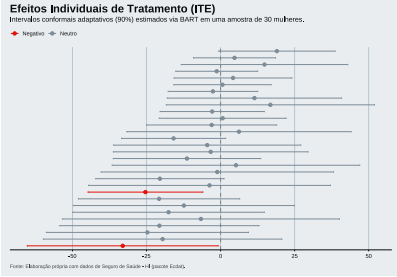
Modelo Base	STAR Tennessee	HI Health Insurance
Random Forest Padrão		
Random Forest Normalizada		
Quantile Regression Forest		
CatBoost Quantílico		
BART		

Figura 1 – Intervalos conformais para o Efeito Individual de Tratamento (ITE), com cobertura empírica almejada de 90%. A figura compara o comportamento estrutural dos algoritmos preditivos em uma amostra de 30 indivíduos para cada base empírica.

5 DISCUSSÃO E CONCLUSÃO

Este capítulo sintetiza os resultados empíricos do Capítulo 4 e explicita o principal aprendizado do trabalho: a Predição Conformal Ponderada (*Weighted Conformal Prediction*, WCP) oferece uma forma rigorosa de quantificar incerteza em inferência contrafactual, mas sua utilidade prática depende fortemente das condições de suporte comum, da qualidade do escore de propensão e da relação entre a magnitude do efeito e o ruído do desfecho.

5.1 INTERPRETAÇÃO DOS RESULTADOS E PAPEL DA SOBREPOSIÇÃO

A evidência das simulações é consistente com o resultado teórico de Lei e Candès (2021): quando as hipóteses de reponderação são plausíveis, a WCP preserva validade marginal para intervalos contrafactuais em amostras finitas. No entanto, os experimentos mostram que validade estatística e utilidade decisória são critérios distintos. Um intervalo pode cobrir o contrafactual verdadeiro e, ao mesmo tempo, ser largo demais ou cruzar zero com frequência elevada, impedindo uma conclusão individual sobre o sinal do tratamento.

Os resultados podem ser organizados em três regimes:

- **Estabilidade relativa:** No DGP Lei Complex, o deslocamento de covariadas é moderado, a degeneração é nula e a cobertura permanece próxima do nível nominal. Mesmo nesse caso favorável, uma parcela relevante dos intervalos contém zero, refletindo efeitos heterogêneos próximos de zero e ruído heterocedástico.
- **Ruptura de positividade:** Nos DGPs HMC e HMC Complex (Carvalho, 2019a; Hahn; Murray; Carvalho, 2020), a falta de suporte comum aumenta a variância dos pesos e pode gerar intervalos infinitos. O HMC é particularmente inconclusivo porque o efeito verdadeiro é pequeno em módulo diante do ruído; já o HMC Complex se torna mais informativo quando a calibração cresce, pois o efeito constante tem maior magnitude.

- **Sensibilidade ao escore de propensão:** No DGP Hahn (Hahn, 2021), a superfície de seleção é altamente não linear. Com PS conhecido, a cobertura é razoável, mas muitos intervalos ainda cruzam zero porque o efeito verdadeiro varia em $[-1, 0]$. Com PS estimado, surgem coberturas quase nulas e larguras negativas em alguns cenários, sinalizando instabilidade numérica e não precisão estatística.

Assim, o método funciona melhor como uma camada de auditoria da incerteza causal do que como uma ferramenta que sempre produzirá intervalos individualmente úteis. Quando a sobreposição é fraca, a resposta conformal expõe a fragilidade do desenho de dados em vez de escondê-la por meio de estimativas pontuais excessivamente confiantes.

5.2 IMPLICAÇÕES PARA APLICAÇÕES EMPÍRICAS

As aplicações em dados reais reforçam essa leitura. Na base observacional *Health Insurance* (HI), a largura média infinita em todos os modelos mostra que a WCP encontra pouco suporte para extrapolar contrafactuais de forma informativa. A baixa proporção de intervalos formalmente infinitos não elimina o problema: basta que alguns pesos dominem a distribuição de calibração para comprometer a largura média e reduzir a utilidade prática dos intervalos.

No experimento STAR, a randomização melhora o suporte comum e evita intervalos não informativos. Ainda assim, os valores elevados de **Cobertura Zero** indicam que grande parte dos intervalos não identifica com segurança a direção do efeito individual. Isso é substantivamente importante para a interpretação aplicada: em problemas de política pública, medicina ou marketing, a cobertura marginal deve ser acompanhada por métricas de largura, proporção de intervalos infinitos e proporção de intervalos que cruzam zero.

Portanto, a principal contribuição empírica do trabalho não é mostrar que a WCP sempre entrega intervalos úteis, mas delimitar quando ela é informativa e quando sua resposta revela uma limitação do desenho causal disponível.

5.3 LIMITAÇÕES

Quatro limitações merecem destaque para a leitura final dos resultados:

1. **Dependência de suporte comum:** Quando $e(x)$ se aproxima de 1 para unidades tratadas sem controles comparáveis, os pesos de importância se tornam instáveis e os intervalos podem se tornar infinitos ou excessivamente largos.
2. **Dependência da estimação do PS:** A validade operacional da WCP depende da qualidade de $\hat{e}(x)$. Em superfícies complexas, como no DGP Hahn, erros de estimação do PS podem destruir a calibração efetiva.
3. **Impossibilidade de verificar cobertura em dados reais:** Em bases observacionais, apenas o desfecho factual é observado. Assim, a cobertura verdadeira do ITE não pode ser medida diretamente; avaliam-se apenas métricas indiretas, como largura e inconclusão.
4. **Sensibilidade numérica:** A calibração ponderada exige cuidado com ordenação dos resíduos, normalização dos pesos, *clipping* e cruzamento de limites. Larguras negativas ou limites invertidos devem ser tratados como falhas diagnósticas do procedimento implementado.

5.4 CONCLUSÃO

Este TCC aplicou Predição Conformal Ponderada à estimação de incerteza do Efeito de Tratamento Individual, combinando simulações controladas e aplicações reais. Os resultados indicam que a WCP é teoricamente atraente porque preserva validade marginal sob deslocamento de covariadas, mas também deixam claro que essa garantia não elimina os problemas centrais da inferência causal observacional.

Em termos práticos, a WCP deve ser interpretada como uma ferramenta de quantificação e diagnóstico de incerteza. Quando há suporte comum razoável, ela pode produzir intervalos finitos e informativos. Quando há falha de positividade, PS mal estimado ou efeitos pequenos diante do ruído, a metodologia tende a devolver intervalos largos, infinitos

ou inconclusivos. Essa resposta não invalida o método, mas limita sua utilidade como instrumento direto de decisão individual.

Para trabalhos futuros, três caminhos são prioritários: aplicar o procedimento a bases reais maiores e mais complexas; investigar estimadores de escore de propensão mais estáveis e métodos de balanceamento; e desenvolver diagnósticos prévios de suporte comum que indiquem quando a WCP tem chance real de produzir intervalos úteis. Esses caminhos preservam a principal lição do trabalho: em inferência causal, incerteza bem quantificada é tão importante quanto a estimativa pontual do efeito.

REFERÊNCIAS

CARVALHO, Carlos. **Bayesian regression tree models for causal inference: Regularization, confounding, and heterogeneous effects**. [S.l.: s.n.], abr. 2019a. Presentation. Joint work with Jared Murray, P. Richard Hahn, David Yeager, et al.

CARVALHO, Carlos. **Carlos Carvalho, "Bayesian Regression Tree Models for Causal Inference"**. [S.l.: s.n.], abr. 2019b. YouTube video. Disponível em: https://www.youtube.com/watch?v=xm1CJCCNirY.

DORIE, Vincent; CHIPMAN, Hugh; MCCULLOCH, Robert. **dbarts: Discrete Bayesian Additive Regression Trees Sampler**. [S.l.], 2026. R package version 0.9-33. DOI: 10.32614/CRAN.package.dbarts. Disponível em: https://CRAN.R-project.org/package=dbarts.

DOROGUSH, Anna Veronika; ERSHOV, Vasily; GULIN, Andrey. **CatBoost: Gradient Boosting with Categorical Features Support**. [S.l.: s.n.], 2018. Disponível em: https://arxiv.org/abs/1810.11363.

FINN, Jeremy D; ACHILLES, Charles M. Answers and questions about class size: A statewide experiment. **American Educational Research Journal**, Sage Publications, v. 27, n. 3, p. 557–589, 1990.

HAHN, P. Richard; MURRAY, Jared S.; CARVALHO, Carlos M. Bayesian Regression Tree Models for Causal Inference: Regularization, Confounding, and Heterogeneous Effects (with Discussion). **Bayesian Analysis**, International Society for Bayesian Analysis, v. 15, n. 3, p. 965–1056, 2020. DOI: 10.1214/19-BA1195. Disponível em: https://doi.org/10.1214/19-BA1195.

HAHN, Richard. **Machine learning for causal inference that works**. [S.l.: s.n.], jan. 2021. Blog post. Disponível em: https://youngstats.github.io/post/2021/01/26/machine-learning-for-causal-inference-that-works/.

KRUEGER, Alan B. Experimental estimates of education production functions. **The Quarterly Journal of Economics**, MIT Press, v. 114, n. 2, p. 497–532, 1999.

LARMARANGE, Joseph. **labelled: Manipulating Labelled Data**. [S.l.], 2025. R package version 2.16.0. DOI: 10.32614/CRAN.package.labelled. Disponível em: https://CRAN.R-project.org/package=labelled.

LEI, Lihua; CANDÈS, Emmanuel J. Conformal inference of counterfactuals and individual treatment effects. **Journal of the Royal Statistical Society: Series B (Statistical Methodology)**, v. 83, n. 5, p. 911–938, 2021. DOI: 10.1111/rssb.12445.

MARQUES, Paulo C. Universal distribution of the empirical coverage in split conformal prediction. **Statistics and Probability Letters**, v. 219, p. 110350, 2025. DOI: 10.1016/j.spl.2024.110350.

MEINSHAUSEN, Nicolai. Quantile Regression Forests. **Journal of Machine Learning Research**, v. 7, p. 983–999, 2006.

NEYMAN, Jerzy. On the application of probability theory to agricultural experiments. Essay on principles. Section 9. **Roczniki Nauk Rolniczych**, v. 10, p. 1–51, 1923. English translation by D. M. Dabrowska and T. P. Speed in Statistical Science, 5(4), 465–480, 1990.

OLSON, Craig A. A comparison of parametric and semiparametric estimates of the effect of spousal health insurance coverage on weekly hours worked by wives. **Journal of Applied Econometrics**, v. 13, n. 5, p. 543–565, 1998. DOI: 10.1002/(SICI)1099-1255(1998090)13:5<543::AID-JAE507>3.0.CO;2-J.

PEDERSEN, Thomas Lin; OOMS, Jeroen; GOVETT, Devon. **systemfonts: System Native Font Finding**. [S.l.], 2026. R package version 1.3.2. DOI: 10.32614/CRAN.package.systemfonts. Disponível em: https://CRAN.R-project.org/package=systemfonts.

POSIT TEAM. **RStudio: Integrated Development Environment for R**. Boston, MA, 2026. RStudio version 2026.04.0+526. Disponível em: http://www.posit.co/.

PROKHORENKOVA, Liudmila et al. **CatBoost: Unbiased Boosting with Categorical Features**. [S.l.: s.n.], 2017. Disponível em: https://arxiv.org/abs/1706.09516.

QIU, Yixuan. **showtext: Using Fonts More Easily in R Graphs**. [S.l.], 2026. R package version 0.9-8. DOI: 10.32614/CRAN.package.showtext. Disponível em: https://CRAN.R-project.org/package=showtext.

R CORE TEAM. **R: A Language and Environment for Statistical Computing**. Vienna, Austria, 2026. R version 4.5.3. Disponível em: https://www.R-project.org/.

RUBIN, Donald B. Estimating causal effects of treatments in randomized and nonrandomized studies. **Journal of Educational Psychology**, American Psychological Association, v. 66, n. 5, p. 688–701, 1974.

TIBSHIRANI, Ryan J. et al. Conformal Prediction Under Covariate Shift. In: ADVANCES in Neural Information Processing Systems 32. [S.l.: s.n.], 2019.

VENABLES, W. N.; RIPLEY, B. D. **Modern Applied Statistics with S**. Fourth. New York: Springer, 2002. ISBN 0-387-95457-0. Disponível em: https://www.stats.ox.ac.uk/pub/MASS4/.

VOVK, Vladimir; GAMMERMAN, Alexander; SHAFER, Glenn. **Algorithmic Learning in a Random World**. New York: Springer, 2005. ISBN 978-0-387-00152-4. DOI: 10.1007/b106715.

WICKHAM, Hadley; AVERICK, Mara et al. Welcome to the tidyverse. **Journal of Open Source Software**, v. 4, n. 43, p. 1686, 2019. DOI: 10.21105/joss.01686.

WICKHAM, Hadley; PEDERSEN, Thomas Lin; SEIDEL, Dana. **scales: Scale Functions for Visualization**. [S.l.], 2025. R package version 1.4.0. DOI: 10.32614/CRAN.package.scales. Disponível em: https://CRAN.R-project.org/package=scales.

WRIGHT, Marvin N.; ZIEGLER, Andreas. ranger: A Fast Implementation of Random Forests for High Dimensional Data in C++ and R. **Journal of Statistical Software**, v. 77, n. 1, p. 1–17, 2017. DOI: 10.18637/jss.v077.i01.

Apêndices

APÊNDICE A – METODOLOGIA EXPERIMENTAL E RESULTADOS VISUAIS

Este apêndice consolida a análise metodológica desta tese. O seu propósito é documentar, com total transparência e reprodutibilidade, o desenho experimental rigoroso, a arquitetura algorítmica (pseudocódigos) dos Processos Geradores de Dados (DGPs), e o portfólio visual das simulações que sustentam as constatações teóricas e empíricas afirmadas no Capítulo 5.

A.1 ARQUITETURA E PARAMETRIZAÇÃO DA SIMULAÇÃO

Para garantir uma comparação justa da taxa de erro e da largura dos intervalos entre os cenários, o protocolo de simulação seguiu uma configuração fixa. Em cada DGP, as amostras sintéticas foram geradas e a rotina conformal foi aplicada seguindo esta divisão em três partes:

- **Massa de Treinamento ($n_{\text{trn}} = 10.000$):** Volume dedicado exclusivamente para o treinamento do modelo basl ($\hat{\mu}_0$) e ao ajuste da superfície de seleção, o escore de propensão ($\hat{e}(x)$).
- **Vetor de Calibração ($n_{\text{cal}} \in \{200, 500, 1.000, 5.000, 10.000\}$):** Fração independente destinada para construções dos escores de não-conformidade e à delimitação exata da fronteira de probabilidade via quantil reponderado. O aumento gradativo deste vetor ajudou na investigação sobre os limites de convergência da largura.
- **Alvo Contrafactual ($n_{\text{tst}} = 10.000$):** Conjunto de teste para a mensuração de eficácia, permitindo o cálculo da cobertura empírica e da amplitude métrica do Efeito de Tratamento Individual (ITE) frente à ”verdade”geradora.

O nível nominal de significância foi fixado em $\alpha = 10\%$, garantindo uma cobertura-alvo estrita de 90%. A estratégia de inferência adaptativa e o motor de estimação da probabilidade de tratamento foram mantidos os mesmos ao longo de todos os domínios

de estresse, permitindo atribuir a variação de performance às perturbações introduzidas por cada cenário causal.

A.2 FORMALIZAÇÃO ALGORÍTMICA: PSEUDOCÓDIGOS

Os blocos lógicos a seguir deixam claro a matemática aplicada à geração dos dados e o núcleo operacional da Predição Conformal Ponderada em esquema dividido.

Algoritmo 1: Predição Conformal Ponderada em esquema dividido (ITE sob deslocamento de covariadas)

Input: Dados: D_{train}, D_{cal}, D_{test}. Nível: α. Algoritmos: $\mathcal{A}_\mu$, $\mathcal{A}_e$. e^{true} (se houver).
Output: Métricas e Intervalos para $k \in \{1, 2\}$

`// Etapa 1: Separação e Modelagem Base`

$D^0_{\text{cal}} \leftarrow \{(X_i, Y_i) \in D_{\text{cal}} \mid T_i = 0\}$
$D^1_{\text{test}} \leftarrow \{(X_j, Y_j) \in D_{\text{test}} \mid T_j = 1\}$
Treinar $\hat{\mu}_0$ via $\mathcal{A}_\mu$ nos controles de D_{train}
Treinar $\hat{e}(x)$ via $\mathcal{A}_e$ na amostra mista D_{train}

`// Etapa 2: Escores de Não-Conformidade`

for $i \in D^0_{\text{cal}}$ **do**
    $R_i \leftarrow \mathcal{S}(X_i, Y_i, \hat{\mu}_0)$ `// 𝒮: Função de erro genérica`
Ordenar resíduos: $R_{(1)} \leq R_{(2)} \leq \cdots \leq R_{(n_{\text{cal0}})}$
$\mathbf{R}_{\text{ext}} \leftarrow (R_{(1)}, \ldots, R_{(n_{\text{cal0}})}, \infty)$

`// Etapa 3: Definição dos Pesos (PS)`

$\mathbf{e}^{(1)} \leftarrow e^{\text{true}}$
$\mathbf{e}^{(2)} \leftarrow \hat{e}$

CENÁRIOS DE FISSURA DE *OVERLAP* E CONFUNDIMENTO (HMC)

CENÁRIOS DE DESLOCAMENTO DE COVARIADAS E VARIÂNCIA HETEROCEDÁSTICA (LEI ET AL.)

CENÁRIO DE EXTREMA DEGENERAÇÃO NÃO-LINEAR (HAHN)

Algoritmo 2: Predição Conformal Ponderada em esquema dividido (continuação)

// Etapa 4: Reponderação e Calibração

for $k \leftarrow 1$ **to** 2 **do**

  for $i \in D^0_{\textbf{cal}}$ **do**

    $w^{(k)}_{\text{cal},i} \leftarrow \frac{\mathbf{e}^{(k)}(X_i)}{1-\mathbf{e}^{(k)}(X_i)}$

  Reordenar $\mathbf{w}^{(k)}_{\text{cal}}$ para parear com $R_{(i)}$

  for $j \in D^1_{\textbf{test}}$ **do**

    $w^{(k)}_{\text{test},j} \leftarrow \frac{\mathbf{e}^{(k)}(X_j)}{1-\mathbf{e}^{(k)}(X_j)}$

    $\text{thr}_j \leftarrow (1-\alpha) \cdot \left(\sum_i w^{(k)}_{\text{cal},(i)} + w^{(k)}_{\text{test},j} \right)$

    // Índice que satisfaz a cobertura alvo

    $m \leftarrow \min \left\{ v : \sum_{i=1}^{v} w^{(k)}_{\text{cal},(i)} \geq \text{thr}_j \right\}$

    $\hat{r}_j \leftarrow \mathbf{R}_{\text{ext}}[m]$

    // Construção do ITE via simetria contrafactual

    $L^{(k)}_{Y(0),j} \leftarrow \hat{\mu}_0(X_j) - \hat{r}_j$

    $U^{(k)}_{Y(0),j} \leftarrow \hat{\mu}_0(X_j) + \hat{r}_j$

    $\hat{C}^{(k)}_{\text{ITE},j} \leftarrow \left[Y_j - U^{(k)}_{Y(0),j},\ Y_j - L^{(k)}_{Y(0),j} \right]$

  // Etapa 5: Consolidação de Métricas

  $N \leftarrow |D^1_{\text{test}}|$

  $\text{Cob}^{(k)} \leftarrow \frac{1}{N} \sum_j \mathbf{1}\{\text{ITE}^{\text{true}}_j \in \hat{C}^{(k)}_{\text{ITE},j}\}$

  $\text{Triv}^{(k)} \leftarrow \frac{1}{N} \sum_j \mathbf{1}\{|\hat{C}^{(k)}_{\text{ITE},j}| = \infty\}$

  $\text{Larg}^{(k)} \leftarrow \text{Mediana}_j \left(U^{(k)}_{Y(0),j} - L^{(k)}_{Y(0),j} \right)$

return $\{\hat{C}^{(k)}_{\textbf{ITE}}, \text{Cob}^{(k)}, \text{Triv}^{(k)}, \text{Larg}^{(k)}\}_{k=1}^{2}$

Algoritmo 3: DGP HMC (Forte Confusão e *Overlap* Fraco) (Carvalho, 2019b,a)

Input: Tamanho amostral n, efeito contrafactual constante $\tau = -1$, ruído $\sigma = 0.7$

Output: Conjunto de dados gerado $D = \{(X_i, T_i, Y_i)\}_{i=1}^{n}$

for $i \leftarrow 1$ **to** n **do**

  `// Etapa 1: Amostragem do espaço de covariadas`

  $x_{1,i}, x_{2,i} \sim \mathcal{N}(0, 1)$

  $X_i \leftarrow (x_{1,i}, x_{2,i})$

  `// Etapa 2: Superfície prognóstica e Mecanismo de seleção (PS)`

  if $x_{1,i} < x_{2,i}$ **then**

    $\mu_i \leftarrow 1$

  else

    $\mu_i \leftarrow -1$

  $e_i \leftarrow \Phi(\mu_i)$ `// Φ(·) é a CDF da Normal Padrão`

  $T_i \sim \text{Bernoulli}(e_i)$ `// Induz propensões extremas (≈ 0.16 e 0.84)`

  `// Etapa 3: Geração de contrafactuais` $(Y(0), Y(1))$

  $\varepsilon_{0,i}, \varepsilon_{1,i} \sim \mathcal{N}(0, \sigma^2)$ `// Ruído homoscedástico`

  $Y_i(0) \leftarrow \mu_i + \varepsilon_{0,i}$

  $Y_i(1) \leftarrow \mu_i + \tau + \varepsilon_{1,i}$

  `// Etapa 4: Desfecho factual via Equação de Neyman-Rubin`

  $Y_i \leftarrow T_i \cdot Y_i(1) + (1 - T_i) \cdot Y_i(0)$

return $D = \{(X_i, T_i, Y_i)\}_{i=1}^{n}$

Algoritmo 4: DGP HMC Complexo (Violação de *Overlap* Severa) (Hahn; Murray; Carvalho, 2020)

Input: Tamanho amostral n, efeito contrafactual constante $\tau = 3$, ruído $\sigma = 1$
Output: Conjunto de dados gerado $D = \{(X_i, T_i, Y_i)\}_{i=1}^{n}$

`// Etapa 1: Amostragem de covariáveis mistas e função base`

for $i \leftarrow 1$ **to** n **do**
- $x_{1,i}, x_{2,i}, x_{3,i} \sim \mathcal{N}(0, 1)$
- $x_{4,i} \sim \text{Categorical}(\{1, 2, 3\}, \{1/3, 1/3, 1/3\})$
- $x_{5,i} \sim \text{Bernoulli}(0.5)$
- $X_i \leftarrow (x_{1,i}, x_{2,i}, x_{3,i}, x_{4,i}, x_{5,i})$
- **if** $x_{4,i} = 1$ **then**
  - $g_i \leftarrow 2$
- **else**
  - **if** $x_{4,i} = 2$ **then**
    - $g_i \leftarrow -1$
  - **else**
    - $g_i \leftarrow -4$
- $\mu_i \leftarrow 1 + g_i + x_{1,i}x_{3,i}$ `// Superfície de confusão não linear`

$s \leftarrow \text{SD}(\{\mu_i\}_{i=1}^{n})$ `// Fator de escala amostral`

`// Etapa 2: Mecanismo de seleção e resultados contrafactuais`

for $i \leftarrow 1$ **to** n **do**
- $u_i \sim \mathcal{U}(0, 1)$
- $\tilde{e}_i \leftarrow 0.8 \cdot \Phi\left(\frac{3\mu_i}{s} - 0.5x_{1,i}\right) + 0.05 + \frac{u_i}{10}$
- `// Restrição paramétrica estrita para evitar singularidade (clipping)`
- $e_i \leftarrow \max(0.01, \min(\tilde{e}_i, 0.99))$
- $T_i \sim \text{Bernoulli}(e_i)$
- $\varepsilon_{0,i}, \varepsilon_{1,i} \sim \mathcal{N}(0, \sigma^2)$
- $Y_i(0) \leftarrow \mu_i + \varepsilon_{0,i}$
- $Y_i(1) \leftarrow \mu_i + \tau + \varepsilon_{1,i}$
- `// Desfecho factual via Equação de Neyman-Rubin`
- $Y_i \leftarrow T_i \cdot Y_i(1) + (1 - T_i) \cdot Y_i(0)$

return $D = \{(X_i, T_i, Y_i)\}_{i=1}^{n}$

Algoritmo 5: DGP Lei Complexo (Deslocamento Moderado e Heterocedasticidade) (Lei; Candès, 2021)

Input: Tamanho n, dimensão $d = 10$, correlação $\rho = 0.9$, indicador `heteroscedastic`
Output: Conjunto de dados gerado $D = \{(X_i, T_i, Y_i)\}_{i=1}^{n}$

`// Etapa 1: Construção do espaço de covariáveis correlacionadas`

$\boldsymbol{\Sigma} \leftarrow \rho \mathbf{J}_{d\times d} + (1-\rho)\mathbf{I}_d$
$\mathbf{Z} \sim \mathcal{N}_d(\mathbf{0}, \boldsymbol{\Sigma})$
for $i \leftarrow 1$ **to** n **do**
    for $j \leftarrow 1$ **to** d **do**
        $x_{j,i} \leftarrow \Phi(z_{j,i})$ `// Transformação para marginal Uniforme via CDF`
    $X_i \leftarrow (x_{1,i}, \ldots, x_{d,i})$

`// Etapa 2: Superfícies de resposta, seleção e resultados potenciais`

for $i \leftarrow 1$ **to** n **do**
    $\mu_{0,i} \leftarrow 2x_{1,i} - 3x_{2,i} + 5x_{1,i}x_{2,i}$ `// Resposta base com interação`
    $\varepsilon_{0,i} \sim \mathcal{N}(0, 0.5^2)$
    $Y_i(0) \leftarrow \mu_{0,i} + \varepsilon_{0,i}$
    `// Efeito heterogêneo de tratamento (ITE verdadeiro)`
    $\tau_i \leftarrow \frac{2}{1+\exp(-12(x_{1,i}-0.5))} \cdot \frac{2}{1+\exp(-12(x_{2,i}-0.5))}$
    `// Controle da variância do resultado sob tratamento`
    if `heteroscedastic` **then**
        $\sigma_i \leftarrow -\log(x_{1,i} + 10^{-9})$ `// Variância dependente da covariável`
    else
        $\sigma_i \leftarrow 1$
    $\varepsilon_{1,i} \sim \mathcal{N}(0, 1)$
    $Y_i(1) \leftarrow Y_i(0) + \tau_i + \sigma_i \varepsilon_{1,i}$
    `// Mecanismo de propensão (viés de seleção moderado)`
    $e_i \leftarrow 0.25 \cdot (1 + F_{\text{Beta}}(x_{1,i}; 2, 4))$
    $T_i \sim \text{Bernoulli}(e_i)$
    `// Desfecho factual observado via Equação de Neyman-Rubin`
    $Y_i \leftarrow T_i \cdot Y_i(1) + (1 - T_i) \cdot Y_i(0)$
return $D = \{(X_i, T_i, Y_i)\}_{i=1}^{n}$

Algoritmo 6: DGP Hahn (Forte Não Linearidade e Confusão) (Hahn, 2021)

Input: Tamanho amostral n, frequência $\nu = 30$, fator de ruído $\kappa = 2$
Output: Conjunto de dados gerado $D = \{(x_i, T_i, Y_i)\}_{i=1}^{n}$

// Etapa 1: Estrutura determinística e seleção direcionada
for $i \leftarrow 1$ **to** n **do**
  $x_i \leftarrow \dfrac{i-1}{n-1}$ // Covariável em grid uniforme $[0, 1]$
  $\mu_i \leftarrow 2(\sin(\nu x_i) + 1)$ // Superfície prognóstica altamente não linear
  $\tau_i \leftarrow -1 + x_i$ // Efeito de tratamento individual (ITE) linear
  // O viés de seleção correlaciona-se estritamente com a não linearidade
  $\tilde{e}_i \leftarrow \dfrac{\mu_i}{5} + 0.1$
  $e_i \leftarrow \max(0.001, \min(\tilde{e}_i, 0.999))$ // Limites de sobreposição (clipping)
  $T_i \sim \text{Bernoulli}(e_i)$
  $f_i \leftarrow \mu_i + \tau_i \cdot T_i$
$\sigma \leftarrow \kappa \cdot \text{SD}(\{f_i\}_{i=1}^{n})$ // Escalonamento do ruído via variância estrutural
// Etapa 2: Resultados contrafactuais e observáveis
for $i \leftarrow 1$ **to** n **do**
  $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$
  $Y_i(0) \leftarrow \mu_i + \varepsilon_i$
  $Y_i(1) \leftarrow \mu_i + \tau_i + \varepsilon_i$
  // Comutação para o desfecho factual (Neyman-Rubin)
  $Y_i \leftarrow T_i \cdot Y_i(1) + (1 - T_i) \cdot Y_i(0)$
return $D = \{(x_i, T_i, Y_i)\}_{i=1}^{n}$

A.3 PORTFÓLIO VISUAL DE INCERTEZA CONTRAFACTUAL

Esta seção junta graficamente o comportamento preditivo da camada conformal em cada DGP. Apresentando o espelhamento avaliativo através de duas fronteiras fundamentais de seleção de tratamento: calibração sob conhecimento do viés (PS conhecido) *versus* a realidade empírica da indução (PS estimado). Foi fixada a amostra de calibração num regime de alta estabilidade teórica ($n_{\text{cal}} = 5000$).

A leitura das Figuras 2–5 deve separar cobertura estatística de utilidade direcional. No HMC, a maioria dos intervalos contém zero porque o efeito verdadeiro constante é pequeno em módulo diante do ruído e da incerteza induzida por sobreposição fraca. No HMC Complexo, a maior magnitude do efeito reduz a inconclusão quando a calibração cresce, mas a falta de suporte ainda gera intervalos infinitos em calibrações pequenas. No DGP Hahn, o efeito verdadeiro varia em $[-1, 0]$ e frequentemente se aproxima de zero; por isso, intervalos que cruzam zero são esperados mesmo com PS conhecido, enquanto as anomalias sob PS estimado revelam instabilidade da estimação de propensão. No Lei Complexo, a cobertura é estável e as larguras são finitas, mas a heterogeneidade do efeito e a heterocedasticidade mantêm uma fração relevante de intervalos sem sinal definido. Assim, as figuras mostram uma limitação central do método: ele pode preservar validade marginal sem entregar, para muitos indivíduos, uma conclusão interpretável sobre a direção do tratamento.

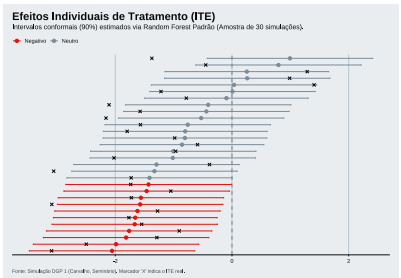
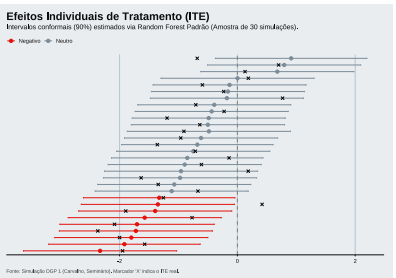
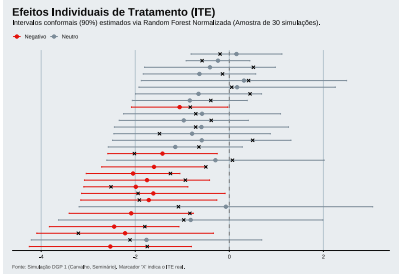
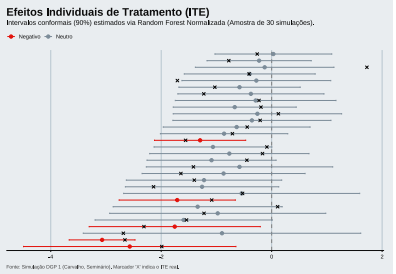
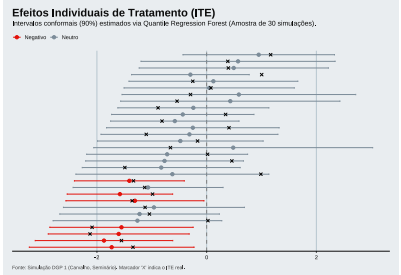
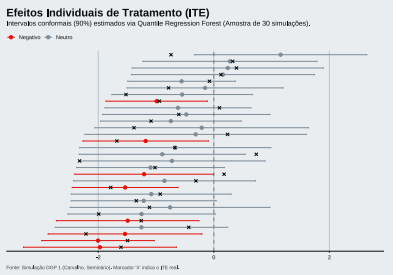
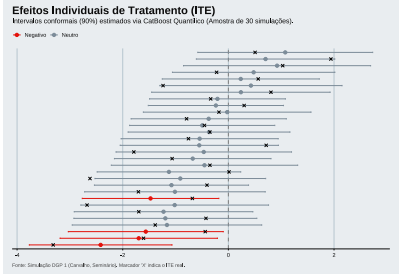
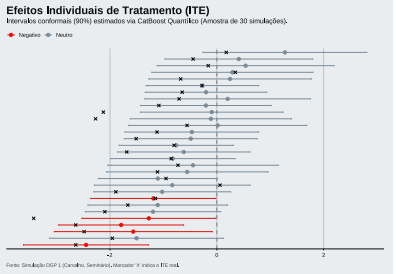
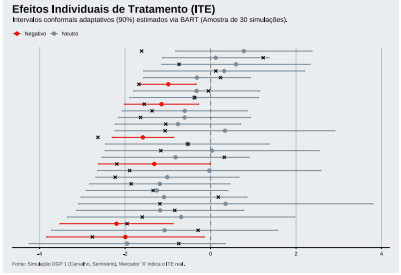
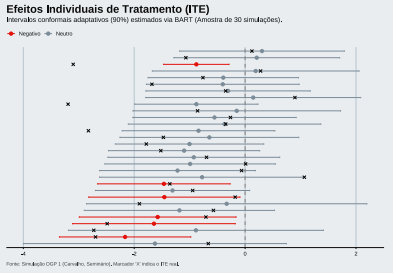
Modelo de Inferência Base	Superfície do Oráculo (PS Conhecido)	Superfície Empírica (PS Estimado)
Random Forest Margem Simétrica		
Random Forest Resíduo Normalizado		
Quantile Regression Forest		
CatBoost Otimização Quantílica		
BART Regularização Bayesiana		

Figura 2 – Processo Gerador HMC (DGP 1), em regime de densidade $n_{\text{cal}} = 5000$: Diagnóstico visual do impacto do viés de seleção sobre os intervalos de predição do ITE.

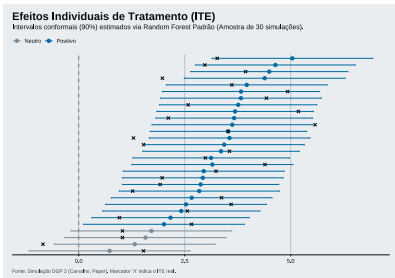
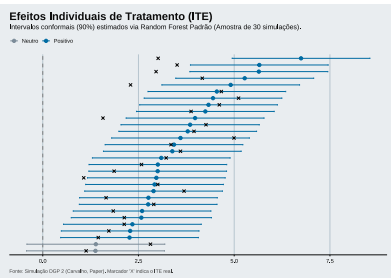
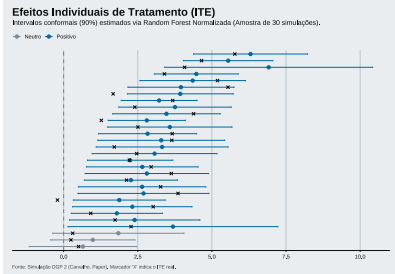
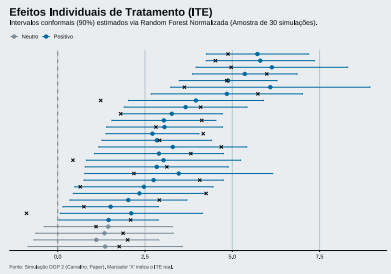
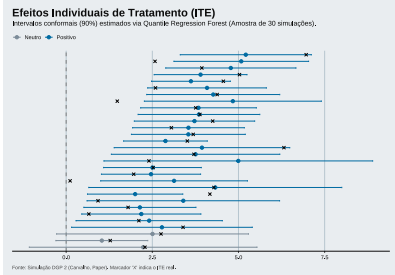
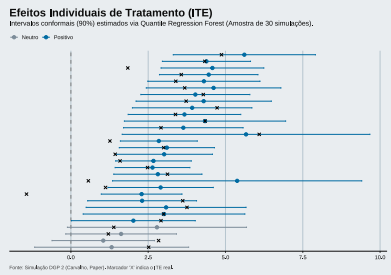
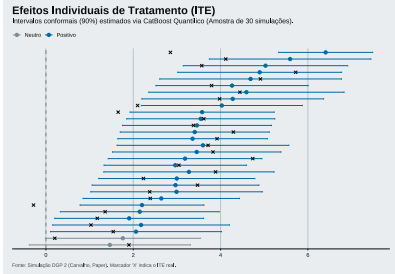
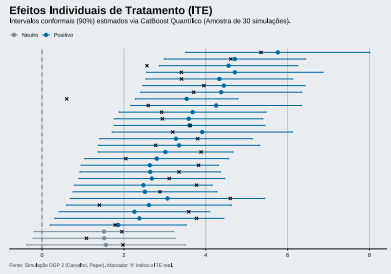
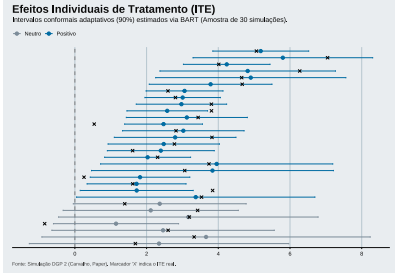
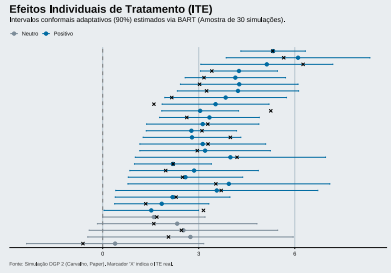
Modelo de Inferência Base	Superfície do Oráculo (PS Conhecido)	Superfície Empírica (PS Estimado)
Random Forest Margem Simétrica		
Random Forest Resíduo Normalizado		
Quantile Regression Forest		
CatBoost Otimização Quantílica		
BART Regularização Bayesiana		

Figura 3 – Processo Gerador HMC Complexo (DGP 2), em regime de densidade $n_{\text{cal}} = 5000$: Diagnóstico visual do impacto do viés de seleção sobre os intervalos de predição do ITE.

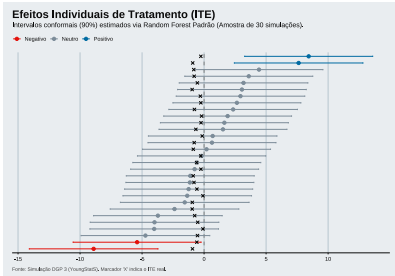
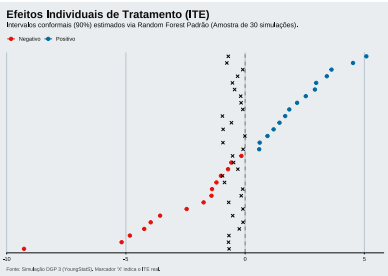
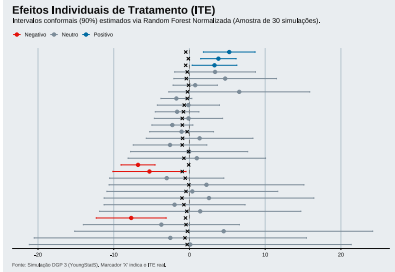
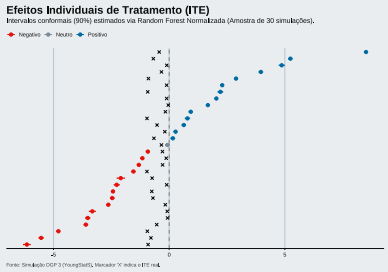
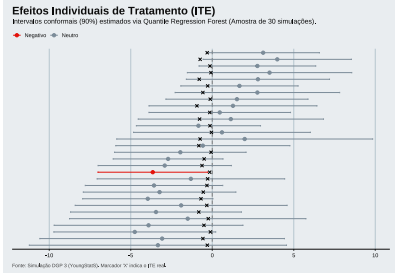
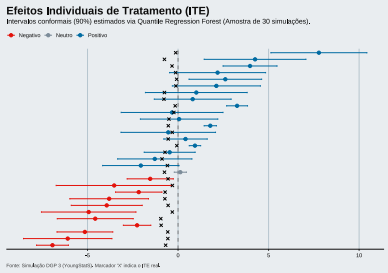
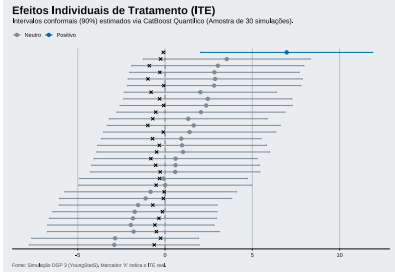
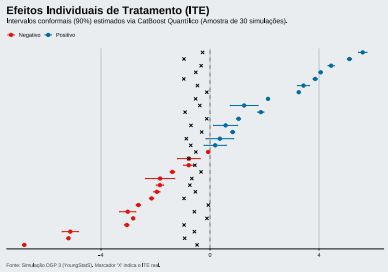
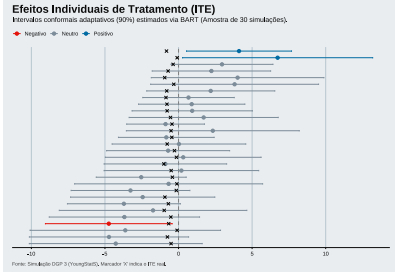
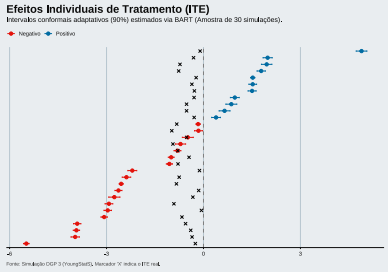
Modelo de Inferência Base	Superfície do Oráculo (PS Conhecido)	Superfície Empírica (PS Estimado)
Random Forest Margem Simétrica		
Random Forest Resíduo Normalizado		
Quantile Regression Forest		
CatBoost Otimização Quantílica		
BART Regularização Bayesiana		

Figura 4 – Processo Gerador Hahn (DGP 3), em regime de densidade $n_{\text{cal}} = 5000$: Diagnóstico visual do impacto do viés de seleção sobre os intervalos de predição do ITE.

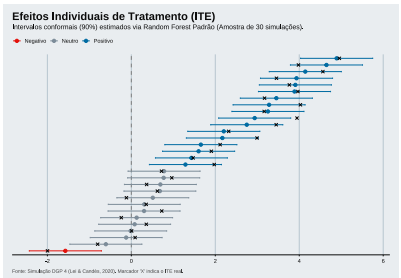
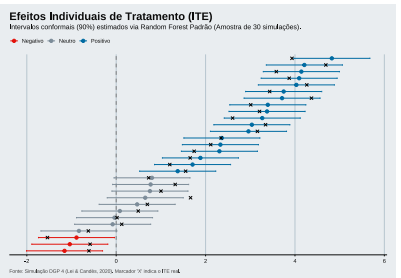
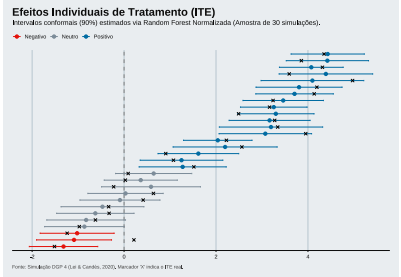
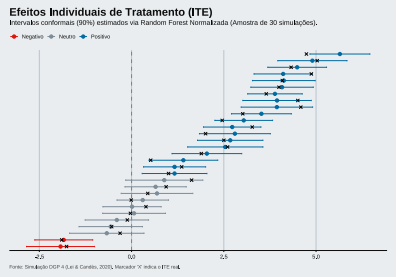
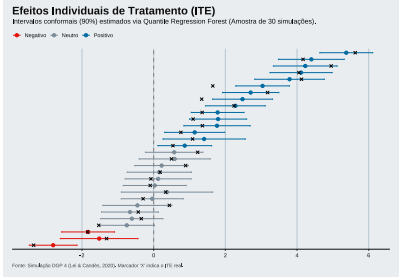
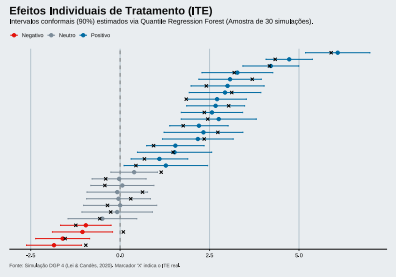
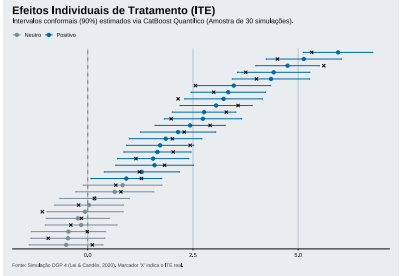
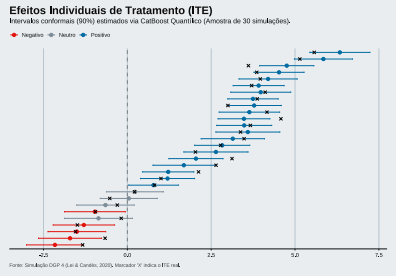
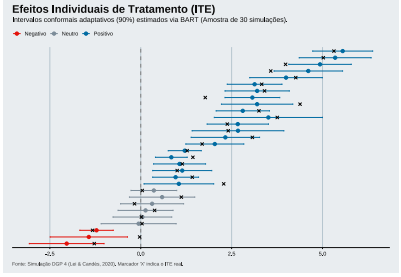
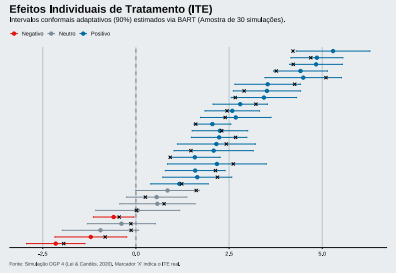
Modelo de Inferência Base	Superfície do Oráculo (PS Conhecido)	Superfície Empírica (PS Estimado)
Random Forest Margem Simétrica		
Random Forest Resíduo Normalizado		
Quantile Regression Forest		
CatBoost Otimização Quantílica		
BART Regularização Bayesiana		

Figura 5 – Processo Gerador Lei Complexo (DGP 4), em regime de densidade $n_{\text{cal}} = 5000$: Diagnóstico visual do impacto do viés de seleção sobre os intervalos de predição do ITE.

APÊNDICE B – CÓDIGOS EM R

Este apêndice apresenta os códigos em R utilizadas nas simulações e aplicações empíricas do trabalho. Os scripts foram organizados conforme a especificação estimada, preservando a estrutura original dos arquivos.

B.1 CONFIGURAÇÕES GRÁFICAS COMPARTILHADAS

O Código B.1 apresenta as configurações gráficas utilizada pelos demais scripts, incluindo paleta de cores, fonte, tema e escalas.

Código B.1 – R para configurações gráficas compartilhadas

```r
library(tidyverse)
library(scales)
library(showtext)

# Funções Gráficas The Economist ----

# Definição do tibble de cores

econ_colors_tbl <- tribble(
  ~category,           ~color_name,    ~hex,
  # Cores principais e para dados
  "branding",          "econ_red",     "#E3120B",
  "main",              "data_red",     "#DB444B",
  "main",              "blue1",        "#006BA2",
  "main",              "blue2",        "#3EBCD2",
  "main",              "green",        "#379A8B",
  "main",              "yellow",       "#EBB434",
  "main",              "olive",        "#B4BA39",
  "main",              "purple",       "#9A607F",
  "main",              "gold",         "#D1B07C",

  # Cores secundárias e para texto
  "text",              "red_text",     "#CC334C",
  "text",              "blue2_text",   "#0097A7",
  "secondary",         "mustard",      "#E6B83C",
  "secondary",         "burgundy",     "#A63D57",
  "secondary",         "mauve",        "#B48A9B",
  "secondary",         "teal",         "#008080",
  "secondary",         "aqua",         "#6FC7C7",
```

```
  # Suporte para claridade
  "supporting_bright", "purple_b",     "#924C7A",
  "supporting_bright", "pink",         "#DA3C78",
  "supporting_bright", "orange",       "#F7A11A",
  "supporting_bright", "lime",         "#B3D334",

  # Suporte para escuro
  "supporting_dark",   "navy",         "#003D73",
  "supporting_dark",   "cyan_dk",      "#005F73",
  "supporting_dark",   "green_dk",     "#385F44",

  # Fundo
  "background",        "print_bkgd",   "#E9EDF0",
  "background",        "highlight",    "#DDE8EF",
  "background",        "number_box",   "#C2D3E0",

  # Para mapas
  "maps",              "sea",          "#EBF5FB",
  "maps",              "land",         "#EBEBEB",
  "maps",              "land_text",    "#6D6E71",

  # Neutro
  "neutral",           "grid_lines",   "#B7C6CF",
  "neutral",           "grey_box",     "#7C8C99",
  "neutral",           "grey_text",    "#333333",
  "neutral",           "black25",      "#BFBFBF",
  "neutral",           "black50",      "#808080",
  "neutral",           "black75",      "#404040",
  "neutral",           "black100",     "#000000",

  # Mesma claridade
  "equal_lightness",   "red",          "#A81829",
  "equal_lightness",   "blue",         "#00588D",
  "equal_lightness",   "cyan",         "#005F73",
  "equal_lightness",   "green",        "#005F52",
  "equal_lightness",   "yellow",       "#714C00",
  "equal_lightness",   "olive",        "#4C5900",
  "equal_lightness",   "purple",       "#78405F",
  "equal_lightness",   "gold",         "#674E1F",
  "equal_lightness",   "grey",         "#3F5661"
)

# Vetor de busca

pal <- econ_colors_tbl %>%
  mutate(color_name = case_when(
    category == "equal_lightness" ~ paste0(color_name, "_eq"),
    category == "text" ~ paste0(color_name, "_txt"),
    TRUE ~ color_name
```

```r
  )) %>%
  dplyr::select(color_name, hex) %>%
  deframe()

# Configuração de Fonte

(font_family <- if ("Roboto Condensed" %in% systemfonts::system_fonts()$family)
  "Roboto Condensed" else "sans")
showtext_auto()

# Definição de Bases

econ_base <- list(
  bg   = pal["print_bkgd"],
  grid = pal["grid_lines"],
  text = "#0C0C0C"
)

# Esquemas de Cores

econ_scheme <- list(
  bars = unname(pal[c("blue1",
                      "blue2",
                      "mustard",
                      "teal",
                      "burgundy",
                      "mauve",
                      "data_red",
                      "grey_eq")]),

  web = unname(pal[c("data_red",
                     "blue1",
                     "blue2",
                     "green",
                     "yellow",
                     "olive",
                     "purple",
                     "gold")]),

  stacked     = unname(pal[c("blue1", "blue2", "mustard", "teal", "burgundy", "mauve")]),
  lines_side  = unname(pal[c("blue1", "blue2", "mustard", "teal", "burgundy", "mauve")]),

  equal       = unname(pal[grep("_eq$", names(pal))])
)

# Funções de Tema e Escala
theme_econ_base <- function(base_family = font_family) {
  theme_minimal(base_family = base_family) +
    theme(
      plot.background  = element_rect(fill = econ_base$bg, colour = NA),
```

```
      panel.background = element_rect(fill = econ_base$bg, colour = NA),

      # Títulos e Legendas
      plot.title.position = "plot",
      plot.title     = element_text(
        face = "bold",
        size = 20,
        hjust = 0,
        colour = econ_base$text,
        margin = margin(b = 4)
      ),
      plot.subtitle  = element_text(
        size = 12.5,
        hjust = 0,
        colour = econ_base$text,
        margin = margin(b = 10)
      ),
      plot.caption   = element_text(
        size = 9,
        colour = "#404040",
        hjust = 0,
        margin = margin(t = 10)
      ),

      # Eixos
      axis.title     = element_blank(),
      axis.text      = element_text(size = 10, colour = econ_base$text),
      axis.line.x    = element_line(colour = econ_base$text, linewidth = 0.6),
      axis.ticks.x   = element_line(colour = econ_base$text, linewidth = 0.6),
      axis.ticks.y   = element_blank(),

      # Grid
      panel.grid.major.y = element_line(colour = econ_base$grid, linewidth = 0.4),
      panel.grid.major.x = element_blank(),
      panel.grid.minor   = element_blank(),

      # Legenda
      legend.position = "top",
      legend.justification = "left",
      legend.title    = element_blank(),
      legend.text     = element_text(size = 10, colour = econ_base$text),
      legend.margin   = margin(t = 0, b = 5),

      plot.margin     = margin(16, 16, 12, 16)
    )
}

scale_econ <- function(aes = c("colour", "fill"),
                       scheme = "bars",
                       reverse = FALSE,
```

```
                       values = NULL,
                       ...) {
  aes <- match.arg(aes)

  pal_vec <- if (!is.null(values)) {
    unname(values)
  } else {
    if (!scheme %in% names(econ_scheme))
      scheme <- "bars"
    econ_scheme[[scheme]]
  }

  if (reverse)
    pal_vec <- rev(pal_vec)

  if (aes == "colour") {
    scale_colour_manual(values = pal_vec, ...)
  } else {
    scale_fill_manual(values = pal_vec, ...)
  }
}

fmt_lab <- function(kind = c("number", "percent", "si")) {
  kind <- match.arg(kind)
  switch(
    kind,
    number  = label_number(big.mark = ",", decimal.mark = "."),
    percent = label_percent(accuracy = 1),
    si      = label_number(scale_cut = cut_short_scale())
  )
}
```

B.2 PROPENSITY SCORE CONHECIDO

O Código B.2 são das simulações com escore de propensão conhecido.

Código B.2 – R para Propensity Score conhecido

```r
library(tidyverse)
library(dbarts)
library(ranger)
library(catboost)

# ----

# DPG : Carlos Carvalho (Seminário):
# https://www.youtube.com/watch?v=xm1CJCCNirY&t=933s
# https://faculty.mccombs.utexas.edu/carlos.carvalho/BCFTalk_March2019.pdf
# Slide : 13-14

dgp1 <- function(n, true_tau = -1, stdev = 0.7) {
  x1 <- rnorm(n)
  x2 <- rnorm(n)
  mu <- ifelse(x1 < x2, 1, -1)
  e <- pnorm(mu)
  t <- rbinom(n, size = 1, prob = e)
  y0 <- mu + rnorm(n, sd = stdev)
  y1 <- mu + true_tau + rnorm(n, sd = stdev)
  y <- ifelse(t == 1, y1, y0)
  tibble(x1, x2, e, t, y0, y1, y)
}

# DGP : Carlos Carvalo (Paper)
# https://projecteuclid.org/journalArticle/Download?urlId=10.1214%2F19-BA1195
# Seção 6.1

dgp2 <- function(n, true_tau = 3, stdev = 1) {
  x1 <- rnorm(n)
  x2 <- rnorm(n)
  x3 <- rnorm(n)
  x4 <- sample(1:3, n, replace = TRUE)
  x5 <- rbinom(n, 1, 0.5)
  g_x4 <- ifelse(x4 == 1, 2, ifelse(x4 == 2, -1, -4))
  mu <- 1 + g_x4 + x1 * x3
  s <- sd(mu)
  u <- runif(n)
  e <- pmin(pmax(0.8 * pnorm(3 * mu / s - 0.5 * x1) + 0.05 + u / 10, 0.01), 0.99)
  t <- rbinom(n, 1, prob = e)
  y0 <- mu + rnorm(n, sd = stdev)
  y1 <- mu + true_tau + rnorm(n, sd = stdev)
  y <- ifelse(t == 0, y0, y1)
```

```r
  tibble(x1, x2, x3, x4 = factor(x4), x5, t, y, y0, y1, e)
}

# DGP : YoungStatS - Richard Hahn
# https://youngstats.github.io/post/2021/01/26/machine-learning-for-causal-inference-that-works/
# "Seção" : Example

dgp3 <- function(n, v = 30, kappa = 2) {
  x <- seq(0, 1, length.out = n)
  mu_x <- 2 * (sin(v * x) + 1)
  tau_x <- -1 + x
  e <- pmin(pmax(mu_x / 5 + 0.1, 0.001), 0.999)
  t <- rbinom(n, 1, prob = e)
  sigma <- kappa * sd(mu_x + tau_x * t)
  noise <- sigma * rnorm(n)
  y0 <- mu_x + noise
  y1 <- mu_x + tau_x + noise
  y <- ifelse(t == 0, y0, y1)
  tibble(x, t, y, y0, y1, e)
}

# DGP : Lei & Candès (Paper)
# https://arxiv.org/abs/2006.06138
# Seção 3.6

dgp4 <- function(n, d = 10, rho = 0.9, heteroscedastic = FALSE) {
  Sigma <- matrix(rho, d, d)
  diag(Sigma) <- 1
  X <- data.frame(pnorm(MASS::mvrnorm(n, rep(0, d), Sigma)))
  colnames(X) <- paste0("x", 1:d)
  x1 <- X$x1
  x2 <- X$x2
  mu0 <- 2 * x1 - 3 * x2 + 5 * x1 * x2
  y0 <- mu0 + rnorm(n, sd = 0.5)
  f <- function(x) 2 / (1 + exp(-12 * (x - 0.5)))
  cate <- f(x1) * f(x2)
  eps <- rnorm(n)
  sigma <- if (heteroscedastic) -log(x1 + 1e-9) else 1
  y1 <- y0 + cate + sigma * eps
  pi <- 0.25 * (1 + pbeta(x1, 2, 4))
  t <- rbinom(n, 1, prob = pi)
  y <- t * y1 + (1 - t) * y0
  bind_cols(X, tibble(t, y, y0, y1, e = pi))
}


###

dgp <- dgp4
```

```r
dgp_fonte <- case_when(identical(dgp, dgp1) ~ "DGP 1 (Carvalho, Seminário)",
                       identical(dgp, dgp2) ~ "DGP 2 (Carvalho, Paper)",
                       identical(dgp, dgp3) ~ "DGP 3 (YoungStatS)",
                       identical(dgp, dgp4) ~ "DGP 4 (Lei & Candès, 2020)",
                       TRUE ~ "DGP Customizado")

set.seed(42)

alpha <- 0.1

alpha_out <- alpha/2

trn <- dgp(1e4)
cal <- dgp(1e4)
tst <- dgp(1e4)

# Modelo Random Forest ----

rf0 <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-e, -t, -y0, -y1))

cal0 <- cal |> filter(t == 0) |> select(-y0, -y1, -t)
tst1 <- tst |> filter(t == 1) |> select(-t)

nrow(tst1)

mu_hat_cal <- predict(rf0, data = cal0)$predictions
mu_hat_tst <- predict(rf0, data = tst1)$predictions

R <- abs(cal0$y - mu_hat_cal)

w_cal <- with(cal0[order(R), ], e / (1 - e))
w_tst <- with(tst1, e / (1 - e))

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- mu_hat_tst - r_hat
upper_y0 <- mu_hat_tst + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

true_tau <- tst1$y1 - tst1$y0

summary(upper_ite - lower_ite)

mean_rf <- mean(upper_ite - lower_ite)
```

```r
prop_inf_rf <- mean(upper_ite == Inf)
cov_zero_rf <- mean(lower_ite <= 0 & 0 <= upper_ite)
cov_tau_rf <- mean(lower_ite <= true_tau & true_tau <= upper_ite)

set.seed(42)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite, true_tau = true_tau) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  geom_point(aes(x = true_tau), color = "black", shape = 4, size = 2) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via Random Forest Padrão (Amostra de 30 simulações).",
       caption = paste0("Fonte: Simulação ", dgp_fonte, ". Marcador 'X' indica o ITE real."),
       x = "Estimativa do Efeito Contrafactual",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Modelo Quantile Regresion Forest ----

rf0 <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-e, -t, -y0, -y1), quantreg = TRUE)

cal0 <- cal |> filter(t == 0) |> select(-y0, -y1, -t)
tst1 <- tst |> filter(t == 1) |> select(-t)

nrow(tst1)

q_hat_cal <- predict(rf0, data = cal0, type = "quantiles", quantiles = c(alpha_out, 1 - alpha_out))$predictions
q_hat_tst <- predict(rf0, data = tst1, type = "quantiles", quantiles = c(alpha_out, 1 - alpha_out))$predictions

R <- pmax(q_hat_cal[, 1] - cal0$y, cal0$y - q_hat_cal[, 2])

w_cal <- with(cal0[order(R), ], e / (1 - e))
w_tst <- with(tst1, e / (1 - e))
```

```r
threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- q_hat_tst[, 1] - r_hat
upper_y0 <- q_hat_tst[, 2] + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

true_tau <- tst1$y1 - tst1$y0

summary(upper_ite - lower_ite)

mean_qrf <- mean(upper_ite - lower_ite)
prop_inf_qrf <- mean(upper_ite == Inf)
cov_zero_qrf <- mean(lower_ite <= 0 & 0 <= upper_ite)
cov_tau_qrf <- mean(lower_ite <= true_tau & true_tau <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite, true_tau = true_tau) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  geom_point(aes(x = true_tau), color = "black", shape = 4, size = 2) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via Quantile Regression Forest (Amostra de 30 simulações).",
       caption = paste0("Fonte: Simulação ", dgp_fonte, ". Marcador 'X' indica o ITE real."),
       x = "Estimativa do Efeito Contrafactual",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Bayesian Additive Regression Trees ----

bart0 <- bart2(y ~ ., data = trn |> filter(t == 0) |> select(-e, -t, -y0, -y1), keepTrees = TRUE,
      verbose = FALSE)
```

```r
cal0 <- cal |> filter(t == 0) |> select(-y0, -y1, -t)
tst1 <- tst |> filter(t == 1) |> select(-t)

nrow(tst1)

pred_cal <- predict(bart0, newdata = cal0)
pred_tst <- predict(bart0, newdata = tst1)

mu_hat_cal <- apply(pred_cal, 2, median)
sig_hat_cal <- apply(pred_cal, 2, sd)

mu_hat_tst <- apply(pred_tst, 2, median)
sig_hat_tst <- apply(pred_tst, 2, sd)

R <- abs(cal0$y - mu_hat_cal) / sig_hat_cal

w_cal <- with(cal0[order(R), ], e / (1 - e))
w_tst <- with(tst1, e / (1 - e))

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- mu_hat_tst - r_hat * sig_hat_tst
upper_y0 <- mu_hat_tst + r_hat * sig_hat_tst

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

true_tau <- tst1$y1 - tst1$y0

summary(upper_ite - lower_ite)

mean_bart <- mean(upper_ite - lower_ite)
prop_inf_bart <- mean(upper_ite == Inf)
cov_zero_bart <- mean(lower_ite <= 0 & 0 <= upper_ite)
cov_tau_bart <- mean(lower_ite <= true_tau & true_tau <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite, true_tau = true_tau) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
```

```
  geom_point(aes(x = true_tau), color = "black", shape = 4, size = 2) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais adaptativos (90%) estimados via BART (Amostra de 30 simulações).",
       caption = paste0("Fonte: Simulação ", dgp_fonte, ". Marcador 'X' indica o ITE real."),
       x = "Estimativa do Efeito Contrafactual",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Modelo Random Forest Normalizado ----

rf0 <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-e, -t, -y0, -y1))

cal0 <- cal |> filter(t == 0) |> select(-y0, -y1, -t)
tst1 <- tst |> filter(t == 1) |> select(-t)

trn0_mad <- trn |> filter(t == 0) |> select(-e, -t, -y0, -y1) |> mutate(res_abs = abs(y - rf0$predictions)) |>
  select(-y)

rf_mad <- ranger(res_abs ~ ., data = trn0_mad)

mu_hat_cal <- predict(rf0, data = cal0)$predictions
sigma_hat_cal <- pmax(predict(rf_mad, data = cal0)$predictions, 1e-6)

mu_hat_tst <- predict(rf0, data = tst1)$predictions
sigma_hat_tst <- pmax(predict(rf_mad, data = tst1)$predictions, 1e-6)

R <- abs(cal0$y - mu_hat_cal) / sigma_hat_cal

w_cal <- with(cal0[order(R), ], e / (1 - e))
w_tst <- with(tst1, e / (1 - e))

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- mu_hat_tst - r_hat * sigma_hat_tst
upper_y0 <- mu_hat_tst + r_hat * sigma_hat_tst

lower_ite <- tst1$y - upper_y0
```

```r
upper_ite <- tst1$y - lower_y0

true_tau <- tst1$y1 - tst1$y0

summary(upper_ite - lower_ite)

mean_rfn <- mean(upper_ite - lower_ite)
prop_inf_rfn <- mean(upper_ite == Inf)
cov_zero_rfn <- mean(lower_ite <= 0 & 0 <= upper_ite)
cov_tau_rfn <- mean(lower_ite <= true_tau & true_tau <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite, true_tau = true_tau) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  geom_point(aes(x = true_tau), color = "black", shape = 4, size = 2) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via Random Forest Normalizada (Amostra de 30 simulações).",
       caption = paste0("Fonte: Simulação ", dgp_fonte, ". Marcador 'X' indica o ITE real."),
       x = "Estimativa do Efeito Contrafactual",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Modelo Catboost Quantílico ----

cb_lo <- trn |> filter(t == 0) |>
  select(-c(e, t, y0, y1)) |>
  (\(df) catboost.load_pool(data = select(df, -y), label = df$y))() |>
  catboost.train(
    test_pool = NULL,
    params = c(list(iterations = 200, logging_level = "Silent"), list(loss_function = paste0("Quantile:alpha=", alpha_out)))
  )

cb_hi <- trn |>
  filter(t == 0) |>
  select(-c(e, t, y0, y1)) |>
```

```
  (\(df) catboost.load_pool(data = select(df, -y), label = df$y))() |>
  catboost.train(
    test_pool = NULL,
    params = c(list(iterations = 200, logging_level = "Silent"), list(loss_function = paste0("
     Quantile:alpha=", 1 - alpha_out)))
  )

q_hat_cal_lo <- cal0 |>
  select(-any_of(c("e", "t", "y0", "y1", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_lo, pool))()

q_hat_cal_hi <- cal0 |>
  select(-any_of(c("e", "t", "y0", "y1", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_hi, pool))()

q_hat_tst_lo <- tst1 |>
  select(-any_of(c("e", "t", "y0", "y1", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_lo, pool))()

q_hat_tst_hi <- tst1 |>
  select(-any_of(c("e", "t", "y0", "y1", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_hi, pool))()

R <- pmax(q_hat_cal_lo - cal0$y, cal0$y - q_hat_cal_hi)

w_cal <- with(cal0[order(R), ], e / (1 - e))
w_tst <- with(tst1, e / (1 - e))

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- q_hat_tst_lo - r_hat
upper_y0 <- q_hat_tst_hi + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

true_tau <- tst1$y1 - tst1$y0

summary(upper_ite - lower_ite)

mean_cbq <- mean(upper_ite - lower_ite)
prop_inf_cbq <- mean(upper_ite == Inf)
```

```r
cov_zero_cbq <- mean(lower_ite <= 0 & 0 <= upper_ite)
cov_tau_cbq <- mean(lower_ite <= true_tau & true_tau <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite, true_tau = true_tau) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  geom_point(aes(x = true_tau), color = "black", shape = 4, size = 2) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via CatBoost Quantílico (Amostra de 30
    simulações).",
       caption = paste0("Fonte: Simulação ", dgp_fonte, ". Marcador 'X' indica o ITE real."),
       x = "Estimativa do Efeito Contrafactual",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Resultados Colidados ----

(metricas_consolidadas <- tibble(
  modelo = c("Random Forest", "Quantile Forest Regression",
             "BART", "Random Forest Normalizada", "CatBoost Quantílico"),
  n_cal = nrow(cal),
  n_cal0 = nrow(cal0),
  prop_infinitos = c(prop_inf_rf, prop_inf_qrf, prop_inf_bart, prop_inf_rfn, prop_inf_cbq),
  cobertura_zero = c(cov_zero_rf, cov_zero_qrf, cov_zero_bart, cov_zero_rfn, cov_zero_cbq),
  cobertura_tau  = c(cov_tau_rf, cov_tau_qrf, cov_tau_bart, cov_tau_rfn, cov_tau_cbq),
  largura_media = c(mean_rf, mean_qrf, mean_bart, mean_rfn, mean_cbq)) |>
   labelled::set_variable_labels(
     modelo = "Arquitetura do Modelo Preditivo",
     prop_infinitos = "Taxa de Intervalos Não-Informativos (Eficiência)",
     cobertura_zero = "Taxa de Cobertura do Zero (Insignificância Causal)",
     cobertura_tau  = "Cobertura Marginal do ITE Real (Validade)",
     largura_media = "Largura Média dos Intervalos Conformais"
   ))
```

B.3 PROPENSITY SCORE DESCONHECIDO

O Código B.3 são das simulações com escore de propensão estimado.

Código B.3 – R para Propensity Score desconhecido

```r
library(tidyverse)
library(dbarts)
library(ranger)
library(catboost)

# ----
# DPG : Carlos Carvalho (Seminário):
# https://www.youtube.com/watch?v=xm1CJCCNirY&t=933s
# https://faculty.mccombs.utexas.edu/carlos.carvalho/BCFTalk_March2019.pdf
# Slide : 13-14

dgp1 <- function(n, true_tau = -1, stdev = 0.7) {
  x1 <- rnorm(n)
  x2 <- rnorm(n)
  mu <- ifelse(x1 < x2, 1, -1)
  e <- pnorm(mu)
  t <- rbinom(n, size = 1, prob = e)
  y0 <- mu + rnorm(n, sd = stdev)
  y1 <- mu + true_tau + rnorm(n, sd = stdev)
  y <- ifelse(t == 1, y1, y0)
  tibble(x1, x2, e, t, y0, y1, y)
}

# DGP : Carlos Carvalho (Paper)
# https://projecteuclid.org/journalArticle/Download?urlId=10.1214%2F19-BA1195
# Seção 6.1

dgp2 <- function(n, true_tau = 3, stdev = 1) {
  x1 <- rnorm(n)
  x2 <- rnorm(n)
  x3 <- rnorm(n)
  x4 <- sample(1:3, n, replace = TRUE)
  x5 <- rbinom(n, 1, 0.5)
  g_x4 <- ifelse(x4 == 1, 2, ifelse(x4 == 2, -1, -4))
  mu <- 1 + g_x4 + x1 * x3
  s <- sd(mu)
  u <- runif(n)
  e <- pmin(pmax(0.8 * pnorm(3 * mu / s - 0.5 * x1) + 0.05 + u / 10, 0.01), 0.99)
  t <- rbinom(n, 1, prob = e)
  y0 <- mu + rnorm(n, sd = stdev)
  y1 <- mu + true_tau + rnorm(n, sd = stdev)
  y <- ifelse(t == 0, y0, y1)
  tibble(x1, x2, x3, x4 = factor(x4), x5, t, y, y0, y1, e)
```

```r
}

# DGP : YoungStatS - Richard Hahn
# https://youngstats.github.io/post/2021/01/26/machine-learning-for-causal-inference-that-works/
# "Seção" : Example

dgp3 <- function(n, v = 30, kappa = 2) {
  x <- seq(0, 1, length.out = n)
  mu_x <- 2 * (sin(v * x) + 1)
  tau_x <- -1 + x
  e <- pmin(pmax(mu_x / 5 + 0.1, 0.001), 0.999)
  t <- rbinom(n, 1, prob = e)
  sigma <- kappa * sd(mu_x + tau_x * t)
  noise <- sigma * rnorm(n)
  y0 <- mu_x + noise
  y1 <- mu_x + tau_x + noise
  y <- ifelse(t == 0, y0, y1)
  tibble(x, t, y, y0, y1, e)
}

# DGP : Lei & Candès (Paper)
# https://arxiv.org/abs/2006.06138
# Seção 3.6

dgp4 <- function(n, d = 10, rho = 0.9, heteroscedastic = FALSE) {
  Sigma <- matrix(rho, d, d)
  diag(Sigma) <- 1
  X <- data.frame(pnorm(MASS::mvrnorm(n, rep(0, d), Sigma)))
  colnames(X) <- paste0("x", 1:d)
  x1 <- X$x1
  x2 <- X$x2
  mu0 <- 2 * x1 - 3 * x2 + 5 * x1 * x2
  y0 <- mu0 + rnorm(n, sd = 0.5)
  f <- function(x) 2 / (1 + exp(-12 * (x - 0.5)))
  cate <- f(x1) * f(x2)
  eps <- rnorm(n)
  sigma <- if (heteroscedastic) -log(x1 + 1e-9) else 1
  y1 <- y0 + cate + sigma * eps
  pi <- 0.25 * (1 + pbeta(x1, 2, 4))
  t <- rbinom(n, 1, prob = pi)
  y <- t * y1 + (1 - t) * y0
  bind_cols(X, tibble(t, y, y0, y1, e = pi))
}

###

dgp <- dgp4

dgp_fonte <- case_when(identical(dgp, dgp1) ~ "DGP 1 (Carvalho, Seminário)",
                       identical(dgp, dgp2) ~ "DGP 2 (Carvalho, Paper)",
```

```
                        identical(dgp, dgp3) ~ "DGP 3 (YoungStatS)",
                        identical(dgp, dgp4) ~ "DGP 4 (Lei & Candès, 2020)",
                        TRUE ~ "DGP Customizado")

set.seed(42)

alpha <- 0.1
alpha_out <- alpha/2

trn <- dgp(1e4)
cal <- dgp(1e4)
tst <- dgp(1e4)

ps_hat <- ranger(t ~ ., data = trn |> select(-e, -y0, -y1, -y) |> mutate(t = factor(t)),
     probability = TRUE)

cal0 <- cal |> filter(t == 0) |> select(-y0, -y1, -t)
tst1 <- tst |> filter(t == 1) |> select(-t)

e_hat_cal <- predict(ps_hat, data = cal0)$predictions[, "1"]
e_hat_tst <- predict(ps_hat, data = tst1)$predictions[, "1"]


# Modelo Random Forest ----

rf0 <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-e, -t, -y0, -y1))

mu_hat_cal <- predict(rf0, data = cal0)$predictions
mu_hat_tst <- predict(rf0, data = tst1)$predictions

R <- abs(cal0$y - mu_hat_cal)

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- mu_hat_tst - r_hat
upper_y0 <- mu_hat_tst + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

true_tau <- tst1$y1 - tst1$y0

summary(upper_ite - lower_ite)
```

```r
mean_rf <- mean(upper_ite - lower_ite)
prop_inf_rf <- mean(upper_ite == Inf)
cov_zero_rf <- mean(lower_ite <= 0 & 0 <= upper_ite)
cov_tau_rf <- mean(lower_ite <= true_tau & true_tau <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite, true_tau = true_tau) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  geom_point(aes(x = true_tau), color = "black", shape = 4, size = 2) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via Random Forest Padrão (Amostra de 30 simulações).",
       caption = paste0("Fonte: Simulação ", dgp_fonte, ". Marcador 'X' indica o ITE real."),
       x = "Estimativa do Efeito Contrafactual",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Modelo Quantile Regression Forest ----

rf0_q <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-e, -t, -y0, -y1), quantreg = TRUE)


q_hat_cal <- predict(rf0_q, data = cal0, type = "quantiles", quantiles = c(alpha_out, 1 - alpha_out))$predictions
q_hat_tst <- predict(rf0_q, data = tst1, type = "quantiles", quantiles = c(alpha_out, 1 - alpha_out))$predictions

R <- pmax(q_hat_cal[, 1] - cal0$y, cal0$y - q_hat_cal[, 2])

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1
```

```r
r_hat <- c(sort(R), Inf)[k]

lower_y0 <- q_hat_tst[, 1] - r_hat
upper_y0 <- q_hat_tst[, 2] + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

true_tau <- tst1$y1 - tst1$y0

summary(upper_ite - lower_ite)

mean_qrf <- mean(upper_ite - lower_ite)
prop_inf_qrf <- mean(upper_ite == Inf)
cov_zero_qrf <- mean(lower_ite <= 0 & 0 <= upper_ite)
cov_tau_qrf <- mean(lower_ite <= true_tau & true_tau <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite, true_tau = true_tau) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  geom_point(aes(x = true_tau), color = "black", shape = 4, size = 2) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via Quantile Regression Forest (Amostra de 30 simulações).",
       caption = paste0("Fonte: Simulação ", dgp_fonte, ". Marcador 'X' indica o ITE real."),
       x = "Estimativa do Efeito Contrafactual",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Bayesian Additive Regression Trees ----

bart0 <- bart2(y ~ ., data = trn |> filter(t == 0) |> select(-e, -t, -y0, -y1), keepTrees = TRUE,
      verbose = FALSE)

pred_cal <- predict(bart0, newdata = cal0)
pred_tst <- predict(bart0, newdata = tst1)
```

```r
mu_hat_cal <- apply(pred_cal, 2, median)
sig_hat_cal <- apply(pred_cal, 2, sd)

mu_hat_tst <- apply(pred_tst, 2, median)
sig_hat_tst <- apply(pred_tst, 2, sd)

R <- abs(cal0$y - mu_hat_cal) / sig_hat_cal

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- mu_hat_tst - r_hat * sig_hat_tst
upper_y0 <- mu_hat_tst + r_hat * sig_hat_tst

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

true_tau <- tst1$y1 - tst1$y0

summary(upper_ite - lower_ite)

mean_bart <- mean(upper_ite - lower_ite)
prop_inf_bart <- mean(upper_ite == Inf)
cov_zero_bart <- mean(lower_ite <= 0 & 0 <= upper_ite)
cov_tau_bart <- mean(lower_ite <= true_tau & true_tau <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite, true_tau = true_tau) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  geom_point(aes(x = true_tau), color = "black", shape = 4, size = 2) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais adaptativos (90%) estimados via BART (Amostra de 30
     simulações).",
       caption = paste0("Fonte: Simulação ", dgp_fonte, ". Marcador 'X' indica o ITE real."),
       x = "Estimativa do Efeito Contrafactual",
```

```
286         y = NULL) +
287   theme_econ_base() +
288   theme(
289     axis.text.y = element_blank(),
290     panel.grid.major.y = element_blank(),
291     panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

293 # Modelo Random Forest Normalizado ----

295 rf0_norm <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-e, -t, -y0, -y1))

297 trn0_mad <- trn |> filter(t == 0) |> select(-e, -t, -y0, -y1) |> mutate(res_abs = abs(y - rf0_
      norm$predictions)) |>
298   select(-y)

300 rf_mad <- ranger(res_abs ~ ., data = trn0_mad)

302 mu_hat_cal <- predict(rf0_norm, data = cal0)$predictions
303 sigma_hat_cal <- pmax(predict(rf_mad, data = cal0)$predictions, 1e-6)

305 mu_hat_tst <- predict(rf0_norm, data = tst1)$predictions
306 sigma_hat_tst <- pmax(predict(rf_mad, data = tst1)$predictions, 1e-6)

308 R <- abs(cal0$y - mu_hat_cal) / sigma_hat_cal

310 w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
311 w_tst <- e_hat_tst / (1 - e_hat_tst)

313 threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

315 k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

317 r_hat <- c(sort(R), Inf)[k]

319 lower_y0 <- mu_hat_tst - r_hat * sigma_hat_tst
320 upper_y0 <- mu_hat_tst + r_hat * sigma_hat_tst

322 lower_ite <- tst1$y - upper_y0
323 upper_ite <- tst1$y - lower_y0

325 true_tau <- tst1$y1 - tst1$y0

327 summary(upper_ite - lower_ite)

329 mean_rfn <- mean(upper_ite - lower_ite)
330 prop_inf_rfn <- mean(upper_ite == Inf)
331 cov_zero_rfn <- mean(lower_ite <= 0 & 0 <= upper_ite)
332 cov_tau_rfn <- mean(lower_ite <= true_tau & true_tau <= upper_ite)

334 tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite, true_tau = true_tau) |>
```

```r
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  geom_point(aes(x = true_tau), color = "black", shape = 4, size = 2) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via Random Forest Normalizada (Amostra de 30 simulações).",
       caption = paste0("Fonte: Simulação ", dgp_fonte, ". Marcador 'X' indica o ITE real."),
       x = "Estimativa do Efeito Contrafactual",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Modelo Catboost Quantílico ----

cb_lo <- trn |> filter(t == 0) |>
  select(-c(e, t, y0, y1)) |>
  (\(df) catboost.load_pool(data = select(df, -y), label = df$y))() |>
  catboost.train(
    test_pool = NULL,
    params = c(list(iterations = 200, logging_level = "Silent"), list(loss_function = paste0("Quantile:alpha=", alpha_out)))
  )

cb_hi <- trn |>
  filter(t == 0) |>
  select(-c(e, t, y0, y1)) |>
  (\(df) catboost.load_pool(data = select(df, -y), label = df$y))() |>
  catboost.train(
    test_pool = NULL,
    params = c(list(iterations = 200, logging_level = "Silent"), list(loss_function = paste0("Quantile:alpha=", 1 - alpha_out)))
  )

q_hat_cal_lo <- cal0 |>
  select(-any_of(c("e", "t", "y0", "y1", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_lo, pool))()
```

```r
q_hat_cal_hi <- cal0 |>
  select(-any_of(c("e", "t", "y0", "y1", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_hi, pool))()

q_hat_tst_lo <- tst1 |>
  select(-any_of(c("e", "t", "y0", "y1", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_lo, pool))()

q_hat_tst_hi <- tst1 |>
  select(-any_of(c("e", "t", "y0", "y1", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_hi, pool))()

R <- pmax(q_hat_cal_lo - cal0$y, cal0$y - q_hat_cal_hi)

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- q_hat_tst_lo - r_hat
upper_y0 <- q_hat_tst_hi + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

true_tau <- tst1$y1 - tst1$y0

summary(upper_ite - lower_ite)

mean_cbq <- mean(upper_ite - lower_ite)
prop_inf_cbq <- mean(upper_ite == Inf)
cov_zero_cbq <- mean(lower_ite <= 0 & 0 <= upper_ite)
cov_tau_cbq <- mean(lower_ite <= true_tau & true_tau <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite, true_tau = true_tau) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
```

```
  geom_point(aes(x = true_tau), color = "black", shape = 4, size = 2) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via CatBoost Quantílico (Amostra de 30
      simulações).",
       caption = paste0("Fonte: Simulação ", dgp_fonte, ". Marcador 'X' indica o ITE real."),
       x = "Estimativa do Efeito Contrafactual",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Resultados Colidados ----

(metricas_consolidadas <- tibble(
  modelo = c("Random Forest", "Quantile Forest Regression",
             "BART", "Random Forest Normalizada", "CatBoost Quantílico"),
  n_cal = nrow(cal),
  n_cal0 = nrow(cal0),
  prop_infinitos = c(prop_inf_rf, prop_inf_qrf, prop_inf_bart, prop_inf_rfn, prop_inf_cbq),
  cobertura_zero = c(cov_zero_rf, cov_zero_qrf, cov_zero_bart, cov_zero_rfn, cov_zero_cbq),
  cobertura_tau  = c(cov_tau_rf, cov_tau_qrf, cov_tau_bart, cov_tau_rfn, cov_tau_cbq),
  largura_media = c(mean_rf, mean_qrf, mean_bart, mean_rfn, mean_cbq)) |>
   labelled::set_variable_labels(
     modelo = "Arquitetura do Modelo Preditivo",
     prop_infinitos = "Taxa de Intervalos Não-Informativos (Eficiência)",
     cobertura_zero = "Taxa de Cobertura do Zero (Insignificância Causal)",
     cobertura_tau  = "Cobertura Marginal do ITE Real (Validade)",
     largura_media = "Largura Média dos Intervalos Conformais"
   ))
```

B.4 APLICAÇÃO COM DADOS DO PROJETO STAR

O Código B.4 é da aplicação com dados do projeto STAR.

Código B.4 – R para a aplicação com dados do projeto STAR

```r
library(tidyverse)
library(dbarts)
library(ranger)
library(catboost)

# ----

data(star, package = "mlmRev")

db <- star |>
  as_tibble() |>
  drop_na() |>
  mutate(t = if_else(cltype == "small", 1, 0)) |>
  rename(y = math) |>
  select(-id, -cltype)

set.seed(42)

alpha <- 0.1
alpha_out <- alpha/2

idx <- sample(c(1, 2, 3), nrow(db), replace = TRUE, prob = c(0.5, 0.25, 0.25))

trn <- db[idx == 1, ]
cal <- db[idx == 2, ]
tst <- db[idx == 3, ]

ps_hat <- ranger(t ~ ., data = trn |> select(-y) |> mutate(t = factor(t)), probability = TRUE)

cal0 <- cal |> filter(t == 0)
tst1 <- tst |> filter(t == 1)

e_hat_cal <- predict(ps_hat, data = cal0 |> select(-y))$predictions[, "1"]
e_hat_tst <- predict(ps_hat, data = tst1 |> select(-y))$predictions[, "1"]

# Modelo Random Forest ----

rf0 <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-t))

mu_hat_cal <- predict(rf0, data = cal0 |> select(-t))$predictions
mu_hat_tst <- predict(rf0, data = tst1 |> select(-t))$predictions

R <- abs(cal0$y - mu_hat_cal)
```

```r
w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- mu_hat_tst - r_hat
upper_y0 <- mu_hat_tst + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

summary(upper_ite - lower_ite)

mean_rf <- mean(upper_ite - lower_ite)
prop_inf_rf <- mean(upper_ite == Inf)
cov_zero_rf <- mean(lower_ite <= 0 & 0 <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
    geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
    geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
    geom_point(size = 2.5) +
    scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                  "Neutro" = unname(pal["grey_box"]),
                                  "Negativo" = unname(pal["econ_red"]))) +
    labs(title = "Efeitos Individuais de Tratamento (ITE)",
         subtitle = "Intervalos conformais (90%) estimados via Random Forest Padrão em uma
     amostra de 30 alunos.",
         caption = "Fonte: Elaboração própria com dados do projeto STAR (pacote mlmRev).",
         x = "Estimativa do Efeito Contrafactual nas Notas de Matemática",
         y = NULL) +
    theme_econ_base() +
    theme(
      axis.text.y = element_blank(),
      panel.grid.major.y = element_blank(),
      panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Modelo Quantile Regression Forest ----

rf0_q <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-t), quantreg = TRUE)
```

```
q_hat_cal <- predict(rf0_q, data = cal0, type = "quantiles", quantiles = c(alpha_out, 1 - alpha_
    out))$predictions
q_hat_tst <- predict(rf0_q, data = tst1, type = "quantiles", quantiles = c(alpha_out, 1 - alpha_
    out))$predictions

R <- pmax(q_hat_cal[, 1] - cal0$y, cal0$y - q_hat_cal[, 2])

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- q_hat_tst[, 1] - r_hat
upper_y0 <- q_hat_tst[, 2] + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

summary(upper_ite - lower_ite)

mean_qrf <- mean(upper_ite - lower_ite)
prop_inf_qrf <- mean(upper_ite == Inf)
cov_zero_qrf <- mean(lower_ite <= 0 & 0 <= upper_ite)

set.seed(42)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via Quantile Regression Forest em uma
    amostra de 30 alunos.",
       caption = "Fonte: Elaboração própria com dados do projeto STAR (pacote mlmRev).",
       x = "Estimativa do Efeito Contrafactual nas Notas de Matemática",
       y = NULL) +
  theme_econ_base() +
  theme(
```

```r
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Bayesian Additive Regression Trees ----

bart0 <- bart2(y ~ ., data = trn |> filter(t == 0) |> select(-t), keepTrees = TRUE, verbose =
    FALSE)

pred_cal <- predict(bart0, newdata = cal0)
pred_tst <- predict(bart0, newdata = tst1)

mu_hat_cal <- apply(pred_cal, 2, median)
sig_hat_cal <- apply(pred_cal, 2, sd)

mu_hat_tst <- apply(pred_tst, 2, median)
sig_hat_tst <- apply(pred_tst, 2, sd)

R <- abs(cal0$y - mu_hat_cal) / sig_hat_cal

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- mu_hat_tst - r_hat * sig_hat_tst
upper_y0 <- mu_hat_tst + r_hat * sig_hat_tst

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

summary(upper_ite - lower_ite)

mean_bart <- mean(upper_ite - lower_ite)
prop_inf_bart <- mean(upper_ite == Inf)
cov_zero_bart <- mean(lower_ite <= 0 & 0 <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
```

```
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais adaptativos (90%) estimados via BART em uma amostra de 30 alunos.",
       caption = "Fonte: Elaboração própria com dados do projeto STAR (pacote mlmRev).",
       x = "Estimativa do Efeito Contrafactual nas Notas de Matemática",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Modelo Random Forest Normalizado ----

rf0_norm <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-t))

trn0_mad <- trn |> filter(t == 0) |> select(-t) |> mutate(res_abs = abs(y - rf0_norm$predictions)) |>
  select(-y)

rf_mad <- ranger(res_abs ~ ., data = trn0_mad)

mu_hat_cal <- predict(rf0_norm, data = cal0)$predictions
sigma_hat_cal <- pmax(predict(rf_mad, data = cal0)$predictions, 1e-6)

mu_hat_tst <- predict(rf0_norm, data = tst1)$predictions
sigma_hat_tst <- pmax(predict(rf_mad, data = tst1)$predictions, 1e-6)

R <- abs(cal0$y - mu_hat_cal) / sigma_hat_cal

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- mu_hat_tst - r_hat * sigma_hat_tst
upper_y0 <- mu_hat_tst + r_hat * sigma_hat_tst

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

summary(upper_ite - lower_ite)
```

```r
mean_rfn <- mean(upper_ite - lower_ite)
prop_inf_rfn <- mean(upper_ite == Inf)
cov_zero_rfn <- mean(lower_ite <= 0 & 0 <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via Random Forest Normalizada em uma
    amostra de 30 alunos.",
       caption = "Fonte: Elaboração própria com dados do projeto STAR (pacote mlmRev).",
       x = "Estimativa do Efeito Contrafactual nas Notas de Matemática",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Modelo Catboost Quantílico ----

cb_lo <- trn |>
  filter(t == 0) |>
  select(-t) |>
  (\(df) catboost.load_pool(data = select(df, -y), label = df$y))() |>
  catboost.train(
    test_pool = NULL,
    params = c(list(iterations = 200, logging_level = "Silent"),
               list(loss_function = paste0("Quantile:alpha=", alpha_out))))

cb_hi <- trn |>
  filter(t == 0) |>
  select(-t) |>
  (\(df) catboost.load_pool(data = select(df, -y), label = df$y))() |>
  catboost.train(
    test_pool = NULL,
    params = c(list(iterations = 200, logging_level = "Silent"),
               list(loss_function = paste0("Quantile:alpha=", 1 - alpha_out))))

q_hat_cal_lo <- cal0 |>
  select(-any_of(c("t", "y"))) |>
```

```
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_lo, pool))()

q_hat_cal_hi <- cal0 |>
  select(-any_of(c("t", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_hi, pool))()

q_hat_tst_lo <- tst1 |>
  select(-any_of(c("t", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_lo, pool))()

q_hat_tst_hi <- tst1 |>
  select(-any_of(c("t", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_hi, pool))()

R <- pmax(q_hat_cal_lo - cal0$y, cal0$y - q_hat_cal_hi)

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- q_hat_tst_lo - r_hat
upper_y0 <- q_hat_tst_hi + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

summary(upper_ite - lower_ite)

mean_cbq <- mean(upper_ite - lower_ite)
prop_inf_cbq <- mean(upper_ite == Inf)
cov_zero_cbq <- mean(lower_ite <= 0 & 0 <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
```

```r
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via CatBoost Quantílico em uma amostra de 30 alunos.",
       caption = "Fonte: Elaboração própria com dados do projeto STAR (pacote mlmRev).",
       x = "Estimativa do Efeito Contrafactual nas Notas de Matemática",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Resultados Colidados ----

(metricas_consolidadas <- tibble(
  modelo = c("Random Forest", "Quantile Forest Regression",
             "BART", "Random Forest Normalizada", "CatBoost Quantílico"),
  n_cal = nrow(cal),
  n_cal0 = nrow(cal0),
  prop_infinitos = c(prop_inf_rf, prop_inf_qrf, prop_inf_bart, prop_inf_rfn, prop_inf_cbq),
  cobertura_zero = c(cov_zero_rf, cov_zero_qrf, cov_zero_bart, cov_zero_rfn, cov_zero_cbq),
  largura_media = c(mean_rf, mean_qrf, mean_bart, mean_rfn, mean_cbq)) |>
   labelled::set_variable_labels(
     modelo = "Arquitetura do Modelo Preditivo",
     prop_infinitos = "Taxa de Intervalos Não-Informativos (Eficiência)",
     cobertura_zero = "Taxa de Cobertura do Zero (Insignificância Causal)",
     largura_media = "Largura Média dos Intervalos Conformais"))
```

B.5 APLICAÇÃO COM DADOS DE SEGURO DE SAÚDE

O Código B.5 é da aplicação com dados de seguro de saúde.

Código B.5 – R para a aplicação com dados de seguro de saúde

```r
library(tidyverse)
library(dbarts)
library(ranger)
library(catboost)

# ----

data(HI, package = "Ecdat")

db <- HI |>
  as_tibble() |>
  drop_na() |>
  mutate(t = if_else(hhi == "yes", 1, 0)) |>
  rename(y = whrswk) |>
  select(-hhi, -wght)

set.seed(42)

alpha <- 0.1
alpha_out <- alpha/2

idx <- sample(c(1, 2, 3), nrow(db), replace = TRUE, prob = c(0.5, 0.25, 0.25))

trn <- db[idx == 1, ]
cal <- db[idx == 2, ]
tst <- db[idx == 3, ]

ps_hat <- ranger(t ~ ., data = trn |> select(-y) |> mutate(t = factor(t)), probability = TRUE)

cal0 <- cal |> filter(t == 0)
tst1 <- tst |> filter(t == 1)

e_hat_cal <- predict(ps_hat, data = cal0 |> select(-y))$predictions[, "1"]
e_hat_tst <- predict(ps_hat, data = tst1 |> select(-y))$predictions[, "1"]

# Modelo Random Forest ----

rf0 <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-t))

mu_hat_cal <- predict(rf0, data = cal0 |> select(-t))$predictions
mu_hat_tst <- predict(rf0, data = tst1 |> select(-t))$predictions

R <- abs(cal0$y - mu_hat_cal)
```

```r
w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- mu_hat_tst - r_hat
upper_y0 <- mu_hat_tst + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

summary(upper_ite - lower_ite)

mean_rf <- mean(upper_ite - lower_ite)
prop_inf_rf <- mean(upper_ite == Inf)
cov_zero_rf <- mean(lower_ite <= 0 & 0 <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via Random Forest Padrão em uma amostra de 30 mulheres.",
       caption = "Fonte: Elaboração própria com dados de Seguro de Saúde - HI (pacote Ecdat).",
       x = "Estimativa do Efeito Contrafactual nas Horas Trabalhadas por Semana",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Modelo Quantile Regression Forest ----

rf0_q <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-t), quantreg = TRUE)
```

```r
q_hat_cal <- predict(rf0_q, data = cal0, type = "quantiles", quantiles = c(alpha_out, 1 - alpha_out))$predictions
q_hat_tst <- predict(rf0_q, data = tst1, type = "quantiles", quantiles = c(alpha_out, 1 - alpha_out))$predictions

R <- pmax(q_hat_cal[, 1] - cal0$y, cal0$y - q_hat_cal[, 2])

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- q_hat_tst[, 1] - r_hat
upper_y0 <- q_hat_tst[, 2] + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

summary(upper_ite - lower_ite)

mean_qrf <- mean(upper_ite - lower_ite)
prop_inf_qrf <- mean(upper_ite == Inf)
cov_zero_qrf <- mean(lower_ite <= 0 & 0 <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via Quantile Regression Forest em uma amostra de 30 mulheres.",
       caption = "Fonte: Elaboração própria com dados de Seguro de Saúde - HI (pacote Ecdat).",
       x = "Estimativa do Efeito Contrafactual nas Horas Trabalhadas por Semana",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
```

```r
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Bayesian Additive Regression Trees ----

bart0 <- bart2(y ~ ., data = trn |> filter(t == 0) |> select(-t), keepTrees = TRUE, verbose =
    FALSE)

pred_cal <- predict(bart0, newdata = cal0)
pred_tst <- predict(bart0, newdata = tst1)

mu_hat_cal <- apply(pred_cal, 2, median)
sig_hat_cal <- apply(pred_cal, 2, sd)

mu_hat_tst <- apply(pred_tst, 2, median)
sig_hat_tst <- apply(pred_tst, 2, sd)

R <- abs(cal0$y - mu_hat_cal) / sig_hat_cal

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- mu_hat_tst - r_hat * sig_hat_tst
upper_y0 <- mu_hat_tst + r_hat * sig_hat_tst

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

summary(upper_ite - lower_ite)

mean_bart <- mean(upper_ite - lower_ite)
prop_inf_bart <- mean(upper_ite == Inf)
cov_zero_bart <- mean(lower_ite <= 0 & 0 <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
```

```
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais adaptativos (90%) estimados via BART em uma amostra de
    30 mulheres.",
       caption = "Fonte: Elaboração própria com dados de Seguro de Saúde - HI (pacote Ecdat).",
       x = "Estimativa do Efeito Contrafactual nas Horas Trabalhadas por Semana",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Modelo Random Forest Normalizado ----

rf0_norm <- ranger(y ~ ., data = trn |> filter(t == 0) |> select(-t))

trn0_mad <- trn |> filter(t == 0) |> select(-t) |> mutate(res_abs = abs(y - rf0_norm$predictions)
    ) |>
  select(-y)

rf_mad <- ranger(res_abs ~ ., data = trn0_mad)

mu_hat_cal <- predict(rf0_norm, data = cal0)$predictions
sigma_hat_cal <- pmax(predict(rf_mad, data = cal0)$predictions, 1e-6)

mu_hat_tst <- predict(rf0_norm, data = tst1)$predictions
sigma_hat_tst <- pmax(predict(rf_mad, data = tst1)$predictions, 1e-6)

R <- abs(cal0$y - mu_hat_cal) / sigma_hat_cal

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- mu_hat_tst - r_hat * sigma_hat_tst
upper_y0 <- mu_hat_tst + r_hat * sigma_hat_tst

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

summary(upper_ite - lower_ite)

mean_rfn <- mean(upper_ite - lower_ite)
prop_inf_rfn <- mean(upper_ite == Inf)
```

```r
cov_zero_rfn <- mean(lower_ite <= 0 & 0 <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via Random Forest Normalizada em uma
    amostra de 30 mulheres.",
       caption = "Fonte: Elaboração própria com dados de Seguro de Saúde - HI (pacote Ecdat).",
       x = "Estimativa do Efeito Contrafactual nas Horas Trabalhadas por Semana",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Modelo Catboost Quantílico ----

cb_lo <- trn |>
  filter(t == 0) |>
  select(-t) |>
  (\(df) catboost.load_pool(data = select(df, -y), label = df$y))() |>
  catboost.train(
    test_pool = NULL,
    params = c(list(iterations = 200, logging_level = "Silent"),
               list(loss_function = paste0("Quantile:alpha=", alpha_out))))

cb_hi <- trn |>
  filter(t == 0) |>
  select(-t) |>
  (\(df) catboost.load_pool(data = select(df, -y), label = df$y))() |>
  catboost.train(
    test_pool = NULL,
    params = c(list(iterations = 200, logging_level = "Silent"),
               list(loss_function = paste0("Quantile:alpha=", 1 - alpha_out))))

q_hat_cal_lo <- cal0 |>
  select(-any_of(c("t", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_lo, pool))()
```

```
q_hat_cal_hi <- cal0 |>
  select(-any_of(c("t", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_hi, pool))()

q_hat_tst_lo <- tst1 |>
  select(-any_of(c("t", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_lo, pool))()

q_hat_tst_hi <- tst1 |>
  select(-any_of(c("t", "y"))) |>
  (\(df) catboost.load_pool(data = df))() |>
  (\(pool) catboost.predict(cb_hi, pool))()

R <- pmax(q_hat_cal_lo - cal0$y, cal0$y - q_hat_cal_hi)

w_cal <- e_hat_cal[order(R)] / (1 - e_hat_cal[order(R)])
w_tst <- e_hat_tst / (1 - e_hat_tst)

threshold <- (1 - alpha) * (sum(w_cal) + w_tst)

k <- findInterval(threshold, cumsum(w_cal), left.open = TRUE) + 1

r_hat <- c(sort(R), Inf)[k]

lower_y0 <- q_hat_tst_lo - r_hat
upper_y0 <- q_hat_tst_hi + r_hat

lower_ite <- tst1$y - upper_y0
upper_ite <- tst1$y - lower_y0

summary(upper_ite - lower_ite)

mean_cbq <- mean(upper_ite - lower_ite)
prop_inf_cbq <- mean(upper_ite == Inf)
cov_zero_cbq <- mean(lower_ite <= 0 & 0 <= upper_ite)

tibble(id = 1:nrow(tst1), lower = lower_ite, upper = upper_ite) |>
  slice_sample(n = 30) |>
  mutate(ite_est = (lower + upper) / 2,
         status = case_when(lower > 0 ~ "Positivo", upper < 0 ~ "Negativo", TRUE ~ "Neutro"),
         id = fct_reorder(factor(id), lower)) |>
  ggplot(aes(ite_est, id, color = status)) +
  geom_vline(xintercept = 0, lty = 2, color = pal["black50"], linewidth = 0.8) +
  geom_errorbarh(aes(xmin = lower, xmax = upper), height = 0.2, linewidth = 0.8) +
  geom_point(size = 2.5) +
  scale_color_manual(values = c("Positivo" = unname(pal["blue1"]),
                                "Neutro" = unname(pal["grey_box"]),
```

```
                                "Negativo" = unname(pal["econ_red"]))) +
  labs(title = "Efeitos Individuais de Tratamento (ITE)",
       subtitle = "Intervalos conformais (90%) estimados via CatBoost Quantílico em uma amostra de 30 mulheres.",
       caption = "Fonte: Elaboração própria com dados de Seguro de Saúde - HI (pacote Ecdat).",
       x = "Estimativa do Efeito Contrafactual nas Horas Trabalhadas por Semana",
       y = NULL) +
  theme_econ_base() +
  theme(
    axis.text.y = element_blank(),
    panel.grid.major.y = element_blank(),
    panel.grid.major.x = element_line(colour = econ_base$grid, linewidth = 0.4))

# Resultados Colidados ----

(metricas_consolidadas <- tibble(
  modelo = c("Random Forest", "Quantile Forest Regression",
             "BART", "Random Forest Normalizada", "CatBoost Quantílico"),
  n_cal = nrow(cal),
  n_cal0 = nrow(cal0),
  prop_infinitos = c(prop_inf_rf, prop_inf_qrf, prop_inf_bart, prop_inf_rfn, prop_inf_cbq),
  cobertura_zero = c(cov_zero_rf, cov_zero_qrf, cov_zero_bart, cov_zero_rfn, cov_zero_cbq),
  largura_media = c(mean_rf, mean_qrf, mean_bart, mean_rfn, mean_cbq)) |>
   labelled::set_variable_labels(
     modelo = "Arquitetura do Modelo Preditivo",
     prop_infinitos = "Taxa de Intervalos Não-Informativos (Eficiência)",
     cobertura_zero = "Taxa de Cobertura do Zero (Insignificância Causal)",
     largura_media = "Largura Média dos Intervalos Conformais"))
```